



UNIVERSIDAD AUTÓNOMA DE
CHIAPAS



FACULTAD DE CIENCIAS EN FÍSICA Y
MATEMÁTICAS

Aproximación numérica de la solución para
ecuaciones diferenciales estocásticas con
saltos

T E S I S

QUE PARA OBTENER EL GRADO DE:
MAESTRA EN CIENCIAS MATEMÁTICAS

PRESENTA:
MARA DOMINGUEZ LIMAS X180099

DIRECTOR DE TESIS:
Dr. YOFRE HERNÁN GARCÍA GÓMEZ

Tuxtla Gutiérrez, Chiapas a 1 de octubre de 2026.

Apoyado con beca SECIHTI y Proyecto Ciencia Básica y De
Frontera CBF 2025 -I-4436

Dedicatoria

Agradecimientos

Tabla de contenidos

1	Resumen	7
1.1	Abstract	8
2	Abstract	9
3	Introducción	10
4	Objetivos	12
4.1	Objetivo general:	12
4.2	Objetivos específicos:	12
5	Resultados técnicos fundamentales	14
5.1	Espacios de Probabilidad y Filtraciones	14
5.2	Resultados de Teoría de la Medida y Análisis Funcional	15
5.2.1	Fundamentos de Inferencia Estadística	16
5.3	Procesos Estocásticos Fundamentales	18
5.4	Desigualdades y Lemmas Clásicos	19
5.5	Medidas Aleatorias de Poisson.	23
5.6	Espacios Funcionales para Procesos Predecibles.	27
5.6.1	Definición del espacio $L^2_{\text{pred}}(\tilde{N})$ y su norma.	27
5.7	La Integral de Itô para Movimiento Browniano.	28
5.7.1	Extensión a $\mathcal{H}^2$ por densidad.	28
5.7.2	Integral como proceso y propiedades	29
5.7.3	Extensión por localización	29
5.8	La Integral de Itô para la Parte de Saltos.	30
5.9	Fórmula de Itô	31
5.10	Variación Cuadrática y Desigualdades de Martingalas	32
6	Ecuaciones diferenciales estocásticas.	36
6.1	Formulación y Teoremas de Existencia y Unicidad	36
6.1.1	Teorema de existencia y unicidad global de una solución fuerte para la EDE con difusión y saltos	36
6.1.2	Teorema de existencia y unicidad local de una solución fuerte para la EDE con difusión y saltos	43
6.2	Modelo de Cramér–Lundberg Extendido.	46
6.2.1	Formulación del modelo base (C-L clásico).	46
6.2.2	Extensión del modelo (C-L) a un modelo con difusión y saltos.	47

6.3	Análisis Asintótico y Estimación de Parámetros	49
6.3.1	Estimación de la Varianza Integrada	49
6.3.2	Hipótesis técnicas	50
6.4	Estimación de la Intensidad de Saltos.	54
6.4.1	Estimador $\hat{\lambda}_n$ y elección del umbral $\tau_n = \alpha \Delta_n^\varpi$	54
6.4.2	Estimación no paramétrica de la distribución de severidad de los saltos.	56
6.4.3	Distribución de los tiempos entre saltos detectados	63
7	Métodos Numéricos para EDE	72
7.1	Introducción a la Discretización de EDE con difusión y salto.	72
7.1.1	Formulación general del modelo de Cramér–Lundberg con reinversión como EDESJ.	73
7.2	Esquema de Milstein	74
7.3	Esquema de Milstein Compensado	75
7.4	Esquema Semi-Implícito Compensado	79
7.5	Método Monte Carlo	84
7.5.1	Estimador de Monte Carlo	84
7.5.2	Convergencia y rigor asintótico.	84
7.5.3	Generación de variables aleatorias.	86
7.5.4	Técnicas de Reducción de Varianza.	86
8	Implementación Numérica.	87
8.1	Estimación de Parámetros para el mercado de seguros de bienes raíces Mexicano	87
8.1.1	Función de Primas Ajustadas por Inflación: $c(t)$	87
8.1.2	Modelado de la tasa de inversión: $r(t)$	88
8.1.3	Modelado de la volatilidad de Inversiones $\sigma(t)$	89
8.1.4	Función de Costos de Saltos: Eventos Meteorológicos y Sísmicos.	91
8.3	Aproximación numérica del modelo de Crámer Lundberg extendido	96
8.4	Implementación Numérica Métodos Milstein y Semi-Implícito.	97
8.4.1	Pseudocódigo: Esquema de Milstein Compensado para EDE con Difusión y Salto.	97
8.4.2	Pseudocódigo: Esquema Semi-Implícito Compensado para EDE con Difusión y Salto	101
9	Análisis de Resultados.	105
9.1	Simulación Milstein sin Compensación.	105
9.2	Milstein compensado.	107
9.3	Semi-Implícito compensado.	108
9.4	Análisis Cuantitativo de la Simulación	108
9.4.1	Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein vs Semi-Implícito y Compensación.	109

9.5	Análisis de la Trayectoria Mediana y Estructura de Saltos	110
9.5.1	Análisis de Monte Carlo y Pronóstico mediante Mediana	111
9.6	Distribución de severidad de los saltos detectados y distribución de los tiempos entre detecciones	111
9.6.1	Configuración común y calibración del detector	112
9.6.2	Distribución agregada de las severidades detectadas	118
9.6.3	Estimación no paramétrica mediante ECDF	119
9.7	9.6.2.2. Estimación de densidad mediante KDE	120
9.7.1	Ajustes paramétricos auxiliares	122
9.7.2	Distribución de los tiempos entre detecciones	123
9.7.3	Estimación de la intensidad estacional de las detecciones	128
9.7.4	Diagnóstico mediante el cambio de tiempo	130
9.7.5	Comparación integrada de los resultados	131
9.8	Implicaciones para la Gestión de Riesgos en el Contexto de la CDMX . .	132
9.8.1	Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein vs Semi-Implícito y Compensación.	133
9.9	Análisis de la Trayectoria Mediana y Estructura de Saltos	153
9.9.1	Análisis de Monte Carlo y Pronóstico mediante Mediana	154
9.10	Implicaciones para la Gestión de Riesgos en el Contexto de la CDMX . .	154
10	Conclusiones.	156
	Referencias	160

1 Resumen

En este trabajo se aborda el problema de la aproximación numérica de soluciones de ecuaciones diferenciales estocásticas con difusión y saltos (EDESJs), con aplicación al modelo de Cramér-Lundberg extendido para el cálculo de reservas técnicas en el sector asegurador de vivienda de la Ciudad de México. Se establece un marco riguroso de cálculo estocástico que incluye la demostración de existencia y unicidad de soluciones fuertes bajo condiciones de Lipschitz local y crecimiento lineal global; la isometría de Itô para la parte de saltos; y las desigualdades de Burkholder-Davis-Gundy en espacios de Hilbert.

Se implementan y analizan dos esquemas numéricos: el método de Milstein compensado, que alcanza convergencia fuerte de orden $\gamma = 1/2$ para la componente difusiva, y el esquema Semi-implícito compensado, que trata el término de interés $r(t)U(t)$ de forma implícita, garantizando estabilidad incondicional. Bajo hipótesis de regularidad de los coeficientes (Lipschitz global, crecimiento lineal, momentos finitos de saltos), se demuestra que ambos esquemas convergen fuertemente con orden $\gamma = 1/2$, utilizando técnicas de descomposición del error local, estimaciones recursivas y la desigualdad de Grönwall discreta.

La calibración del modelo incorpora datos reales del mercado mexicano: primas ajustadas por inflación (INEGI), tasa de inversión combinada con activos locales (CETES) y globales (bonos USD), volatilidad estacional basada en el índice ILS, e intensidades de siniestros hidrometeorológicos (CONAGUA) y sísmicos (SSN). Mediante simulación Monte Carlo ($N_{\text{sim}} = 1000$) se comparan los esquemas en términos de mediana final, intervalos de confianza al 90 % y detección de saltos, validando la robustez del modelo.

Los resultados muestran que el esquema semi-implícito compensado presenta ventajas críticas para la gestión de riesgos en la CDMX:

- I. Prudencia regulatoria (+2.30 % en reserva mediana);
- II. Estabilidad incondicional ante shocks en tasas de interés;
- III. Eficiencia computacional (reducción del 96.7 % en pasos de tiempo para horizontes extendidos). Se concluye que, para sistemas dominados por saltos catastróficos y volatilidad macroeconómica, el esquema semi-implícito es preferible sobre Milstein.

Palabras clave: Ecuaciones diferenciales estocásticas con saltos, método de Milstein, esquema semi-implícito, convergencia fuerte, modelo de Cramér-Lundberg, simulación Monte Carlo, gestión de riesgos, seguros de vivienda, Ciudad de México.

1.1. Abstract

2 Abstract

This work addresses the numerical approximation problem of stochastic differential equations with diffusion and jumps (SDEJs), applied to an extended Cramér-Lundberg model for calculating technical reserves in the housing insurance sector in Mexico City. A rigorous stochastic calculus framework is established, including the demonstration of existence and uniqueness of strong solutions under local Lipschitz and global linear growth conditions; Itô isometry for the jump component; and Burkholder-Davis-Gundy inequalities in Hilbert spaces.

Two numerical schemes are implemented and analyzed: the compensated Milstein method, which achieves strong convergence of order $\alpha = 1/2$ for the diffusive component, and the compensated semi-implicit scheme, which treats the interest term $r(t)U(t)$ implicitly, guaranteeing unconditional stability. Under regularity hypotheses of the coefficients (global Lipschitz, linear growth, finite jump moments), it is demonstrated that both schemes converge strongly with order $\alpha = 1/2$, using local error decomposition techniques, recursive estimates, and the discrete Grönwall inequality.

The model calibration incorporates real data from the Mexican market: inflation-adjusted premiums (INEGI), combined investment rate with local (CETES) and global (USD bonds) assets, seasonal volatility based on the ILS index, and intensities of hydrometeorological (CONAGUA) and seismic (SSN) claims. Through Monte Carlo simulation ($N_{\text{sim}} = 1000$), the schemes are compared in terms of final median, 90 % confidence intervals, and jump detection, validating the robustness of the model.

The results show that the compensated semi-implicit scheme presents critical advantages for risk management in Mexico City:

- I. Regulatory prudence (+2.30 % in median reserve);
- II. Unconditional stability against interest rate shocks;
- III. Computational efficiency (96.7 % reduction in time steps for extended horizons). It is concluded that for systems dominated by catastrophic jumps and macroeconomic volatility, the semi-implicit scheme is preferable over Milstein.

Keywords: Stochastic differential equations with jumps, Milstein method, semi-implicit scheme, strong convergence, Cramér-Lundberg model, Monte Carlo simulation, risk management, housing insurance, Mexico City.

3 Introducción

La modelación matemática de fenómenos dinámicos sometidos a incertidumbre ha experimentado un desarrollo extraordinario en las últimas décadas, particularmente en el ámbito de las ecuaciones diferenciales estocásticas (EDEs). Cuando estos fenómenos presentan, además de evolución continua gobernada por procesos de difusión, discontinuidades abruptas inducidas por eventos extremos o choques externos, el marco teórico natural lo constituyen las ecuaciones diferenciales estocásticas con saltos (EDEs con saltos, o SDEJs por sus siglas en inglés: Jump-Diffusion Stochastic Differential Equations).

El modelo clásico de Cramér-Lundberg, pilar fundamental de la teoría de riesgo actuarial desde principios del siglo XX, describe la evolución del capital de una aseguradora mediante un proceso de Poisson compuesto que captura la llegada de siniestros y una deriva determinista que representa la acumulación de primas. Sin embargo, este modelo, en su formulación original, asume parámetros constantes (tasa de primas, intensidad de saltos) y omite componentes cruciales para la gestión moderna de reservas:

- La evolución estocástica de las inversiones de las reservas técnicas en instrumentos financieros;
- La dependencia temporal de parámetros debido a factores macroeconómicos (inflación, tasas de interés, volatilidad de mercados);
- La estacionalidad en la frecuencia de siniestros catastróficos;
- La no linealidad inherente a la capitalización de rendimientos.

En el contexto del mercado asegurador mexicano, y particularmente para el ramo de seguros de vivienda en la Ciudad de México (CDMX), estas limitaciones son especialmente críticas. La CDMX, con aproximadamente 2.38 millones de viviendas particulares habitadas (INEGI [15]) y una concentración del 18-22 % del mercado nacional de seguros de vivienda (AMIS [4]), enfrenta desafíos específicos:

- **Exposición a riesgos catastróficos:** La ubicación geográfica de la CDMX la hace vulnerable a eventos sísmicos significativos y fenómenos hidrometeorológicos intensos, los cuales generan siniestros de magnitud considerable y frecuencia estacional.
- **Dinámica inflacionaria:** La erosión del poder adquisitivo afecta tanto el valor de las sumas aseguradas como los costos de reparación, requiriendo ajustes continuos en las primas INEGI [16].

- **Volatilidad de inversiones:** Las reservas técnicas son invertidas en instrumentos financieros cuyos rendimientos presentan variabilidad temporal, impactando directamente la solvencia de la aseguradora.
- **Dependencia temporal de parámetros:** Los procesos estocásticos subyacentes no son estacionarios; sus parámetros (intensidad de saltos, severidad, tasas de interés) varían sistemáticamente con el tiempo.

Ante esta complejidad, la extensión del modelo de Cramér-Lundberg a una EDE con difusión y saltos, con parámetros tiempo-dependientes, se impone como necesidad teórica y práctica. Formalmente, el proceso de reservas $\{U(t)\}_{t \geq 0}$ satisface:

$$dU(t) = c(t) dt + U(t^-)r(t) dt + U(t^-)\sigma(t) dW(t) - dJ(t),$$

donde $c(t)$ es la tasa de prima ajustada por inflación, $r(t)$ la tasa de inversión, $\sigma(t)$ la volatilidad de inversiones, $W(t)$ un movimiento browniano estándar, y $J(t)$ un proceso de saltos compuesto que modela siniestros catastróficos mediante medidas de Poisson compensadas.

Sin embargo, la no estacionariedad de parámetros, la no linealidad del término de interés $r(t)U(t)$, y la estructura de saltos compuestos hacen que la solución analítica de esta EDE sea intratable, requiriendo métodos numéricos robustos para su aproximación.

Por todo lo anterior, el presente estudio se basa en establecer fundamentos teóricos (espacios de probabilidad, medidas de Poisson, integral de Itô, fórmula de Itô, desigualdades de martingalas), demostrar existencia y unicidad de soluciones fuertes para EDE con saltos y presentar el modelo de Cramér-Lundberg extendido el cual deriva los esquemas numéricos de Milstein y semi-implícito compensados.

4 Objetivos

4.1. Objetivo general:

Desarrollar e implementar esquemas numéricos de aproximación fuerte (Milstein compensado y semi-implícito compensado) para ecuaciones diferenciales estocásticas con saltos de tipo Cramér-Lundberg extendido, que modelen la evolución de reservas técnicas de una aseguradora de vivienda en la Ciudad de México, incorporando parámetros tiempo-dependientes (primas ajustadas por inflación, tasas de interés estocásticas, volatilidad variable) y procesos de salto compuestos que capturen siniestros catastróficos meteorológicos y sísmicos; establecer rigurosamente las condiciones de convergencia fuerte de orden $\gamma = 1/2$ bajo hipótesis de Lipschitz local y crecimiento lineal; y evaluar comparativamente el desempeño numérico de ambos esquemas en términos de estabilidad, precisión y eficiencia computacional para la gestión de riesgos de solvencia en el contexto del mercado asegurador mexicano.

4.2. Objetivos específicos:

1. **Fundamentación teórica:** Establecer el marco teórico-matemático riguroso de espacios de probabilidad filtrados, medidas aleatorias de Poisson compensadas, integral estocástica de Itô para procesos con saltos, y fórmula de Itô generalizada para semimartingalas, demostrando los teoremas de isometría, Fubini estocástico y densidad de procesos elementales simples en $L^2_{\text{pred}}(\tilde{N})$.
2. **Existencia y unicidad:** Demostrar teoremas de existencia y unicidad global y local de soluciones fuertes para EDE con difusión y saltos bajo condiciones de Lipschitz (global y local respectivamente) y crecimiento lineal, utilizando el principio de contracción de Banach en espacios de Hilbert ponderados $S^2_{\mathcal{F}}{}^{\text{loc}}(\mathbb{R})$ con norma exponencialmente ponderada, y estableciendo cotas uniformes de momentos de segundo orden mediante desigualdades de Burkholder-Davis-Gundy y Gronwall.
3. **Diseño de esquemas numéricos:** Derivar rigurosamente los esquemas numéricos de Milstein compensado (con corrección de segundo orden $\frac{1}{2}\sigma\sigma_x[(\Delta W)^2 - \Delta t]$) y semi-implícito compensado (con tratamiento implícito del término de interés $r(t)U(t)$ en el denominador $1 - r(t_{n+1})\Delta t$), justificando la compensación de saltos $\lambda E[Y|\mathcal{F}_t]$ para garantizar propiedad de martingala local y estabilidad numérica.

4. **Convergencia fuerte:** Probar teoremas de convergencia fuerte de orden $\gamma = 1/2$ para ambos esquemas bajo hipótesis de Lipschitz global, crecimiento lineal, momentos finitos de cuarto orden para saltos, y condición de estabilidad $1 - r(t)\Delta t \geq \delta > 0$, descomponiendo el error global en componentes de difusión, salto e implícitud, y estableciendo cotas recursivas mediante desigualdades de Gronwall discretas.
5. **Calibración de parámetros:** Estimar rigurosamente los parámetros del modelo extendido de Cramér-Lundberg para el mercado de seguros de vivienda en la CDMX, función de primas $c(t)$ ajustadas por inflación mensual del INPC, tasa de inversión $r(t)$ como combinación convexa de CETES y bonos USD, volatilidad $\sigma(t)$ ponderada entre componentes locales (CETES) y globales (ILS), intensidades de salto $\lambda_{\text{meteo}}(t)$ estacionales y λ_{sismo} constantes, distribuciones de severidad Y_{meteo} y Y_{sismo} como normales truncadas, utilizando máxima verosimilitud y datos históricos de CONAGUA, SSN y CNSF.
6. **Implementación computacional:** Implementar algoritmos eficientes en Python/NumPy para ambos esquemas numéricos con $N_{\text{sim}} = 1000$ trayectorias Monte Carlo, paso temporal $\Delta t = 1/365$ (diario), horizonte $T = 2$ años (2024-2025) más pronóstico a 30 días (enero 2026), incorporando técnicas de reducción de varianza (variables de control) y detección automática de saltos en trayectorias medianas mediante umbrales de 3σ en retornos logarítmicos.
7. **Análisis comparativo:** Evaluar cuantitativamente el desempeño de ambos métodos comparando el sesgo sistemático en medianas (+2.30 % favorable al semi-implícito), la amplitud de intervalos de confianza al 90 % (+12.54 % mayor dispersión en semi-implícito), la estabilidad incondicional del semi-implícito vs condicionalidad de Milstein ($\Delta t < 2/r_{\text{máx}}$), eficiencia computacional (posibilidad de usar $\Delta t = 1/12$ mensual en semi-implícito reduciendo costo 96.7 %), implicaciones para gestión de riesgos y solvencia regulatoria CNSF.

5 Resultados técnicos fundamentales

5.1. Espacios de Probabilidad y Filtraciones

En esta sección se presentan con detalle los resultados clave que sustentan la demostración del Teorema de Isometría de Itô para la parte de saltos. Se asume que $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$ es un espacio de probabilidad filtrado que satisface las condiciones usuales, Z es un espacio métrico separable completo, y ν es una medida σ -finita sobre $(Z, \mathcal{B}(Z))$. Sea $\widetilde{N}(ds, dz) = N(ds, dz) - \nu(dz)ds$ la medida aleatoria compensada asociada a una medida de Poisson.

Definición 5.1. (Espacio de probabilidad filtrado). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $\{\mathcal{F}_t\}_{t \geq 0}$ una filtración, es decir, una familia creciente de sub- σ -álgebras de $\mathcal{F}$:

$$\mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F} \quad \text{para todo } 0 \leq s \leq t.$$

Se dice que la filtración satisface las hipótesis usuales si cumple las siguientes dos condiciones:

- i) Completitud: La σ -álgebra inicial $\mathcal{F}_0$ contiene todos los conjuntos $\mathbb{P}$ -nulos. Es decir:

$$\text{Si } A \in \mathcal{F} \text{ y } \mathbb{P}(A) = 0, \quad \text{entonces } A \in \mathcal{F}_0.$$

Como $\mathcal{F}_0 \subseteq \mathcal{F}_t$ para todo t , esto implica que todos los conjuntos nulos están en cada $\mathcal{F}_t$. En otras palabras, cada $\mathcal{F}_t$ es completa respecto a $\mathbb{P}$.

- ii) Continuidad por la derecha: Para todo $t \geq 0$

$$\mathcal{F}_t = \bigcap_{s > t} \mathcal{F}_s.$$

Definición 5.2. (Filtración natural). Sea $W = \{W_t\}_{t \geq 0}$ un movimiento browniano. La *filtración natural* es $\mathcal{F}_t^W = \sigma(W_s : s \leq t)$. La filtración *usual* asociada es

$$\mathcal{F}_t = \bigcap_{s > t} \sigma(\mathcal{F}_s^W \cup \mathcal{N}),$$

donde $\mathcal{N}$ es la colección de todos los conjuntos $\mathbb{P}$ -nulos.

Definición 5.3. (Tiempo de paro). Una variable aleatoria $\tau : \Omega \rightarrow [0, \infty]$ es un *tiempo de paro* respecto a $\{\mathcal{F}_t\}$ si $\{\tau \leq t\} \in \mathcal{F}_t$ para todo $t \geq 0$.

Definición 5.4. (Tiempos de paro controlados). Un tiempo de paro $\{\tau < t\} \in \mathcal{F}_t$ para todo t . La continuidad por la derecha se deduce que

$$\{\tau < t\} = \bigcup_{q \in \mathbb{Q}, q < t} \{\tau \leq q\} \in \mathcal{F}_t,$$

5.2. Resultados de Teoría de la Medida y Análisis Funcional

Lema 5.1. (Fatou). Sea $\{f_n\}_{n \in \mathbb{N}}$ una sucesión de funciones medibles no negativas. Entonces:

$$\liminf_{n \rightarrow \infty} \int_X f_n d\mu \geq \int_X \liminf_{n \rightarrow \infty} f_n d\mu.$$

Demostración. Ver demostración completa Applebaum [5] Corolario 1.1.2. $\square$

Teorema 5.1. (Convergencia Monotona). Sea $\{f_n\}_{n \in \mathbb{N}}$ una sucesión de funciones medibles no negativas tales que $0 \leq f_1 \leq f_2 \leq \dots$ y $f_n \rightarrow f$ puntualmente. Entonces:

$$\lim_{n \rightarrow \infty} \int_X f_n d\mu = \int_X f d\mu.$$

Demostración. Ver demostración completa Applebaum [5] Teorema 1.1.1 $\square$

Teorema 5.2. (Convergencia Dominada). Sea $(X, \mathcal{A}, \mu)$ un espacio de medida y $\{f_n\}_{n \in \mathbb{N}}$ una sucesión de funciones μ -medibles $f_n : X \rightarrow \mathbb{R}$. Supongamos que:

- I. $f_n(x) \rightarrow f(x)$ μ -casi en todas partes,
- II. existe una función $g \in L^1(X, \mathcal{A}, \mu)$ tal que $|f_n(x)| \leq g(x)$ para μ -casi todo $x \in X$ y todo $n \in \mathbb{N}$.

Entonces $f \in L^1(\mu)$ y

$$\lim_{n \rightarrow \infty} \int_X f_n d\mu = \int_X f d\mu.$$

Demostración. Ver demostración completa Teorema 1.34 [27] La idea central consiste en aplicar el Lema de Fatou a la sucesión $2g - |f_n - f| \geq 0$. $\square$

Teorema 5.3. Sea $(X, \mathcal{A}, \mu)$ un espacio de medida σ -finito. Entonces, el conjunto de funciones simples integrables es denso en $L^2(X, \mathcal{A}, \mu)$. Es decir, para toda $f \in L^2(\mu)$ existe una sucesión de funciones simples $\{\phi_n\}$ tal que $\|\phi_n - f\|_{L^2(\mu)} \rightarrow 0$.

Demostración. Sea $f \in L^2(\mu)$. Como f es medible, existen funciones simples ψ_n tales que $\psi_n \rightarrow f$ puntualmente y $|\psi_n| \leq |f|$ para todo n (ver [11], Prop. 2.20). Entonces,

$$|\psi_n - f|^2 \leq 4|f|^2 \in L^1(\mu).$$

Por el Teorema 5.2,

$$\int_X |\psi_n - f|^2 d\mu \rightarrow 0.$$

Luego, $\|\psi_n - f\|_{L^2(\mu)} \rightarrow 0$. Además, al truncar ψ_n en conjuntos de medida finita (posible por ser μ σ -finita), podemos asumir que cada ψ_n es integrable. $\square$

En el contexto estocástico, aplicamos este resultado al espacio de medida

$$(\Omega \times [0, T] \times Z, \mathcal{P} \otimes \mathcal{B}(Z), \mathbb{P} \otimes ds \otimes \nu),$$

que es σ -finito si ν lo es. Esto garantiza que cualquier proceso predecible cuadrado integrable puede aproximarse en L^2 por procesos simples.

Teorema 5.4. *Sea H un espacio de Hilbert y $\{x_n\} \subset H$ una sucesión tal que $x_n \rightarrow x$ en norma. Entonces $\|x_n\| \rightarrow \|x\|$*

Demostración. Por la desigualdad triangular inversa,

$$|\|x_n\| - \|x\|| \leq \|x_n - x\| \rightarrow 0.$$

$\square$

Teorema 5.5. *(Principio de contracción de Banach). Sea $(H, \|\cdot\|)$ un espacio de Banach y $\Phi : H \rightarrow H$ una contracción, es decir, existe $\kappa < 1$ tal que $\|\Phi(x) - \Phi(y)\| \leq \kappa\|x - y\|$ para todo $x, y \in H$. Entonces Φ tiene un único punto fijo en H .*

Demostración. Ver Istrăţescu [17], Capítulo 3, Sección 3.1 $\square$

5.2.1. Fundamentos de Inferencia Estadística

En esta sección se introducen conceptos básicos de inferencia estadística necesarios para la calibración de los parámetros del modelo de severidad. En particular, se definen los M-estimadores y la regresión cuantílica, herramientas robustas que permiten estimar parámetros en presencia de valores atípicos o distribuciones con colas pesadas.

5.2.1.1. M-estimadores

Definición 5.5. (M-estimador). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea $X_1, X_2, \dots, X_n$ una muestra aleatoria independiente e idénticamente distribuida (i.i.d.) con función de distribución $\mathcal{F}_0$ perteneciente a una familia paramétrica $\{\mathcal{F} : \theta \in \Theta \subseteq \mathbb{R}\}$. Sea $\rho : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ una función de pérdida (o función de contraste) tal que: 1. ρ es medible con respecto a la σ -álgebra producto, 2. ρ es convexa en el parámetro θ (para garantizar existencia y unicidad del mínimo), 3. $\mathbb{E}[|\rho(\theta, X)|] < \infty$ para todo $\theta \in \Theta$.

Un M-estimador (estimador de máxima similitud o estimador de mínimo contraste) $\hat{\theta}_n$ para el parámetro θ se define como:

$$\hat{\theta}_n := \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \rho(\theta, X_i).$$

Alternativamente, cuando la función ρ es diferenciable, el M-estimador puede definirse como la solución de la ecuación de estimación:

$$\sum_{i=1}^n \psi(\hat{\theta}_n, X_i) = 0,$$

donde $\psi(\theta, x) = \nabla_{\theta} \rho(\theta, x)$ es la función de influencia o función score.

Observación: La elección de la función de pérdida ρ determina diferentes estimadores: - Si se elige $\rho(\theta, x) = -\log f(x; \theta)$, donde f es la función de densidad de la distribución, entonces el M-estimador coincide con el estimador de máxima verosimilitud (MLE). - Si se elige $\rho(\theta, x) = |x - \theta|$, el M-estimador corresponde a la mediana muestral. - Si se elige $\rho(\theta, x) = (x - \theta)^2$, el M-estimador corresponde a la media muestral. Para más detalles de la definición de M-estimador

5.2.1.2. Regresión Cuantílica

Definición 5.6. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea $\{(Y_i, \mathbf{X}_i)\}_{i=1}^n$ una muestra aleatoria i.i.d., donde $Y_i \in \mathbb{R}$ es la variable respuesta y $\mathbf{X}_i \in \mathbb{R}^p$ es un vector de covariables. Para un cuantil $\tau \in (0, 1)$, la función de pérdida cuantílica (también llamada función de pérdida asimétrica de Huber o función de pérdida “check”) se define como:

$$\rho_{\tau}(u) := u \cdot (\tau - \mathbf{1}_{\{u < 0\}}) = \begin{cases} \tau|u|, & \text{si } u \geq 0, \\ (1 - \tau)|u|, & \text{si } u < 0. \end{cases}$$

Equivalentemente

$$\rho_{\tau}(u) = |u| \cdot (\tau \cdot \mathbf{1}_{\{u \geq 0\}} + (1 - \tau) \cdot \mathbf{1}_{\{u < 0\}}).$$

El estimador de regresión cuantílica $\hat{\beta}_n(\tau)$ para el τ -ésimo cuantil condicional de Y_i dado $\mathbf{X}_i$ se define como:

$$\hat{\beta}_n(\tau) := \arg \min_{\beta \in \mathbb{R}^p} \sum_{i=1}^n \rho_\tau(Y_i - \mathbf{X}_i^\top \beta).$$

El cuantil condicional estimado de Y_i dado $\mathbf{X}_i = \mathbf{x}$ viene dado por:

$$\hat{Q}_{Y|\mathbf{X}}(\tau | \mathbf{x}) = \mathbf{x}^\top \hat{\beta}_n(\tau).$$

5.3. Procesos Estocásticos Fundamentales

Definición 5.7. Sea $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t \geq 0}, \mathbb{P})$ un espacio de probabilidad filtrado. Un proceso de Wiener es un proceso estocástico $W = \{W(t)\}_{t \geq 0}$ que satisface las siguientes propiedades:

1. Condición inicial:

$$W(0) = 0 \quad \text{casi seguramente.}$$

2. Trayectorias continuas:

Casi todas las trayectorias $t \mapsto W(t, \omega)$ son funciones continuas en $[0, \infty)$.

3. Incrementos independientes: Para cualesquier partición $0 \leq t_0 < t_1 < \dots < t_n$, los incrementos

$$W(t_1) - W(t_0), W(t_2) - W(t_1), \dots, W(t_n) - W(t_{n-1})$$

son independientes como variables aleatorias reales.

4. Incrementos estacionarios y gaussianos:

Para todo $0 \leq s < t$, el incremento $W(t) - W(s)$ tiene distribución normal con media cero y varianza $t - s$:

$$W(t) - W(s) \sim \mathcal{N}(0, t - s).$$

5. Adaptación:

El proceso W es adaptado a la filtración $\{\mathcal{F}_t\}_{t \geq 0}$, es decir, $W(t)$ es $\mathcal{F}_t$ -medible para todo $t \geq 0$.

6. El proceso tiene variación cuadrática $\langle W \rangle = t$, casi seguramente.

Definición 5.8. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea $X = \{X_t : t \geq 0\}$ un proceso estocástico con valores en $\mathbb{R}$, es decir, para cada $t \geq 0$, $X_t : \Omega \rightarrow \mathbb{R}$ es una variable aleatoria. Se dice que el proceso X es cádlág (o RCLL) si casi todas sus trayectorias son funciones cádlág; es decir, existe un conjunto $\Omega_0 \in \mathcal{F}$ con $\mathbb{P}(\Omega_0) = 1$ tal

que, para todo $\omega \in \Omega_0$, la función

$$t \mapsto X_t(\omega)$$

satisface las siguientes dos propiedades:

1. Continuidad por la derecha: Para todo $t \geq 0$,

$$\lim_{s \downarrow t} X_s(\omega) = X_t(\omega).$$

2. Existencia del límite por la izquierda: Para todo $t > 0$, el límite

$$\lim_{s \uparrow t} X_s(\omega)$$

existe en $\mathbb{R}$. Este límite se denota por $X_{t-}(\omega)$.

Definición 5.9. Se dice que una EDE tiene solución única por trayectorias si para cualquier par de soluciones $\{x_t^i\}_{t \geq 0}, i = 1, 2$, satisface la Ecuación 6.1 sobre el mismo espacio de probabilidad con el mismo movimiento browniano $\{W_t\}_{t \geq 0}$ y una medida de Poisson $\tilde{N}_t(dt, dz)$, $P(\sup_{t \geq 0} |x_t^1 - x_t^2| = 0) = 1$

Teorema 5.6. *Toda martingala local en un espacio filtrado que satisface las hipótesis usuales admite una versión cádlág.*

Demostración. Ver demostración en Tudor [29] Teorema 2.5.17 □

5.4. Desigualdades y Lemmas Clásicos

Teorema 5.7. *Sean $X, Y \in L^2(\Omega, \mathcal{F}, \mathbb{P})$. Entonces*

$$|\mathbb{E}[XY]|^2 \leq \mathbb{E}[X^2] \mathbb{E}[Y^2].$$

Además, la igualdad se da si y solo si existen $a, b \in \mathbb{R}$, no ambos nulos, tales que

$$\mathbb{P}(aX = bY) = 1.$$

Demostración. Observemos que si $\mathbb{E}[Y^2] = 0$, entonces $Y = 0$ casi seguramente (c.s.), y ambas partes de la desigualdad son cero. Lo mismo ocurre si $\mathbb{E}[X^2] = 0$. Por lo tanto, nos resta probar que

$$\mathbb{E}[X^2] > 0 \quad \text{y} \quad \mathbb{E}[Y^2] > 0$$

Para cualquier $\lambda \in \mathbb{R}$, consideremos la variable aleatoria $X - \lambda Y$. Como $(X - \lambda Y)^2 \geq 0$ c.s., se tiene

$$\mathbb{E}[(X - \lambda Y)^2] \geq 0$$

Expandiendo la expresión:

$$\mathbb{E}[(X - \lambda Y)^2] = \mathbb{E}[X^2] - 2\lambda\mathbb{E}[XY] + \lambda^2\mathbb{E}[Y^2].$$

Definimos la función cuadrática

$$f(\lambda) := \mathbb{E}[Y^2] \lambda^2 - 2\mathbb{E}[XY] \lambda + \mathbb{E}[X^2].$$

Entonces $f(\lambda) \geq 0$ para todo $\lambda \in \mathbb{R}$. Dado que $\mathbb{E}[Y^2] > 0$, el coeficiente principal es positivo. Un polinomio cuadrático $a\lambda^2 + b\lambda + c$ con $a > 0$ es no negativo en todo $\mathbb{R}$ si y solo si su discriminante es no positivo:

$$\Delta = b^2 - 4ac \leq 0.$$

Aplicando esto con $a = \mathbb{E}[Y^2]$, $b = -2\mathbb{E}[XY]$, $c = \mathbb{E}[X^2]$, obtenemos:

$$(-2\mathbb{E}[XY])^2 - 4\mathbb{E}[Y^2]\mathbb{E}[X^2] \leq 0 \implies 4\mathbb{E}[XY]^2 \leq 4\mathbb{E}[X^2]\mathbb{E}[Y^2]$$

Dividiendo por 4 y tomando valor absoluto (pues $\mathbb{E}[XY]$ puede ser negativo), concluimos:

$$|\mathbb{E}[XY]|^2 \leq \mathbb{E}[X^2]\mathbb{E}[Y^2].$$

Ahora analizamos cuándo se cumple

$$|\mathbb{E}[XY]|^2 = \mathbb{E}[X^2]\mathbb{E}[Y^2].$$

Esto equivale a que el discriminante sea exactamente cero, es decir, $\Delta = 0$. En tal caso, el polinomio $f(\lambda)$ tiene una raíz doble; es decir, existe tal que $\lambda_0 \in \mathbb{R}$

$$f(\lambda_0) = \mathbb{E}[(X - \lambda_0 Y)^2] = 0.$$

Pero $\mathbb{E}[Z^2] = 0$ implica $Z = 0$ c.s. Por lo tanto,

$$X - \lambda_0 Y = 0 \quad \text{c.s.} \implies \mathbb{P}(X = \lambda_0 Y) = 1.$$

Esto muestra que existen constantes $a = 1$, $b = \lambda_0$ (no ambos nulos) tales que $\mathbb{P}(aX = bY) = 1$. Si en cambio $Y = 0$ c.s., tomamos $a = 0$, $b = 1$, y claramente $\mathbb{P}(0 \cdot X = 1 \cdot Y) = 1$.

Recíprocamente, supongamos que existen $a, b \in \mathbb{R}$, no ambos nulos, tales que $\mathbb{P}(aX = bY) = 1$. Si $a \neq 0$, entonces $X = \frac{b}{a}Y$ c.s., y entonces

$$\mathbb{E}[XY] = \frac{b}{a}\mathbb{E}[Y^2], \quad \mathbb{E}[X^2] = \left(\frac{b}{a}\right)^2 \mathbb{E}[Y^2],$$

de donde

$$\mathbb{E}[X^2]\mathbb{E}[Y^2] = \left(\frac{b}{a}\right)^2 \mathbb{E}[Y^2]^2 = (\mathbb{E}[XY])^2$$

Si $b \neq 0$, entonces $Y = \frac{a}{b}X$ c.s., y un cálculo análogo lleva a la misma conclusión. En ambos casos, se tiene igualdad en la desigualdad de Cauchy-Schwarz. $\square$

Teorema 5.8. Para cualesquier $x_1, x_2, \dots, x_n \in \mathbb{R}$, se cumple:

$$\left(\sum_{i=1}^n x_i \right)^2 \leq n \sum_{i=1}^n x_i^2.$$

Demostración. Aplicando la desigualdad de Cauchy-Schwarz a los vectores $\mathbf{x} = (x_1, \dots, x_n)$ y $\mathbf{1} = (1, \dots, 1)$ en $\mathbb{R}^n$ se tiene:

$$\left(\sum_{i=1}^n x_i \cdot 1 \right)^2 \leq \left(\sum_{i=1}^n x_i^2 \right) \left(\sum_{i=1}^n 1^2 \right) = \left(\sum_{i=1}^n x_i^2 \right) \cdot n.$$

Alternativamente, usando la *desigualdad de Jensen* con $\phi(x) = x^2$ (convexa) se da:

$$\left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2 \leq \frac{1}{n} \sum_{i=1}^n x_i^2 \implies \left(\sum_{i=1}^n x_i \right)^2 \leq n \sum_{i=1}^n x_i^2.$$

□

Observación Esta desigualdad es un caso particular de la desigualdad de Cauchy-Schwarz general en espacios de Hilbert. Para $X, Y \in L^2(\Omega)$:

$$|\mathbb{E}[XY]|^2 \leq \mathbb{E}[X^2]\mathbb{E}[Y^2].$$

Teorema 5.9. Para cualesquier $a, b \in \mathbb{R}$, se cumple:

$$2ab \leq a^2 + b^2.$$

La igualdad se alcanza si y solo si $a = b$.

Demostración. Por la desigualdad aritmético-geométrica para números no negativos:

$$\sqrt{a^2 b^2} \leq \frac{a^2 + b^2}{2} \implies |ab| \leq \frac{a^2 + b^2}{2} \implies 2ab \leq a^2 + b^2.$$

□

Lema 5.2. (Borel–Cantelli). Si $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, entonces $\mathbb{P}(A_n \text{ i.o.}) = 0$.

Teorema 5.10. Si M es una martingala en L^2 , entonces

$$\mathbb{E} \left[\sup_{0 \leq s \leq t} M_s^2 \right] \leq 4\mathbb{E}[M_t^2].$$

Teorema 5.11. Sea $u, \alpha : [0, T] \rightarrow \mathbb{R}_+$ funciones continuas, $\beta \in L^1([0, T])$, con $\beta \geq 0$, tales que

$$u(t) \leq \alpha(t) + \int_0^t \beta(s)u(s)ds, \quad \forall t \in [0, T].$$

Entonces,

$$u(t) \leq \alpha(t) \exp \left(\int_0^t \beta(s)ds \right).$$

En particular, si $\alpha \equiv 0$, entonces $u \equiv 0$.

Demostración. Definimos la función auxiliar

$$v(t) := \int_0^t \beta(s)u(s)ds, \quad t \in [0, T].$$

Dado que $\beta \in L^1([0, T])$ y $u \in C([0, T])$, el producto βu pertenece a $L^1([0, T])$, y por lo tanto $v \in C([0, T])$. Además, v es absolutamente continua y satisface $v(0) = 0$ y

$$v'(t) = \beta(t)u(t) \quad \text{para casi todo } t \in [0, T].$$

Por hipótesis,

$$u(t) \leq \alpha(t) + v(t), \quad \forall t \in [0, T],$$

y, sustituyendo en la derivada de v , obtenemos

$$v'(t) \leq \beta(t)(\alpha(t) + v(t)) \quad \text{casi en todas partes en } [0, T].$$

Consideremos ahora la función

$$w(t) := v(t) \exp \left(- \int_0^t \beta(s)ds \right), \quad t \in [0, T].$$

La función w es absolutamente continua (pues v y la exponencial lo son), y diferenciable casi en todas partes. Derivando se obtiene

$$w'(t) = [v'(t) - \beta(t)v(t)] \exp \left(- \int_0^t \beta(s)ds \right) \leq \beta(t)\alpha(t) \exp \left(- \int_0^t \beta(s)ds \right) \quad \text{c.t.p.}$$

Integrando desde 0 hasta t y usando que $w(0) = 0$, resulta

$$w(t) \leq \int_0^t \beta(s)\alpha(s) \exp \left(- \int_0^s \beta(r)dr \right) ds.$$

Multiplicando ambos lados por $\exp(\int_0^t \beta(s)ds)$ obtenemos

$$v(t) \leq \exp \left(\int_0^t \beta(s)ds \right) \int_0^t \beta(s)\alpha(s) \exp \left(- \int_0^s \beta(r)dr \right) ds.$$

Dado que α es no decreciente, para todo $s \in [0, t]$ se tiene $\alpha(s) \leq \alpha(t)$. Por lo tanto,

$$\begin{aligned} \int_0^t \beta(s) \alpha(s) \exp\left(-\int_0^s \beta(r) dr\right) ds &\leq \alpha(t) \int_0^t \beta(s) \exp\left(-\int_0^s \beta(r) dr\right) ds \\ &= \alpha(t) \left(1 - \exp\left(-\int_0^t \beta(s) ds\right)\right). \end{aligned}$$

Sustituyendo en la expresión anterior para $v(t)$, se sigue que

$$v(t) \leq \alpha(t) \left(\exp\left(\int_0^t \beta(s) ds\right) - 1 \right).$$

Finalmente, combinando con la desigualdad $u(t) \leq \alpha(t) + v(t)$, obtenemos

$$u(t) \leq \alpha(t) + \alpha(t) \left(\exp\left(\int_0^t \beta(s) ds\right) - 1 \right) = \alpha(t) \exp\left(\int_0^t \beta(s) ds\right),$$

, lo cual concluye la demostración. El caso $\alpha \equiv 0$ se deduce inmediatamente: la desigualdad implica $u(t) \leq 0$. Si además $u \geq 0$, entonces $u \equiv 0$ en $[0, T]$. $\square$

5.5. Medidas Aleatorias de Poisson.

Definición 5.10. Sea $(Z, \mathcal{B}(Z))$ un espacio medible polaco o de Lusin. El punto absorbente es un elemento $\partial \notin Z$ que se añade al espacio de estados para formar:

$$Z_\partial := Z \cup \{\partial\}.$$

La σ -álgebra en Z_∂ se define como:

$$\mathcal{B}(Z_\partial) := \sigma(\mathcal{B}(Z) \cup \{\{\partial\}\}).$$

Un proceso estocástico $\{X_t\}_{t \geq 0}$ con valores en Z_∂ se dice que:

1. Es absorbido en ∂ si $X_t = \partial$ para todo $t \geq \tau$, donde $\tau = \inf\{s > 0 : X_s = \partial\}$ es el tiempo de absorción,
2. Permanece en ∂ una vez que llega: $X_t = \partial \implies X_s = \partial$ para todo $s \geq t$.

Observación: El punto absorbente se utiliza para:

- Manejar procesos que pueden “explotar” en tiempo finito.
- Definir procesos de Markov con muerte.
- Extender funciones medibles $f : Z \rightarrow \mathbb{R}$ a Z_∂ mediante $f(\partial) = 0$.

$$f(\partial) = 0, \quad \int_{\{\partial\}} g(z) \nu(dz) = 0, \quad \text{y} \quad \partial + z = \partial \quad \forall z \in Z_\partial.$$

Definición 5.11. (Proceso puntual). Sea $(Z, \mathcal{B}(Z))$ un espacio de Lusin (en particular, Hausdorff y con σ -álgebra de Borel estándar). Un proceso puntual es una aplicación medible $p : \Omega \times (0, \infty) \rightarrow Z \cup \{\partial\}$ tal que, para casi toda $\omega \in \Omega$, el conjunto $\{t \in (0, T] : p(t, \omega) \in Z\}$ es finito para todo $T > 0$. Se asocia a p su medida de conteo N_p , definida en $(0, \infty) \times Z$. Donde ∂ es un punto absorbente (Definición 5.10) fuera de Z .

Definición 5.12. (Saltos aislados). Sea $p : \Omega \times (0, \infty) \rightarrow Z \cup \{\partial\}$ un proceso puntual (Definición 5.11). Decimos que p tiene saltos aislados si para casi toda $\omega \in \Omega$ y todo $T > 0$, el conjunto de tiempos de salto:

$$\mathcal{T}(\omega) \cap (0, T] := \{t \in (0, T] : p(t, \omega) \in Z\}$$

es finito o, más generalmente, discreto sin puntos de acumulación en $(0, T]$. Esto significa que:

1. Para todo $t \in \mathcal{T}(\omega)$, existe $\varepsilon > 0$ tal que:

$$(t - \varepsilon, t + \varepsilon) \cap \mathcal{T}(\omega) = \{t\}.$$

2. El ínfimo entre tiempos de salto consecutivos es positivo:

$$\inf\{t_{i+1} - t_i : t_i, t_{i+1} \in \mathcal{T}(\omega) \cap (0, T]\} > 0 \quad \text{c.s.}$$

3. La suma sobre saltos está bien definida:

$$\sum_{0 < s \leq t} f(s, p(s)) = \sum_{t_i \in \mathcal{T}(\omega) \cap (0, t]} f(t_i, p(t_i)) < \infty \quad \text{c.s.}$$

Definición 5.13. (Conjunto de no salto $p^{-1}(\partial)$). Sea $p : \Omega \times (0, \infty) \rightarrow Z \cup \partial$ un proceso puntual de clase (QL), donde Z es un espacio de Lusin y $\partial \notin Z$ es el punto absorbente (Definición 5.10) que indica ausencia de salto, entonces

$$p^{-1}(\partial) = \{(\omega, t) \in \Omega \times (0, \infty) : p(t, \omega) = \partial\}$$

representa el conjunto de todos los pares (ω, t) en los que la trayectoria del sistema no experimenta un salto en el instante t .

Definición 5.14. (Medida de conteo aleatoria N_p). La medida de conteo aleatoria asociada a p , denotada N_p , es una medida aleatoria sobre el espacio producto $(0, \infty) \times Z$, definida por

$$N_p((0, t] \times U) := \sum_{0 < s \leq t} \mathbf{1}_U(p(s)), \quad \text{para todo } U \in \mathcal{B}(Z), t > 0.$$

En la anterior expresión la suma $\sum_{0 < s \leq t}$ recorre todos los instantes s en el intervalo $(0, t]$.

Aunque hay infinitos s en principio, sólo en los tiempos donde ocurre un salto (es decir, cuando $p(s) \in Z$ el término $\mathbf{1}_U(p(s))$) puede ser distinto de cero. Gracias a la propiedad de que los saltos son aislados (Definición 5.12), la suma es finita c.s. en cada intervalo $(0, t]$.

El indicador $\mathbf{1}_U(p(s))$, evalúa si el tamaño (o tipo) del salto en el instante s , que es $p(s) \in Z$, cae dentro del conjunto $U \subset Z$. Si $p(s) \in U$, el salto cuenta para $N_p((0, t] \times U)$; si no, no se cuenta. La medida $N_p((0, t] \times U)$ es simplemente el número de saltos del proceso p que ocurren hasta el tiempo t y cuyo valor (localización en Z) está en el conjunto U .

Un caso particular y muy importante de proceso puntual es el proceso puntual de Poisson estacionario.

Definición 5.15. (Proceso puntual de Poisson estacionario). Un proceso puntual de Poisson estacionario $k : \Omega \times (0, \infty) \rightarrow Z \cup \{\partial\}$ es un proceso puntual $\mathcal{F}_t$ -adaptado, σ -finito y de clase (QL) (cuasi-continuo por la izquierda).

El proceso de Poisson estacionario k es un caso específico de proceso puntual que satisface propiedades adicionales (independencia, estacionariedad, distribución de Poisson). Por lo tanto, en este contexto, el proceso puntual p del que hablamos en general se especializa al proceso k .

Definición 5.16. (Espacio topológico Hausdorff). Sea (Z, τ) un espacio topológico, es decir, Z es un conjunto no vacío y $\tau \subseteq \mathcal{P}(Z)$ es una colección de subconjuntos (llamados abiertos) que satisface

- $\emptyset, Z \in \tau$,
- La unión arbitraria de elementos de τ pertenece a τ ,
- La intersección finita de elementos de τ pertenece a τ .

Se dice que (Z, τ) es un espacio Hausdorff (o T_2) si satisface la siguiente propiedad de separación: Para todo par de puntos distintos $x, y \in Z$, con $x \neq y$, existen abiertos $U, V \in \tau$ tales que:

$$x \in U, \quad y \in V, \quad \text{y} \quad U \cap V = \emptyset.$$

Ejemplo (*Espacio topológico Hausdorff*)

El espacio $Z = \mathbb{R}$ con topología euclidiana. Es métrico, y todo espacio métrico es Hausdorff.

Definición 5.17. Un espacio de Lusin es un espacio topológico Hausdorff Z que es imagen continua e inyectiva de un espacio polaco.

- Su σ -álgebra de Borel es estándar (isomorfa a la de un espacio polaco).
- Permite la aplicación de teoremas de selección medible, teoremas de convergencia, y garantiza regularidad de medidas.

Definición 5.18. $N(dt, dz)$: medida aleatoria de Poisson en $\mathbb{R}_+ \times Z$, donde Z es un espacio de Lusin (Definición 5.17) (e.g., $\mathbb{R}^d \setminus \{0\}$), con medida de intensidad $\nu(dz)dt$, y ν es una medida de Lévy, i.e.,

$$\int_Z (1 \wedge |z|^2) \nu(dz) < \infty.$$

$\tilde{N}(dt, dz) = N(dt, dz) - \nu(dz)dt$: medida de Poisson compensada. Se asume que W y N son independientes entre sí y de $\mathcal{F}_0$

Definición 5.19. (Conjunto de tiempos de salto $D_p(\omega)$). Para cada realización $\omega \in \Omega$, se define el conjunto de tiempos de salto como:

$$D_p(\omega) := \{t > 0 : p(t, \omega) \in Z\}.$$

Este conjunto recoge todos los instantes $t > 0$ en los cuales el proceso puntual p registra un salto con marca en el espacio de estados Z .

Teorema 5.12. Sean $A, B \in \mathcal{B}([0, T]) \otimes \mathcal{B}(Z)$ con $A \cap B = \emptyset$. Entonces

$$\mathbb{E}[\tilde{N}(A) \tilde{N}(B)] = 0.$$

Demostración. Por definición de la medida compensada,

$$\tilde{N}(A) = N(A) - \mu(A), \quad \tilde{N}(B) = N(B) - \mu(B),$$

donde $\mu = ds \otimes \nu$. Como $A \cap B = \emptyset$, los incrementos $N(A)$ y $N(B)$ son independientes (propiedad de la medida de Poisson). Luego,

$$\mathbb{E}[N(A)N(B)] = \mathbb{E}[N(A)] \mathbb{E}[N(B)] = \mu(A)\mu(B).$$

Por lo tanto,

$$\mathbb{E}[\tilde{N}(A)\tilde{N}(B)] = \mathbb{E}[N(A)N(B)] - \mu(A)\mu(B) - \mu(B)\mathbb{E}[N(A)] + \mu(A)\mu(B) = 0.$$

□

Teorema 5.13. Sea $f : \Omega \times [0, T] \times Z \rightarrow \mathbb{R}$ una función $\mathbb{P} \otimes ds \otimes \nu$ -medible. Si $f \geq 0$, o $\mathbb{E} \left[\int_0^T \int_Z |f(\omega, s, z)| \nu(dz) ds \right] < \infty$, entonces

$$\mathbb{E} \left[\int_0^T \int_Z f(\omega, s, z) \nu(dz) ds \right] = \int_0^T \int_Z \mathbb{E}[f(\cdot, s, z)] \nu(dz) ds.$$

Demostración. Es una consecuencia directa del Teorema de Fubini para espacios de medida producto. Como $\mathbb{P}$, ds y ν son σ -finitas, la medida producto $\mathbb{P} \otimes ds \otimes \nu$ es σ -finita, y el resultado se aplica. $\square$

En la Isometría de Itô, el Teorema 5.13 permite escribir

$$\mathbb{E} \left[\int_0^t \int_Z R(s, z)^2 \nu(dz) ds \right] = \int_0^t \int_Z \mathbb{E}[R(s, z)^2] \nu(dz) ds,$$

lo cual facilita el análisis y la comparación con la varianza de la integral estocástica. También justifica que la norma en $L^2_{\text{pred}}(\tilde{N})$ está bien definida.

5.6. Espacios Funcionales para Procesos Predecibles.

5.6.1. Definición del espacio $L^2_{\text{pred}}(\tilde{N})$ y su norma.

Teorema 5.14. El conjunto $\mathcal{E}$ de procesos elementales simples predecibles es denso en el espacio de Hilbert

$$L^2_{\text{pred}}(\tilde{N}) := \left\{ R : \mathbb{E} \left[\int_0^T \int_Z R(s, z)^2 \nu(dz) ds \right] < \infty \right\}$$

dotado de la norma

$$\|R\| := \left(\mathbb{E} \left[\int_0^T \int_Z R(s, z)^2 \nu(dz) ds \right] \right)^{1/2}.$$

Demostración. Sea $R \in L^2_{\text{pred}}(\tilde{N})$. Por el resultado anterior, existe una sucesión de funciones simples ϕ_n (no necesariamente predecibles) tal que $\|\phi_n - R\| \rightarrow 0$.

Cada ϕ_n es $\mathcal{F} \otimes \mathcal{B}([0, T]) \otimes \mathcal{B}(Z)$ -medible. Dado que la σ -álgebra predecible $\mathcal{P}$ es generada por procesos adaptados y càglàd, y la filtración satisface las condiciones usuales, el espacio $L^2(\mathcal{P} \otimes \mathcal{B}(Z))$ es un subespacio cerrado de $L^2(\mathcal{F} \otimes \mathcal{B}([0, T]) \otimes \mathcal{B}(Z))$.

Existe, por tanto, una proyección ortogonal de ϕ_n sobre este subespacio, sin embargo, basta observar que cualquier función simple puede aproximarse por funciones simples

$\mathcal{P} \otimes \mathcal{B}(Z)$ -medibles [5] Más explícitamente, uno puede refinar la partición de $[0, T]$ y usar funciones constantes en intervalos $(t_{i-1}, t_i]$ con coeficientes $\mathcal{F}_{t_{i-1}}$ -medibles. Esto define una sucesión $\{R_n\} \subset \mathcal{E}$ tal que $\|R_n - R\| \rightarrow 0$. $\square$

5.7. La Integral de Itô para Movimiento Browniano.

Definición 5.20. Sea $0 = t_0 < t_1 < \dots < t_n = T$ una partición finita de $[0, T]$. Un proceso simple es un proceso de la forma

$$X_t(\omega) = \sum_{k=0}^{n-1} X^{(k)}(\omega) \mathbf{1}_{[t_k, t_{k+1})}(t),$$

donde cada $X^{(k)}$ es una variable aleatoria $\mathcal{F}_{t_k}$ -medible y cuadrado integrable.

Denotaremos por $\mathcal{H}_{\text{simple}}$ al espacio de todos los procesos simples

Definición 5.21. Sea X un proceso simple. La integral estocástica de Itô de X respecto a $\{B_t\}$ se define como

$$\int_0^T X_s dB_s := \sum_{k=0}^{n-1} X^{(k)}(B_{t_{k+1}} - B_{t_k}).$$

Teorema 5.15. (*Isometría de Itô para procesos simples*). Para todo $X \in \mathcal{H}_{\text{simple}}$ se cumple

$$\mathbb{E} \left[\left(\int_0^T X_s dB_s \right)^2 \right] = \mathbb{E} \left[\int_0^T X_s^2 ds \right].$$

Espacios H^2 y $L^2(\mathbb{P} \otimes \lambda)$.

5.7.1. Extensión a $\mathcal{H}^2$ por densidad.

Dado que $\mathcal{H}_{\text{simple}}$ es denso en $\mathcal{H}^2$, para cualquier $X \in \mathcal{H}^2$ existe una sucesión $\{X^{(n)}\} \subset \mathcal{H}_{\text{simple}}$ tal que

$$\|X^{(n)} - X\|_{L^2(\mathbb{P} \times dt)} \xrightarrow{n \rightarrow \infty} 0.$$

La Isometría de Itô implica que $\{I(X^{(n)})\}$ es una sucesión de Cauchy en $L^2(\mathbb{P})$, y por la completitud de este espacio, converge en media cuadrática.

Definición 5.22. Sea $X \in \mathcal{H}^2$ y $\{X^{(n)}\} \subset \mathcal{H}_{\text{simple}}$ tal que $X^{(n)} \rightarrow X$ en $L^2(\mathbb{P} \times dt)$. Se define

$$\int_0^T X_s dB_s := \lim_{n \rightarrow \infty} \int_0^T X_s^{(n)} dB_s,$$

donde el límite se entiende en $L^2(\mathbb{P})$. Esta definición es independiente de la sucesión aproximante.

Teorema 5.16. Para todo $X \in \mathcal{H}^2$ se cumple

$$\mathbb{E} \left[\left(\int_0^T X_s dB_s \right)^2 \right] = \mathbb{E} \left[\int_0^T X_s^2 ds \right].$$

Además,

$$\mathbb{E} \left[\int_0^T X_s dB_s \right] = 0.$$

5.7.2. Integral como proceso y propiedades

Para cada $t \in [0, T]$, definimos el proceso integral

$$I_t(X) := \int_0^t X_s dB_s := \int_0^T X_s \mathbf{1}_{[0,t]}(s) dB_s.$$

Este proceso admite una versión continua y constituye una martingala respecto a $\{\mathcal{F}_t\}$. La integral de Itô satisface las siguientes propiedades

- a. Linealidad: Para $X, Y \in \mathcal{H}^2$ y $\alpha, \beta \in \mathbb{R}$,

$$\int_0^T (\alpha X_s + \beta Y_s) dB_s = \alpha \int_0^T X_s dB_s + \beta \int_0^T Y_s dB_s.$$

- b. Martingala: El proceso $\{I_t(X)\}_{0 \leq t \leq T}$ es una martingala en $L^2(\mathbb{P})$.

- c. Versión continua: Existe una versión de $\{I_t(X)\}$ con trayectorias continuas.

5.7.3. Extensión por localización

Denotamos por $\mathcal{L}_{\text{loc}}^2$ al espacio de procesos medibles y adaptados tales que

$$\mathbb{P} \left(\int_0^T X_s^2 ds < \infty \right) = 1.$$

Para $X \in \mathcal{L}_{\text{loc}}^2$, existen tiempos de paro $\{\tau_n\}$ con $\tau_n \uparrow T$ c.s. tales que $X \mathbf{1}_{[0, \tau_n]} \in \mathcal{H}^2$. Se define entonces

$$\int_0^t X_s dB_s := \lim_{n \rightarrow \infty} \int_0^t X_s \mathbf{1}_{\{s \leq \tau_n\}} dB_s,$$

donde el límite es en probabilidad. En este caso, la integral es una martingala local, pero la Isometría de Itô ya no se satisface en general.

5.8. La Integral de Itô para la Parte de Saltos.

Teorema 5.17. Sea $R = R(t, z, \omega)$ un proceso predecible $\mathcal{P} \otimes \mathcal{B}(Z)$ -medible tal que

$$\mathbb{E} \left[\int_0^T \int_Z R(s, z)^2 \nu(dz) ds \right] < \infty.$$

Entonces

$$\mathbb{E} \left[\left(\int_0^t \int_Z R(s, z) \widetilde{N}(ds, dz) \right)^2 \right] = \mathbb{E} \left[\int_0^t \int_Z R(s, z)^2 \nu(dz) ds \right].$$

Demostración. Consideramos el caso en que R es un proceso elemental simple de la forma

$$R(s, z, \omega) = \sum_{i=1}^n \sum_{j=1}^m a_{ij} \mathbf{1}_{(t_{i-1}, t_i]}(s) \mathbf{1}_{A_j}(z),$$

con $a_{ij} \in \mathbb{R}$, $\mathcal{F}_{t_{i-1}}$ -medible, y $A_j \subset Z$ medibles disjuntos con $\nu(A_j) < \infty$. En este caso, la integral estocástica es

$$I_t = \sum_{i=1}^n \sum_{j=1}^m a_{ij} \left[N((t_{i-1} \wedge t, t_i \wedge t] \times A_j) - \nu(A_j)(t_i \wedge t - t_{i-1} \wedge t) \right].$$

Dado que los incrementos de $\widetilde{N}$ sobre rectángulos disjuntos son no correlacionados y $\text{Var}(N((a, b] \times A)) = \nu(A)(b - a)$, se tiene

$$\mathbb{E}[I_t^2] = \sum_{i=1}^n \sum_{j=1}^m a_{ij}^2 \nu(A_j)(t_i \wedge t - t_{i-1} \wedge t) = \mathbb{E} \left[\int_0^t \int_Z R(s, z)^2 \nu(dz) ds \right].$$

Ahora para el caso general, sea R un proceso predecible en $L_{\text{pred}}^2(\widetilde{N})$. Existe una sucesión de procesos elementales simples $\{R_n\}$ tal que

$$\lim_{n \rightarrow \infty} \mathbb{E} \left[\int_0^T \int_Z |R_n(s, z) - R(s, z)|^2 \nu(dz) ds \right] = 0.$$

Definiendo $I_t^n = \int_0^t \int_Z R_n(s, z) \tilde{N}(ds, dz)$, $I_t = \int_0^t \int_Z R(s, z) \tilde{N}(ds, dz)$ se tiene $I_t^n \rightarrow I_t$ en $L^2(\Omega)$ uniformemente en $t \in [0, T]$. Por continuidad de la norma L^2 y el caso anterior para un proceso elemental simple,

$$\mathbb{E}[(I_t^n)^2] = \mathbb{E} \left[\int_0^t \int_Z R_n(s, z)^2 \nu(dz) ds \right] \rightarrow \mathbb{E} \left[\int_0^t \int_Z R(s, z)^2 \nu(dz) ds \right],$$

y también $\mathbb{E}[(I_t^n)^2] \rightarrow \mathbb{E}[I_t^2]$. Por unicidad del límite, se concluye la igualdad. $\square$

5.9. Fórmula de Itô

Teorema 5.18. (*Fórmula de Itô unidimensional*). Sea $f \in C^2(\mathbb{R})$ y $\{B_t\}_{t \geq 0}$ un movimiento Browniano. Entonces, para todo $t \geq 0$,

$$f(B_t) = f(B_0) + \int_0^t f'(B_s) dB_s + \frac{1}{2} \int_0^t f''(B_s) ds.$$

En notación diferencial:

$$df(B_t) = f'(B_t) dB_t + \frac{1}{2} f''(B_t) dt.$$

Demostración. Ver Castañeda, Arunachalam y Dharmaraja [8] Teorema 11.9 $\square$

Teorema 5.19. Sea $\{X_t\}_{0 \leq t \leq T}$ un proceso de Itô que satisface

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dB_t,$$

con b, σ medibles y tales que las integrales están bien definidas. Sea $f \in C^{1,2}([0, T] \times \mathbb{R})$. Entonces el proceso $Y_t = f(t, X_t)$ satisface

$$dY_t = \left(\frac{\partial f}{\partial t} + b \frac{\partial f}{\partial x} + \frac{1}{2} \sigma^2 \frac{\partial^2 f}{\partial x^2} \right) (t, X_t) dt + \sigma(t, X_t) \frac{\partial f}{\partial x} (t, X_t) dB_t.$$

Esta fórmula se deriva formalmente usando la tabla de multiplicación de Itô:

$$(dt)^2 = 0, \quad dt dB_t = 0, \quad (dB_t)^2 = dt.$$

Teorema 5.20. Sea $\sigma = \{\sigma_t\}$ un proceso progresivamente medible con $\mathbb{E}[\int_0^T \sigma_s^2 ds] < \infty$. Entonces,

$$\mathbb{E} \left[\left(\int_0^t \sigma_s dW_s \right)^2 \right] = \mathbb{E} \left[\int_0^t \sigma_s^2 ds \right], \quad \forall t \in [0, T].$$

Demostración. Ver Karatzas y Shreve [18] Teorema 3.2.1. $\square$

5.10. Variación Cuadrática y Desigualdades de Martingalas

Definición 5.23. Sean $M = \{M_t\}_{t \geq 0}$ una martingala local continua (como se asume en la desigualdad Burkholder-Davis-Gundy). La variación cuadrática se denota $[M]_t$ y se define como el límite en probabilidad de sumas de cuadrados de incrementos sobre particiones que se refinan

$$[M]_t = \lim_{|\Pi| \rightarrow 0} \sum_i (M_{t_{i+1}} - M_{t_i})^2,$$

donde $\Pi = \{0 = t_0 < t_1 < \dots < t_n = t\}$.

Cuando M es una martingala local continua, se tiene que $[M]$ es un proceso continuo, creciente y adaptado, pero no necesariamente previsible. La variación cuadrática previsible, denotada $\langle M \rangle$, es el único proceso creciente, continuo y previsible tal que

$$M_t^2 - \langle M \rangle_t$$

es una martingala local.

Teorema 5.21. Sea $M = \{M_t\}_{t \geq 0}$ una martingala continua en un espacio de Hilbert separable H , tal que $M \in \mathcal{M}_c^2(H)$, es decir, $M_0 = 0$ casi seguramente y $\mathbb{E}[\|M_T\|^2] < \infty$ para todo $T > 0$. Entonces, para todo $T > 0$, se cumple la desigualdad

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} \|M_t\| \right] \leq 3 \mathbb{E} [\langle M \rangle_T^{1/2}].$$

Demostración. Para cada $c > 0$, definimos el tiempo de paro

$$T_c := \inf \{t \geq 0 : \langle M \rangle_t \geq c^2\}.$$

Como $\langle M \rangle_t$ es un proceso creciente y continuo, T_c es un tiempo de paro válido. Consideremos el proceso $\|M_{t \wedge T \wedge T_c}\|^2$. Dado que M es una martingala continua, $\|M_t\|^2$ es una submartingala no negativa. Por lo tanto, $\|M_{t \wedge T \wedge T_c}\|^2$ también lo es. Aplicando la desigualdad de Doob para submartingalas reales no negativas, se tiene

$$\mathbb{P} \left(\sup_{0 \leq t \leq T} \|M_t\|^2 \geq c^2 \right) \leq \frac{1}{c^2} \mathbb{E} [\|M_{T \wedge T_c}\|^2].$$

Por la propiedad de la variación cuadrática, $\mathbb{E}[\|M_t\|^2] = \mathbb{E}[\langle M \rangle_t]$, y por la definición de T_c , $\mathbb{E}[\|M_{T \wedge T_c}\|^2] = \mathbb{E}[\langle M \rangle_{T \wedge T_c}] \leq \mathbb{E}[c^2 \wedge \langle M \rangle_T]$. Por lo tanto

$$\mathbb{P} \left(\sup_{0 \leq t \leq T} \|M_t\|^2 \geq c^2 \right) \leq \frac{1}{c^2} \mathbb{E} [c^2 \wedge \langle M \rangle_T].$$

Además, se puede escribir

$$\left\{ \sup_{0 \leq t \leq T} \|M_t\|^2 \geq c^2 \right\} \subseteq \{T_c < T\} \cup \left\{ \sup_{0 \leq t \leq T \wedge T_c} \|M_t\|^2 \geq c^2 \right\},$$

lo que implica

$$\mathbb{P} \left(\sup_{0 \leq t \leq T} \|M_t\|^2 \geq c^2 \right) \leq \mathbb{P} (\langle M \rangle_T \geq c^2) + \frac{1}{c^2} \mathbb{E} [c^2 \wedge \langle M \rangle_T].$$

Ahora, usando la representación del valor esperado como integral de la función de distribución

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} \|M_t\| \right] = \int_0^\infty \mathbb{P} \left(\sup_{0 \leq t \leq T} \|M_t\| \geq c \right) dc = \int_0^\infty \mathbb{P} \left(\sup_{0 \leq t \leq T} \|M_t\|^2 \geq c^2 \right) dc.$$

Sustituyendo la desigualdad anterior

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} \|M_t\| \right] \leq \int_0^\infty \left[\mathbb{P} (\langle M \rangle_T \geq c^2) + \frac{1}{c^2} \mathbb{E} [c^2 \wedge \langle M \rangle_T] \right] dc.$$

Calculamos las dos integrales por separado. Primero

$$\int_0^\infty \mathbb{P} (\langle M \rangle_T \geq c^2) dc = \int_0^\infty \mathbb{P} (\langle M \rangle_T^{1/2} \geq c) dc = \mathbb{E} [\langle M \rangle_T^{1/2}].$$

Después

$$\int_0^\infty \frac{1}{c^2} \mathbb{E} [c^2 \wedge \langle M \rangle_T] dc = \mathbb{E} \left[\int_0^\infty \frac{1}{c^2} (c^2 \wedge \langle M \rangle_T) dc \right].$$

Para un valor fijo $x = \langle M \rangle_T$, la integral interna es

$$\int_0^\infty \frac{1}{c^2} (c^2 \wedge x) dc = \int_0^{\sqrt{x}} 1 dc + x \int_{\sqrt{x}}^\infty \frac{1}{c^2} dc = \sqrt{x} + \sqrt{x} = 2\sqrt{x}.$$

Por lo tanto

$$\int_0^\infty \frac{1}{c^2} \mathbb{E} [c^2 \wedge \langle M \rangle_T] dc = \mathbb{E} [2\langle M \rangle_T^{1/2}].$$

Sumando ambos términos

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} \|M_t\| \right] \leq \mathbb{E} [\langle M \rangle_T^{1/2}] + 2 \mathbb{E} [\langle M \rangle_T^{1/2}] = 3 \mathbb{E} [\langle M \rangle_T^{1/2}]$$

Esto concluye la demostración. $\square$

Teorema 5.22. Sea $M = \{M_t\}_{t \geq 0}$ una martingala local continua en $L^2(\mathbb{P})$, y sea τ un tiempo de paro respecto a la filtración $\{\mathcal{F}_t\}$. Entonces, para cualquier $m \geq \frac{1}{2}$, se cumplen las siguientes desigualdades:

(a). Para $m \geq \frac{1}{2}$,

$$\mathbb{E} \left[\sup_{0 \leq t \leq \tau} |M_t|^{2m} \right] \leq B_m \mathbb{E} [\langle M \rangle_\tau^m],$$

donde

$$B_m = \begin{cases} 3, & \text{si } m = \frac{1}{2}, \\ [q^{2m}m(2m-1)]^m, & \text{si } m > \frac{1}{2}, \text{ con } \frac{1}{2m} + \frac{1}{q} = 1. \end{cases}$$

(b). Para $m > \frac{1}{2}$,

$$\mathbb{E} \left[\sup_{0 \leq t \leq \tau} |M_t|^{2m} \right] \geq C_m \mathbb{E} [\langle M \rangle_\tau^m],$$

donde

$$C_m = \begin{cases} \varepsilon^m \left[\frac{(1+\varepsilon)2^{1-m}}{2m-1} - 1 \right]^{-1}, & \text{si } \frac{1}{2} < m \leq 1, \varepsilon > 0, \\ \varepsilon^{m-1} \left(\frac{1-\varepsilon}{2^{m-1}} - \varepsilon \right), & \text{si } m > 1, \varepsilon \in \left(0, \frac{1}{2^{m-1}-1} \right). \end{cases}$$

Demostración. Sin pérdida de generalidad, podemos suponer que tanto M como su variación cuadrática previsible $\langle M \rangle$ son procesos acotados. Esto se justifica mediante un argumento de localización: existe una sucesión creciente de tiempos de paro $\{\tau_n\}$ tal que $\tau_n \uparrow \infty$ c.s. y los procesos detenidos M^{τ_n} y $\langle M \rangle^{\tau_n}$ son acotados. Las desigualdades se obtienen para cada n y luego se extienden al caso general mediante el teorema de convergencia monótona (Teorema 5.1).

El caso $m = \frac{1}{2}$ se deduce directamente del Teorema 2.5.17 de [29] que establece

$$\mathbb{E} \left[\sup_{0 \leq t \leq \tau} |M_t| \right] \leq 3 \mathbb{E} [\langle M \rangle_\tau^{1/2}].$$

Ahora asumimos $m > \frac{1}{2}$ y que $M, \langle M \rangle$ son acotados. Denotemos

$$M_t^* := \sup_{0 \leq s \leq t} |M_s|, \quad Y_t := \delta + \varepsilon \langle M \rangle_t + M_t^2,$$

donde $\delta > 0$ y $\varepsilon \geq 0$ son constantes a elegir posteriormente. Obsérvese que $Y_t > 0$ y es continuo. Aplicamos la fórmula de Itô a la función $f(x) = x^m$, $x > 0$

$$Y_t^m = \delta^m + m \int_0^t Y_s^{m-1} dY_s + \frac{m(m-1)}{2} \int_0^t Y_s^{m-2} d\langle Y \rangle_s.$$

Como $dY_s = (\varepsilon + 1) d\langle M \rangle_s + 2M_s dM_s$ y $d\langle Y \rangle_s = 4M_s^2 d\langle M \rangle_s$, sustituimos y obtenemos

$$\begin{aligned} Y_t^m &= \delta^m + m(1+\varepsilon) \int_0^t Y_s^{m-1} d\langle M \rangle_s + 2m \int_0^t Y_s^{m-1} M_s dM_s \\ &\quad + 2m(m-1) \int_0^t Y_s^{m-2} M_s^2 d\langle M \rangle_s. \end{aligned}$$

Al tomar esperanza matemática, el término de la integral estocástica desaparece (es una martingala de media cero por acotación), y obtenemos

$$\mathbb{E}[Y_t^m] = \delta^m + m(1+\varepsilon) \mathbb{E} \left[\int_0^t Y_s^{m-1} d\langle M \rangle_s \right] + 2m(m-1) \mathbb{E} \left[\int_0^t Y_s^{m-2} M_s^2 d\langle M \rangle_s \right].$$

5.10.0.0.1. Cota superior (parte (a)).

Consideramos ahora la desigualdad de Doob para martingalas: para $p = 2m > 1$,

$$\mathbb{E}[(M_t^*)^{2m}] \leq q^{2m} \mathbb{E}[|M_t|^{2m}], \quad \text{donde } \frac{1}{p} + \frac{1}{q} = 1.$$

Aplicando la fórmula de Itô a $|M_t|^{2m}$ (con segunda derivada $2m(2m-1)|M_t|^{2m-2}$) y tomando esperanza

$$\mathbb{E}[|M_t|^{2m}] = m(2m-1) \mathbb{E} \left[\int_0^t |M_s|^{2(m-1)} d\langle M \rangle_s \right].$$

Combinando ambas expresiones y aplicando la desigualdad de Hölder, se obtiene

$$\mathbb{E}[(M_t^*)^{2m}] \leq [q^{2m} m(2m-1)]^m \mathbb{E}[\langle M \rangle_t^m].$$

5.10.0.0.2. Cota inferior (parte (b)).

Retomamos la expresión de $\mathbb{E}[Y_t^m]$. Como $Y_t \geq M_t^2$, se tiene $Y_t^m \geq |M_t|^{2m}$. Además, $Y_s \geq \delta$, por lo que

$$\mathbb{E}[|M_t|^{2m}] \geq m(1+\varepsilon) \mathbb{E} \left[\int_0^t Y_s^{m-1} d\langle M \rangle_s \right].$$

Usando la desigualdad $(x+y)^m \leq 2^{m-1}(x^m + y^m)$ para $m \geq 1$, y un argumento de paso al límite $\delta \downarrow 0$, se deduce

$$\mathbb{E}[(M_t^*)^{2m}] \geq C_m \mathbb{E}[\langle M \rangle_t^m],$$

con C_m como en el enunciado (obtenido mediante optimización sobre ε). Finalmente, al considerar τ en lugar de t , basta observar que M^τ es también una martingala local continua y $\langle M^\tau \rangle = \langle M \rangle^\tau$, con lo que las desigualdades se mantienen reemplazando t por τ . Esto concluye la demostración. $\square$

6 Ecuaciones diferenciales estocásticas.

6.1. Formulación y Teoremas de Existencia y Unicidad

Definición 6.1. Un proceso $Y = \{Y_t\}_{t \geq 0}$ es una semimartingala si admite la descomposición canónica

$$Y_t = Y_0 + Y_t^c + \sum_{s \leq t} \Delta Y_s,$$

donde:

- Y_0 es $\mathcal{F}_0$ -medible.
- $Y^c = (Y_t^c)_{t \geq 0}$ es decir, la parte continua de la descomposición de Itô.
- $\Delta Y_s := Y_s - Y_{s-}$ es el salto de Y en el instante s ; por convención, $Y_{s-} = \lim_{r \uparrow s} Y_r$.
- $\sum_{s \leq t} |\Delta Y_s|^2 < \infty$ c.s. en compactos (Protter [25] Cap. II).

6.1.1. Teorema de existencia y unicidad global de una solución fuerte para la EDE con difusión y saltos

Definición 6.2. $\{x_t\}_{t \geq 0}$ es una solución $(\mathcal{F}_t-)$ de

$$\begin{aligned} x_t = x_0 + \int_0^t b(s, x_s, \omega) ds + \int_0^t \sigma(s, x_s, \omega) dw_s \\ + \int_0^t \int_Z R(s, x_{s-}, z, \omega) \tilde{N}_t(ds, dz), \quad t \geq 0 \end{aligned} \quad (6.1)$$

si y solo si $\{x_t\}_{t \geq 0}$ satisface la Ecuación 6.1. en el caso que $x_t \in \mathcal{F}_t^{\omega_s}, \forall t \geq 0$, donde $\mathcal{F}_t^{\omega_s}$ es la σ -álgebra generada por $\omega_s, s \leq t$, es una solución fuerte

Consideramos el espacio:

$$S_{\mathcal{F}}^{2,loc}(R) = \left\{ \begin{array}{l} f(t, \omega) : f(t, \omega) \text{ es } \mathcal{F}_t\text{-adaptada, de valor real, tal que} \\ \mathbb{E} \left[\sup_{t \in [0, T]} |f(t, \omega)|^2 \right] < \infty, \forall T < \infty \end{array} \right\} \quad (6.2)$$

Teorema 6.1. (*Existencia y unicidad global de una solución fuerte (condiciones de Lipschitz y crecimiento lineal global).*). Suponga que:

1. b y $\sigma : [0, \infty) \times \mathbb{R} \times \Omega \rightarrow \mathbb{R}, R : [0, \infty) \times \mathbb{R} \times Z \times \Omega \rightarrow \mathbb{R}$ son conjuntamente medibles y $\mathcal{F}_t$ -adaptadas, donde además R es $\mathcal{F}_t$ -predecible, tales que P-c.s.:

$$|b(t, x, \omega)| \leq \tilde{c}(t)(1 + |x|),$$

$$|\sigma(t, x, \omega)|^2 + \int_Z |R(t, x, z, \omega)|^2 \pi(dz) \leq \tilde{c}(t)(1 + |x|^2),$$

2.

$$|b(t, x_1, \omega) - b(t, x_2, \omega)| \leq \tilde{c}(t)|x_1 - x_2|,$$

$$|\sigma(t, x_1, \omega) - \sigma(t, x_2, \omega)|^2 + \int_Z |R(t, x_1, z, \omega) - R(t, x_2, z, \omega)|^2 \pi(dz) \leq \tilde{c}(t)|x_1 - x_2|^2,$$

donde $\tilde{c}(t)$ satisface las mismas condiciones que en 1°;

3.

$$x_0 \in \mathcal{F}_0, \quad E|x_0|^2 < \infty.$$

Entonces la Ecuación 6.1 tiene una solución única por trayectoria, $\mathcal{F}_t$ -adaptada, $\{x_t\}_{t \geq 0} \in S_{\mathcal{F}}^{2,loc}(\mathbb{R}^d)$.

En el caso en que $b(t, x, \omega)$ y $\sigma(t, x, \omega)$ sean $\mathcal{F}_t^{w, \tilde{N}}$ -adaptadas, y $R(t, x, z, \omega)$ sea $\mathcal{F}_t^{w, \tilde{N}}$ -predecible, entonces la solución también es $\mathcal{F}_t^{w, \tilde{N}}$ -adaptada, es decir, es una solución fuerte.

Demostración. Para algún $T < \infty$ fijo, se define la norma:

$$\|(x.)\|_M^2 = \sup_{t \in [0, T]} e^{-b_0 A(t)} \mathbb{E}[|x_t|^2],$$

donde: - $A(t) := \int_0^t 4\tilde{c}(s)ds$, - $b_0 \geq 0$ es una constante que se elegirá más adelante para hacer que el operador sea contractivo, - $\tilde{c}(s)$ es la función no aleatoria que aparece en las hipótesis 1 y 2 (crecimiento lineal y Lipschitz)

Entonces, el espacio sobre el cual se aplica el principio de contracción es:

$$H = \left\{ \{x_t\} \in B : B \in L_{\mathcal{F}}^2(\mathbb{R}), \|(x.)\|_M < \infty \right\}.$$

Sea $\Phi : H \rightarrow H$ el operador definido por:

$$(\Phi(x))_t = x_0 + \int_0^t b(s, x_s, \omega) ds + \int_0^t \sigma(s, x_s, \omega) dW_s + \int_0^t \int_Z R(s, x_{s-}, z, \omega) \tilde{N}(ds, dz).$$

y sea $X_t = x_t^{(1)} - x_t^{(2)}$, y $Y_t = (\Phi(x^{(1)}))_t - (\Phi(x^{(2)}))_t$. Entonces para un ω fijo

$$Y_t = \int_0^t [b(s, x_s^{(1)}, \omega) - b(s, x_s^{(2)}, \omega)] ds + \int_0^t [\sigma(s, x_s^{(1)}, \omega) - \sigma(s, x_s^{(2)}, \omega)] dW_s \\ + \int_0^t \int_Z [R(s, x_{s-}^{(1)}, z, \omega) - R(s, x_{s-}^{(2)}, z, \omega)] \tilde{N}(ds, dz).$$

Por comodidad

$$Y_t = \int_0^t \Delta b_s ds + \int_0^t \Delta \sigma_s dW_s + \int_0^t \int_Z \Delta R_s(z) \tilde{N}(ds, dz),$$

donde $\Delta b_s := b(s, x_s^{(1)}) - b(s, x_s^{(2)})$, $\Delta \sigma_s := \sigma(s, x_s^{(1)}) - \sigma(s, x_s^{(2)})$, $\Delta R_s(z) := R(s, x_{s-}^{(1)}, z) - R(s, x_{s-}^{(2)}, z)$. Puesto que la función $f(y) = y^2$ tiene derivadas $f'(y) = 2y$, $f''(y) = 2$, al aplicar la fórmula de Itô para semimartingalas con saltos, obtenemos

$$Y_t^2 = Y_0^2 + 2 \int_0^t Y_s dY_s^c + \int_0^t d\langle Y^c \rangle_s + \sum_{s \leq t} [Y_s^2 - Y_{s-}^2 - 2Y_{s-} \Delta Y_s],$$

donde: - $dY_s^c = \Delta b_s ds + \Delta \sigma_s dW_s$ es la parte continua, - $d\langle Y^c \rangle_s = (\Delta \sigma_s)^2 ds$ es la variación cuadrática de la parte continua, - $\Delta Y_s = \int_Z \Delta R_s(z) N(\{s\}, dz)$ es el tamaño del salto en el instante s . Al reescribir a la versión integral ya desarrollada y aplicar la formula de itô para $f(y) = y^2$ aplicada a Y_t

$$|Y_t|^2 = 2 \int_0^t Y_s \Delta b_s ds + 2 \int_0^t Y_s \Delta \sigma_s dW_s + \int_0^t |\Delta \sigma_s|^2 ds + 2 \int_0^t \int_Z Y_s \Delta R_s(z) \tilde{N}(ds, dz) \\ + \int_0^t \int_Z |\Delta R_s(z)|^2 N(ds, dz).$$

Aplicando valor esperado y sus propiedades

$$\mathbb{E}[|Y_t|^2] = \mathbb{E} \left[2 \int_0^t Y_s \Delta b_s ds \right] + \mathbb{E} \left[2 \int_0^t Y_s \Delta \sigma_s dW_s \right] \\ + \mathbb{E} \left[\int_0^t |\Delta \sigma_s|^2 ds + 2 \int_0^t \int_Z Y_s \Delta R_s(s, z) \tilde{N}(ds, dz) \right] \\ \mathbb{E} \left[\int_0^t \int_Z |\Delta R_s(z)|^2 N(ds, dz) \right]$$

Dado que los valores esperados de las integrales respecto a dW_s y $\tilde{N}$ son martingalas,

$$\mathbb{E} \left[\int_0^t Y_s \Delta \sigma_s dW_s \right] = 0,$$

$$\mathbb{E} \left[\int_0^t \int_Z Y_s \Delta R_s(z) \tilde{N}(ds, dz) \right] = 0,$$

y puesto que $\mathbb{E}[N(ds, dz)] = \pi(dz)ds$, se reduce a

$$\mathbb{E}[|Y_t|^2] = \mathbb{E} \left[\int_0^t \left(2Y_s \Delta b(s) + |\Delta \sigma(s)|^2 + \int_Z |\Delta R_s(s, z)|^2 \pi(dz) \right) ds \right].$$

Nótese que para el primer término, al aplicar la desigualdad de Cauchy-Schwarz $2Y_s \Delta b(s) \leq 2|Y_s| |\Delta b(s)|$, y por las hipótesis de Lipschitz

$$|\Delta b(s)| \leq \tilde{c}(s)|X_s|, \quad |\Delta \sigma(s)|^2 + \int_Z |\Delta R(s, z)|^2 \pi(dz) \leq \tilde{c}(s)|X_s|^2.$$

Además usando la desigualdad $2ab \leq a^2 + b^2$, se tiene que

$$2Y_s \Delta b(s) \leq 2|Y_s| \tilde{c}(s)|X_s| \leq \tilde{c}(s)(|Y_s|^2 + |X_s|^2),$$

aplicando valor esperado y tomando el supremo

$$\mathbb{E}[|Y_t|^2] \leq \int_0^t \tilde{c}(s) (\mathbb{E}[|Y_s|^2] + \mathbb{E}[|X_s|^2]) ds.$$

$$\mathbb{E} \left[\sup_{0 \leq r \leq t} |Y_r|^2 \right] \leq \int_0^t \tilde{c}(s) \left(\mathbb{E} \left[\sup_{0 \leq r \leq s} |Y_r|^2 \right] + \mathbb{E} \left[\sup_{0 \leq r \leq s} |X_r|^2 \right] \right) ds.$$

Como se ha eliminado la parte estocástica al tomar el valor esperado anteriormente, se procederá a obtener un acotamiento determinista.

Sea

$$u(t) := \mathbb{E} \left[\sup_{0 \leq r \leq t} |Y_r|^2 \right], \quad v(t) := \mathbb{E} \left[\sup_{0 \leq r \leq t} |X_r|^2 \right],$$

entonces podemos reescribir **eq-3** como

$$u(t) \leq \int_0^t \tilde{c}(s)(u(s) + v(s))ds,$$

aplicando la desigualdad de Gronwall

$$u(t) \leq \int_0^t \tilde{c}(s)v(s) \exp \left(\int_s^t \tilde{c}(r) dr \right) ds.$$

Multiplicamos ambos lados por $e^{-b_0 A(t)}$, donde $A(t) = \int_0^t 4\tilde{c}(r) dr$, entonces

$$e^{-b_0 A(t)} u(t) \leq e^{-b_0 A(t)} \int_0^t \tilde{c}(s) v(s) \exp\left(\int_s^t \tilde{c}(r) dr\right) ds.$$

Notemos que

$$\int_s^t \tilde{c}(r) dr = \frac{1}{4}(A(t) - A(s)),$$

y por lo tanto,

$$\begin{aligned} e^{-b_0 A(t)} u(t) &\leq \int_0^t \tilde{c}(s) v(s) \exp\left(\frac{1}{4}(A(t) - A(s)) - b_0 A(t)\right) ds \\ &= \int_0^t \tilde{c}(s) v(s) \exp\left(-\left(b_0 - \frac{1}{4}\right) A(t) - \frac{1}{4} A(s)\right) ds. \end{aligned}$$

Como $v(s) \leq e^{b_0 A(s)} \|X\|_M^2$, se tiene

$$e^{-b_0 A(t)} u(t) \leq \|X\|_M^2 \int_0^t \tilde{c}(s) \exp\left(-\left(b_0 - \frac{1}{4}\right) A(t) - \frac{1}{4} A(s)\right) ds$$

simplificando lo que esta dentro de la exponencial

$$\left(-\left(b_0 - \frac{1}{4}\right) A(t) - \frac{1}{4} A(s)\right) = \left(b_0 - \frac{1}{4}\right) (A(s) - A(t)),$$

se reduce a

$$e^{-b_0 A(t)} u(t) \leq \|X\|_M^2 \int_0^t \tilde{c}(s) \exp\left(\left(b_0 - \frac{1}{4}\right) (A(s) - A(t))\right) ds.$$

Dado que $A(s) - A(t) \leq 0$, el término exponencial es menor que uno si $b_0 \geq \frac{1}{4}$. Por lo que haciendo un cambio de variable $U = A(s)$, $dU = \tilde{c}(s) ds$, y $A(t) = \int_0^t \tilde{c}(s) ds$

$$\begin{aligned} \int_0^t \tilde{c}(s) \exp\left(\left(b_0 - \frac{1}{4}\right) (A(s) - A(t))\right) ds &= \int_0^{A(t)} \exp\left(\left(b_0 - \frac{1}{4}\right) (U - A(t))\right) dU \\ &= \exp\left(-\left(b_0 - \frac{1}{4}\right) A(t)\right) \\ &\quad \cdot \int_0^{A(t)} \exp\left(\left(b_0 - \frac{1}{4}\right) U\right) dU, \end{aligned}$$

Si $b_0 > \frac{1}{4}$

$$\int_0^{A(t)} \exp\left(\left(b_0 - \frac{1}{4}\right) U\right) dU = \frac{1}{b_0 - \frac{1}{4}} \left[\exp\left(\left(b_0 - \frac{1}{4}\right) A(t)\right) - 1 \right],$$

entonces

$$e^{-b_0 A(t)} u(t) \leq \|X\|_M^2 \frac{1}{b_0 - \frac{1}{4}} \left[1 - \exp\left(-\left(b_0 - \frac{1}{4}\right) A(t)\right) \right] \leq \|X\|_M^2 \frac{1}{b_0 - \frac{1}{4}},$$

por lo tanto

$$\|Y\|_M^2 = \sup_{t \in [0, T]} e^{-b_0 A(t)} u(t) \leq \frac{1}{b_0 - \frac{1}{4}} \|X\|_M^2.$$

Elegimos apropiadamente a $b_0 > \frac{5}{4}$, para que $\frac{1}{b_0 - \frac{1}{4}} < 1$, en consecuencia Φ es contractivo. Por el principio de contracción de Banach, Φ tiene un único punto fijo en H , que es la solución única de la SDE.

Ahora se demostrará que la solución es única por trayectoria. Sea x'_t , una versión RCLL (Definición 5.8) del proceso x_t que es solución de Ecuación 6.1, es decir para cada $t \in [0, T]$, $P(x'_t \neq x_t) = 0$, x'_t es solución de Ecuación 6.1 y es un proceso continuo por la derecha y con límite por la izquierda en t .

Denotemos x''_t y y_t como

$$\begin{aligned} x''_t &= x_0 + \int_0^t b(s, x_s, \omega) ds + \int_0^t \sigma(s, x_s, \omega) dw_s \\ &\quad + \int_0^t \int_Z R(s, x_{s-}, z, \omega) \tilde{N}_t(ds, dz), \quad t \in [0, T] \\ y_t &= x_0 + \int_0^t b(s, x'_s, \omega) ds + \int_0^t \sigma(s, x'_s, \omega) dw_s \\ &\quad + \int_0^t \int_Z R(s, x'_{s-}, z, \omega) \tilde{N}_t(ds, dz), \quad t \in [0, T]. \end{aligned}$$

Dado que x' es una versión RCLL de un proceso adaptado, por el teorema () x' es adaptado. \ Puesto que $x_t \in L^2(\Omega \times [0, T])$ y además ambos procesos son medibles como funciones $(t, \omega) \mapsto x_t(\omega)$ con respecto a la σ -álgebra producto $\mathcal{B}([0, T]) \otimes \mathcal{F}$. Entonces para cada t , $|x'_t - x_t|^2 = 0$ casi seguramente, es decir

$$\mathbb{E}[|x'_t - x_t|^2] = 0, \quad \text{para todo } t \in [0, T].$$

Ahora, bajo la suposición de medibilidad conjunta (que se cumple si, por ejemplo, los procesos son progresivamente medibles, lo cual es cierto para soluciones de SDEs con coeficientes medibles), podemos aplicar el (teorema de Fubini),

$$\mathbb{E}\left[\int_0^T |x'_t - x_t|^2 dt\right] = \int_0^T \mathbb{E}[|x'_t - x_t|^2] dt = 0.$$

Consideremos el conjunto donde los procesos no coinciden

$$N := \{(t, \omega) \in [0, T] \times \Omega : x'_t(\omega) \neq x_t(\omega)\},$$

este conjunto es medible en $\mathcal{B}([0, T]) \otimes \mathcal{F}$ ya que $x'_t(\omega) - x_t(\omega)$ es una función medible y además es equivalente a $N = \{(t, \omega) : |x'_t(\omega) - x_t(\omega)|^2 > 0\}$.

De la **eq-4** se sigue que

$$(dt \otimes \mathbb{P})(N) = \int_0^T \mathbb{P}(x'_t \neq x_t) dt = \mathbb{E} \left[\int_0^T 1_N(t, \omega) dt \right] = 0.$$

Como N tiene medida cero se puede decir que $x'_t = x_t$ para $(dt \otimes \mathbb{P})$ - casi todo (t, ω) .

Ahora, consideremos el conjunto denso $D := \mathbb{Q} \cap [0, T]$. Definimos el evento

$$\Omega_0 := \bigcap_{t \in D} \{\omega \in \Omega : x_t(\omega) = x'_t(\omega)\}.$$

Dado que D es numerable y $\mathbb{P}(x_t = x'_t) = 1$ para cada $t \in D$, se tiene $\mathbb{P}(\Omega_0) = 1$. Fijemos $\omega \in \Omega_0$, como ambas trayectorias $t \mapsto x_t(\omega)$ y $t \mapsto x'_t(\omega)$ son RCLL (continuas por la derecha con límites por la izquierda) y coinciden en el conjunto denso D , se sigue que

$$x_t(\omega) = x'_t(\omega) \quad \text{para todo } t \in [0, T].$$

Por lo tanto, el conjunto

$$\{\omega \in \Omega : x_t(\omega) = x'_t(\omega) \text{ para todo } t \in [0, T]\}$$

contiene a Ω_0 , y en consecuencia tiene probabilidad uno. Por lo tanto, coinciden para todo $t \in [0, T]$. Por lo que se concluye que la solución de la ecuación estocástica diferencial con saltos es única por trayectoria. Además, como los coeficientes b , σ y R son $\mathcal{F}_t^{W, \tilde{N}}$ -adaptados, se sigue la solución es fuerte. $\square$

Definición 6.3.

$$\tau^N := \inf\{t \geq 0 : |x_t| > N\}$$

Se demuestra que $\tau^N \uparrow \infty$ c.s. usando: - Estimaciones en $S^{2, \text{loc}}$ vía BDG y Grönwall, - Cota uniforme en N : $\mathbb{E}[\sup_{t \leq T} |x_t^N|^2] \leq K_T < \infty$, - Argumento de contradicción: $N^2 \mathbb{P}(\tau^N \leq T) \leq K_T \Rightarrow \mathbb{P}(\tau^N \leq T) \rightarrow 0$.

6.1.2. Teorema de existencia y unicidad local de una solución fuerte para la EDE con difusión y saltos

Teorema 6.2. *Si la condición 2° del Teorema anterior se debilita a 2°' tal que para cada $N = 1, 2, \dots$, existe una función no aleatoria $\tilde{c}^N(t)$ tal que para cada $|x_1|, |x_2| \leq N$,*

$$|b(t, x_1, \omega) - b(t, x_2, \omega)| \leq \tilde{c}^N(t) |x_1 - x_2|,$$

$$|\sigma(t, x_1, \omega) - \sigma(t, x_2, \omega)|^2 + \int_Z |R(t, x_1, z, \omega) - R(t, x_2, z, \omega)|^2 \pi(dz) \leq \tilde{c}^N(t) |x_1 - x_2|^2,$$

donde $\tilde{c}^N(t) \geq 0$ satisface

$$\int_0^T \tilde{c}^N(t) dt < \infty \quad \text{para cada } T < \infty,$$

manteniendo la condición de crecimiento lineal global (independiente de N):

$$\begin{aligned} |b(t, x, \omega)| &\leq \tilde{c}(t)(1 + |x|), \\ |\sigma(t, x, \omega)|^2 + \int_Z |R(t, x, z, \omega)|^2 \nu(dz) &\leq \tilde{c}(t)(1 + |x|^2), \end{aligned}$$

con $\tilde{c}(t) \geq 0$ no aleatoria y $\int_0^T \tilde{c}(t) dt < \infty$ para todo $T > 0$, y todas las demás hipótesis del Teorema anterior siguen siendo válidas. Entonces la conclusión del Teorema anterior sigue siendo cierta.

Demostración. Sea $b^N(t, x, \omega)$ definida de la siguiente manera

$$b^N(t, x, \omega) = \begin{cases} b(t, x, \omega), & \text{si } |x| \leq N, \\ b(t, N \frac{x}{|x|}, \omega), & \text{si } |x| > N. \end{cases}$$

De igual manera se hace para $\sigma^N(t, x, \omega)$ y $R^N(t, x, z, \omega)$, consideramos

$$\begin{aligned} x_t = x_0 + \int_0^t b_N(s, x_s^N, \omega) ds + \int_0^t \sigma^N(s, x_s^N, \omega) dw_s \\ + \int_0^t \int_Z R^N(s, x_{s-}^N, z, \omega) \tilde{N}_t(ds, dz), \quad t \geq 0 \end{aligned}$$

Como b^N, σ^N, R^N son globalmente Lipschitz en x y satisfacen las condiciones de medibilidad y crecimiento del Teorema anterior, se deduce inmediatamente la existencia y unicidad de una solución fuerte $\{x_t^N\}_{t \geq 0} \in S_{\mathcal{F}}^{2, loc}(\mathbb{R})$. Definimos el tiempo de paro $\tau^N := \inf\{t \geq 0 : |x_t^N| > N\}$, en el intervalo estocástico $[0, \tau^N)$, se tiene $x_t^N = x_t$, donde x_t es una solución de la ecuación original (Ecuación 6.1). Para $t < \tau^N$, se tiene $|x_t^N| \leq N$. Por la definición de los coeficientes truncados, esto implica

$$b^N(t, x_t^N, \omega) = b(t, x_t^N, \omega), \quad \sigma^N(t, x_t^N, \omega) = \sigma(t, x_t^N, \omega),$$

$$R^N(t, x_{t-}^N, z, \omega) = R(t, x_{t-}^N, z, \omega).$$

Por lo tanto, en $[0, \tau^N)$, la ecuación (7) coincide exactamente con la ecuación (1). Así, la restricción de x^N a $[0, \tau^N)$ es una solución local de (1).

Sea $N < M$, entonces, en el intervalo $[0, \tau^N)$, ambas soluciones x^N y x^M satisfacen la misma SDE, por la unicidad del Teorema anterior aplicada a la ecuación original en el intervalo estocástico, se concluye que

$$x_t^N = x_t^M \quad \text{para todo } t < \tau^N, \quad \text{c.s.}$$

lo que permite definir un proceso $x = \{x_t\}_{t \geq 0}$ mediante

$$x_t := x_t^N \quad \text{para } t \in [0, \tau^N).$$

Gracias a la compatibilidad entre las soluciones truncadas, esta definición es independiente de N , por lo tanto x está bien definido en todo $[0, \infty)$, siempre que $\tau^N \rightarrow \infty$ casi seguramente cuando $N \rightarrow \infty$. Supongamos ahora por contradicción que existe $(T_0 > 0)$ tal que

$$\mathbb{P} \left(\lim_{N \rightarrow \infty} \tau^N \leq T_0 \right) > 0.$$

Definamos $\tau := \lim_{N \rightarrow \infty} \tau^N$. Entonces, para el evento $A := \{\tau \leq T_0\}$, se tiene $\mathbb{P}(A) > 0$, y para todo N , $\tau^N \leq T_0$ en A , con $|x_{\tau^N}^N| = N$. Aplicando la desigualdad de Itô a la solución truncada x^N

$$\begin{aligned} |x_t^N|^2 &= |x_0|^2 + 2 \int_0^t x_s^N \cdot b^N(s, x_s^N) ds + 2 \int_0^t x_s^N \cdot \sigma^N(s, x_s^N) dw_s \\ &\quad + \int_0^t \|\sigma^N(s, x_s^N)\|^2 ds + \int_0^t \int_Z |c^N(s, x_{s-}^N, z)|^2 N(ds, dz) \\ &\quad + 2 \int_0^t \int_Z x_{s-}^N \cdot c^N(s, x_{s-}^N, z) \tilde{N}(ds, dz). \end{aligned}$$

Tomando supremo en $[0, T_0]$ y esperanza, y usando la desigualdad $(a + b + c)^2 \leq 3(a^2 + b^2 + c^2)$, obtenemos

$$\begin{aligned} \mathbb{E} \left[\sup_{0 \leq t \leq T_0} \|x_t^N\|^2 \right] &\leq C \left(\mathbb{E}[\|x_0\|^2] + \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t x_s^N \cdot b^N(s, x_s^N) ds \right| \right] \right. \\ &\quad \left. + \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t x_s^N \cdot \sigma^N(s, x_s^N) dW_s \right|^2 \right] + \mathbb{E} \left[\int_0^{T_0} \|\sigma^N(s, x_s^N)\|^2 ds \right] \right) \end{aligned}$$

$$+\mathbb{E} \left[\int_0^{T_0} \int_Z \|R^N(s, x_{s-}^N, z)\|^2 \nu(dz) ds \right] + \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t \int_Z x_{s-}^N \cdot R^N(s, x_{s-}^N, z) \tilde{N}(ds, dz) \right|^2 \right].$$

Ahora acotamos cada término usando la condición de crecimiento lineal global y la desigualdad de Burkholder–Davis–Gundy (BDG). Para el termino con drift aplicamos Cauchy–Schwarz y crecimiento lineal:

$$|x_s^N \cdot b^N(s, x_s^N)| \leq \|x_s^N\| \cdot \tilde{c}(s)(1 + \|x_s^N\|) \leq \tilde{c}(s)(\|x_s^N\| + \|x_s^N\|^2) \leq \tilde{c}(s)(1 + 2\|x_s^N\|^2).$$

Luego

$$\begin{aligned} \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t x_s^N \cdot b^N(s, x_s^N) ds \right| \right] &\leq \int_0^{T_0} \tilde{c}(s)(1 + 2\mathbb{E}[\|x_s^N\|^2]) ds \\ &\leq C \left(1 + \int_0^{T_0} \tilde{c}(s) \mathbb{E} \left[\sup_{r \leq s} \|x_r^N\|^2 \right] ds \right). \end{aligned}$$

Ahora para el término browniano por la desigualdad de BDG con $p = 2$, existe una constante universal $C_{\text{BDG}} > 0$ tal que

$$\mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t x_s^N \cdot \sigma^N(s, x_s^N) dW_s \right|^2 \right] \leq C_{\text{BDG}} \mathbb{E} \left[\int_0^{T_0} \|x_s^N \cdot \sigma^N(s, x_s^N)\|^2 ds \right].$$

Usando Cauchy–Schwarz y crecimiento lineal:

$$\|x_s^N \cdot \sigma^N(s, x_s^N)\|^2 \leq \|x_s^N\|^2 \cdot \|\sigma^N(s, x_s^N)\|^2 \leq \|x_s^N\|^2 \cdot \tilde{c}(s)(1 + \|x_s^N\|^2) \leq \tilde{c}(s)(\|x_s^N\|^2 + \|x_s^N\|^4).$$

Sin embargo, al trabajar con cotas en L^2 , es estándar usar directamente:

$$\|\sigma^N(s, x_s^N)\|^2 \leq \tilde{c}(s)(1 + \|x_s^N\|^2),$$

y por lo tanto:

$$\begin{aligned} \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t x_s^N \cdot \sigma^N(s, x_s^N) dW_s \right|^2 \right] &\leq C_{\text{BDG}} \int_0^{T_0} \tilde{c}(s) (1 + \mathbb{E}[\|x_s^N\|^2]) ds \\ &\leq C \left(1 + \int_0^{T_0} \tilde{c}(s) \mathbb{E} \left[\sup_{r \leq s} \|x_r^N\|^2 \right] ds \right). \end{aligned}$$

Análogamente para el término de saltos, por la versión con saltos de BDG, se tiene

$$\begin{aligned} \mathbb{E} \left[\sup_{t \leq T_0} \left| \int_0^t \int_Z x_{s-}^N \cdot R^N(s, x_{s-}^N, z) \tilde{N}(ds, dz) \right|^2 \right] &\leq C \mathbb{E} \left[\int_0^{T_0} \int_Z \|x_{s-}^N \cdot R^N(s, x_{s-}^N, z)\|^2 \nu(dz) ds \right] \\ &\leq C \int_0^{T_0} \tilde{c}(s) (1 + \mathbb{E}[\|x_s^N\|^2]) ds \leq C \left(1 + \int_0^{T_0} \tilde{c}(s) \mathbb{E} \left[\sup_{r \leq s} \|x_r^N\|^2 \right] ds \right). \end{aligned}$$

Por crecimiento lineal global se acotan los términos de variación cuadrática

$$\mathbb{E} \left[\int_0^{T_0} \|\sigma^N(s, x_s^N)\|^2 ds \right] + \mathbb{E} \left[\int_0^{T_0} \int_Z \|R^N(s, x_{s-}^N, z)\|^2 \nu(dz) ds \right] \leq C \int_0^{T_0} \tilde{c}(s) (1 + \mathbb{E}[\|x_s^N\|^2]) ds.$$

Reuniendo todas las estimaciones, definimos

$$u(t) := \mathbb{E} \left[\sup_{0 \leq r \leq t} \|x_r^N\|^2 \right],$$

y obtenemos

$$u(t) \leq C \left(1 + \mathbb{E}[\|x_0\|^2] + \int_0^t \tilde{c}(s) u(s) ds \right).$$

Por la desigualdad de Grönwall, se deduce

$$u(T_0) \leq C (1 + \mathbb{E}[\|x_0\|^2]) \exp \left(C \int_0^{T_0} \tilde{c}(s) ds \right) =: K_{T_0}.$$

K_{T_0} no depende de N , ya que $\tilde{c}(t)$ es independiente de N por hipótesis. Ahora, observamos que en el evento A se tiene $\tau_N \leq T_0$ y $\|x_{\tau_N}^N\| = N$, luego

$$N^2 \mathbb{P}(A) \leq \mathbb{E} \left[\sup_{0 \leq t \leq \tau_N \wedge T_0} \|x_t^N\|^2 \right] \leq K_{T_0}.$$

Esto implica

$$\mathbb{P}(A) \leq \frac{K_{T_0}}{N^2} \xrightarrow{N \rightarrow \infty} 0,$$

lo cual contradice $\mathbb{P}(A) > 0$. Por lo tanto, $\mathbb{P}(A) = 0$ para todo $T_0 > 0$, y en consecuencia,

$$\mathbb{P} \left(\lim_{N \rightarrow \infty} \tau_N = \infty \right) = 1.$$

Esto garantiza que el proceso $x = \{x_t\}_{t \geq 0}$ está definido para todo $t \geq 0$, pertenece a $S_{\mathcal{F}}^{2, \text{loc}}(\mathbb{R})$, y es la única solución fuerte de la SDE Ecuación 6.1. La unicidad por trayectoria se sigue del argumento estándar usando densidad de $\mathbb{Q} \cap [0, T]$ y la propiedad cádlág de las soluciones, como se demostró en el Teorema Teorema 6.1. $\square$

6.2. Modelo de Cramér–Lundberg Extendido.

6.2.1. Formulación del modelo base (C-L clásico).

El modelo clásico de Cramér–Lundberg (C-L) constituye un pilar fundamental en la teoría de riesgo actuarial, ofreciendo una representación matemáticamente rigurosa de la evolución del capital de una aseguradora a lo largo del tiempo. Formalmente, consideramos

un proceso estocástico $\{U(t)\}_{t \geq 0}$ que representa la reserva de capital de la aseguradora en el instante t . El modelo clásico de Cramér-Lundberg (Lundberg [22]) postula que esta reserva evoluciona mediante:

$$U(t) = u + ct - \sum_{i=1}^{N(t)} Y_i, \quad (6.3)$$

donde:

- $U(t)$: Reserva o capital en el tiempo t ,
- u : Capital inicial,
- c : Tasa de entrada de primas (constante en el modelo clásico),
- $N(t)$: Proceso de conteo de siniestros, modelado como un proceso de Poisson homogéneo con intensidad $\lambda > 0$. Formalmente, $N(t)$ es un proceso y $\mathbb{E}[N(t)] = \lambda t$.
- $\{Y_i\}_{i \geq 1}$: Secuencia de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) que representan las magnitudes de los siniestros, con distribución F_Y y función de densidad f_Y (en caso de ser absolutamente continua). Se asume que $\mathbb{E}[Y_1] = \mu < \infty$ y $\text{Var}(Y_1) = \sigma^2 < \infty$ para garantizar la existencia de momentos necesarios en el análisis.

La suposición de parámetros constantes (especialmente la tasa de primas c y la intensidad del proceso de Poisson λ) limita su aplicabilidad en entornos dinámicos donde las condiciones del mercado cambian con el tiempo, como es el caso del mercado asegurador mexicano que enfrenta variaciones estacionales en los siniestros catastróficos, cambios en las tasas de inversión y fluctuaciones en la estructura de primas debido a factores macroeconómicos como la inflación.

6.2.2. Extensión del modelo (C-L) a un modelo con difusión y saltos.

Formalmente, extendemos el proceso de reservas $\{U(t)\}_{t \geq 0}$ del modelo (C-L) que sigue la dinámica estocástica de una ecuación diferencial con difusión y saltos (EDES).

Las ecuaciones diferenciales estocásticas con saltos (EDES) constituyen una extensión natural del cálculo estocástico clásico de Itô, (Sección 5.7) permitiendo modelar dinámicas que combinan evolución continua con cambios abruptos discontinuos. Este marco teórico es esencial para representar fenómenos en los que coexisten tendencias suaves y eventos extremos, como es el caso de los mercados financieros y las carteras de seguros sujetas a siniestros catastróficos.

Una ecuación diferencial estocástica con saltos y parámetros dependientes del tiempo toma la forma general (Capítulo 6)

$$dX(t) = a(t, X(t^-))dt + b(t, X(t^-))dW(t) + \int_{\mathbb{R}} R(t, X(t^-), x)\tilde{N}(dt, dx), \quad (6.4)$$

donde los coeficientes a , b y R satisfacen condiciones de Lipschitz y crecimiento lineal que garantizan existencia y unicidad de soluciones fuertes. La notación $X(t^-)$ denota el valor del proceso predecible (Sección 5.6) inmediatamente antes del tiempo t , crucial para manejar correctamente las discontinuidades inducidas por los saltos. (Teorema 6.1) $N(dt, dx)$ es una medida de Poisson aleatoria que cuenta los saltos de tamaño x en el intervalo dt , y $\tilde{N}(dt, dx) = N(dt, dx) - \nu(dx)dt$ es su compensador con ν siendo la medida de Poisson compensada. Esta descomposición separa explícitamente la componente difusiva continua ($\sigma W(t)$) de los saltos de pequeña magnitud (integrado compensado) y los saltos de gran magnitud (integrado puro). (Sección 5.5)

Para capturar la dinámica real del mercado Mexicano, extendemos el modelo incorporando dependencia temporal en todos los parámetros.

En el contexto actuarial, esta estructura matemática permite integrar de manera coherente tres elementos fundamentales:

- La acumulación determinista de primas,
- La evolución estocástica de las inversiones con volatilidad de mercado,
- La ocurrencia aleatoria de siniestros catastróficos modelados como saltos negativos. El uso de parámetros dependientes del tiempo ($c(t)$, $r(t)$, $\sigma(t)$) refleja adecuadamente la estacionalidad en la frecuencia de siniestros, las fluctuaciones en las tasas de interés y la variabilidad de la volatilidad financiera observadas en mercados emergentes como el Mexicano. Incorporando los fundamentos teóricos al marco de la ecuación el proceso de reservas $\{U(t)\}_{t \geq 0}$ se presenta como la siguiente ecuación diferencial estocástica con saltos (Ecuación 6.4)

$$dU(t) = \underbrace{c(t)dt}_{\text{Primas}} + \underbrace{U(t^-)r(t)dt}_{\text{Rendimientos}} + \underbrace{U(t^-)\sigma(t)dW(t)}_{\text{Volatilidad}} - \underbrace{dJ(t)}_{\text{Siniestros}}, \quad (6.5)$$

donde

- $c(t) > 0$ es la tasa de prima neta tiempo-dependiente, ajustada por inflación y estacionalidad en la demanda (Sección 8.1.1);
- $r(t)$ representa la tasa de interés instantánea de la cartera de inversiones, modelada como un proceso determinista que refleja la estructura de tasas de Banxico, los rendimientos de CETES y globales (ILS) (Sección 8.1.2) ;
- $\sigma(t) > 0$ es la volatilidad tiempo-dependiente de las inversiones, estimada mediante una combinación convexa de la volatilidad de activos locales (CETES) y globales (ILS), ponderada por la composición de la cartera según reportes de la CNSF (Sección 8.1.3);
- $W(t)$ es un movimiento browniano estándar que modela el riesgo de mercado continuo;
- $J(t)$: Proceso de saltos compuesto que modela siniestros catastróficos.

Por tanto las soluciones del proceso de reservas presentado por la ecuación (Ecuación 6.5) bajo las especificaciones del modelo (con tasas de prima, interés y volatilidad acotadas), cumple con las condiciones de Lipschitz y crecimiento lineal que garantizan existencia y unicidad de soluciones fuertes para el proceso de reservas.

- $N_m(t)$: Proceso de Poisson no homogéneo para eventos meteorológicos con intensidad $\lambda_m(t)$,
- $N_s(t)$: Proceso de Poisson para eventos sísmicos con intensidad constante λ_s ,
- $Y_k^{(m)} \sim \text{TruncNormal}(\mu_m, \sigma_m^2)$: Severidad de siniestros meteorológicos,
- $Y_\ell^{(s)} \sim \text{TruncNormal}(\mu_s, \sigma_s^2)$: Severidad de siniestros sísmicos.

6.3. Análisis Asintótico y Estimación de Parámetros

6.3.1. Estimación de la Varianza Integrada

Teorema 6.3. *Definamos la variación de bipotencia con retardo $h = 1$,*

$$BV_n := \frac{1}{\mu_1^2} \sum_{i=2}^n |r_{i-1,n}| \cdot |r_{i,n}|, \quad \mu_1 = \sqrt{\frac{2}{\pi}},$$

se quiere demostrar que es un estimador consistente en probabilidad de la varianza integrada

$$IV := \int_0^1 \sigma^2(t) dt,$$

es decir,

$$BV_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} IV.$$

Demostración. Cada retorno se descompone en su parte continua y su parte por saltos

$$r_{i,n} = C_{i,n} + S_{i,n},$$

donde

$$C_{i,n} = \int_{(i-1)\Delta}^{i\Delta} \sigma(t) dW(t), \quad S_{i,n} = \sum_{(i-1)\Delta < t \leq i\Delta} \Delta J_t.$$

Por la hipótesis de actividad finita de los saltos, se tiene que

$$\mathbb{P}(S_{i-1,n} \neq 0 \text{ y } S_{i,n} \neq 0) \xrightarrow[n \rightarrow \infty]{} 0.$$

Por lo tanto, con probabilidad 1,

$$|r_{i-1,n}| \cdot |r_{i,n}| = |C_{i-1,n}| \cdot |C_{i,n}| + o_p(n^{-1}).$$

Dado que $\sigma(t)$ es cádlág, es localmente constante en el límite. Así, condicionalmente,

$$\mathbb{E}[|C_{i-1,n}| \cdot |C_{i,n}| \mid \mathcal{F}_{(i-1)\Delta}] = \mu_1^2 \cdot \sigma^2((i-1)\Delta) \cdot \frac{1}{n} + o(n^{-1}),$$

donde $\mu_1 = \mathbb{E}[|Z|] = \sqrt{2/\pi}$, $Z \sim N(0, 1)$. Sumando sobre $i = 2, \dots, n$, obtenemos

$$\mathbb{E}[BV_n] = \frac{1}{\mu_1^2} \sum_{i=2}^n \mathbb{E}[|r_{i-1,n}| \cdot |r_{i,n}|] = \sum_{i=2}^n \sigma^2((i-1)\Delta) \cdot \frac{1}{n} + o(1).$$

□

6.3.2. Hipótesis técnicas

- **Hipotesis 1** (*Cádlág y previsibilidad*) El proceso $\sigma^2(t)$ es cádlág (continuo por la derecha con límites por la izquierda) y predecible.
- **Hipótesis 2** (*Acotamiento local*) Existe una sucesión creciente de tiempos de parada $(\tau_m)_{m \geq 1}$, con $\tau_m \uparrow \infty$ casi seguramente, tal que

$$\sup_{t \leq \tau_m} \sigma^2(t) < \infty \quad \text{c.s.}$$

- **Hipótesis 3** (*Integrabilidad*)

$$\int_0^1 \sigma^2(t) dt < \infty \quad \text{casi seguramente.}$$

Teorema 6.4. *Bajo las Hipótesis 1–3 y la condición de actividad finita de los saltos, se cumple:*

$$BV_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \int_0^1 \sigma^2(t) dt.$$

Es decir, la variación de bipotencia es un estimador consistente en probabilidad de la varianza integrada.

Sea $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0,1]}, \mathbb{P})$ un espacio de probabilidad filtrado que satisface las condiciones usuales (completo y continuo por la derecha).

Supongamos que $\sigma^2 = (\sigma^2(t))_{t \in [0,1]}$ es un proceso estocástico. Definimos la partición regular del intervalo $[0, 1]$ como $t_i^n := \frac{i}{n}$, $i = 0, 1, \dots, n$. La suma de Riemann izquierda asociada a σ^2 es

$$S_n := \frac{1}{n} \sum_{i=1}^n \sigma^2(t_{i-1}^n) = \frac{1}{n} \sum_{i=1}^n \sigma^2\left(\frac{i-1}{n}\right).$$

Denotamos el límite objetivo como la varianza integrada

$$IV := \int_0^1 \sigma^2(t) dt.$$

se busca demostrar que, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|S_n - IV| > \varepsilon) = 0,$$

es decir, $S_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} IV$.

Demostración. Supongamos que existe una constante $M < \infty$ tal que

$$\sigma^2(t, \omega) \leq M \quad \text{para todo } t \in [0, 1], \text{ c.s.}$$

Como $\sigma^2(\cdot, \omega)$ es cádlág, para cada trayectoria fija ω , la función $t \mapsto \sigma^2(t, \omega)$ es Lebesgue-integrable y Riemann-integrable en $[0, 1]$ (pues las funciones cádlág tienen a lo sumo un número numerable de discontinuidades). Por resultados clásicos del análisis real, para cada ω fijo,

$$S_n(\omega) \xrightarrow[n \rightarrow \infty]{} IV(\omega).$$

Es decir, la convergencia es casi segura. La convergencia casi segura implica convergencia en probabilidad:

$$S_n \xrightarrow{\mathbb{P}} IV \quad \text{cuando } \sigma^2 \text{ está uniformemente acotado.}$$

Dado que σ^2 es localmente acotado, existe una sucesión creciente de tiempos de parada $(\tau_m)_{m \geq 1}$ tal que $\tau_m \uparrow \infty$ c.s. cuando $m \rightarrow \infty$ y $\sup_{t \leq \tau_m} \sigma^2(t) \leq m$ c.s.

Definimos el proceso truncado

$$\sigma_m^2(t) := \sigma^2(t) \cdot \mathbf{1}_{\{t \leq \tau_m\}} + m \cdot \mathbf{1}_{\{t > \tau_m\}}.$$

Entonces: σ_m^2 es uniformemente acotado por m , - $\sigma_m^2(t) \rightarrow \sigma^2(t)$ c.s. para cada t , cuando $m \rightarrow \infty$, - $IV_m := \int_0^1 \sigma_m^2(t) dt \rightarrow IV$ c.s. por el teorema de convergencia monótona.

Definimos la suma de Riemann asociada al proceso truncado:

$$S_n^{(m)} := \frac{1}{n} \sum_{i=1}^n \sigma_m^2\left(\frac{i-1}{n}\right).$$

Del Paso 1, para cada m fijo,

$$S_n^{(m)} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} IV_m.$$

Además, como $\sigma_m^2 \rightarrow \sigma^2$ c.s. y ambas son acotadas por una función integrable (σ^2), se tiene:

$$|S_n^{(m)} - S_n| \leq \frac{1}{n} \sum_{i=1}^n |\sigma_m^2(t_{i-1}^n) - \sigma^2(t_{i-1}^n)| \xrightarrow[m \rightarrow \infty]{} 0 \quad \text{c.s.}$$

Fijemos $\varepsilon > 0$. Queremos mostrar:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|S_n - IV| > \varepsilon) = 0.$$

Por la desigualdad triangular,

$$|S_n - IV| \leq |S_n - S_n^{(m)}| + |S_n^{(m)} - IV_m| + |IV_m - IV|.$$

Luego, para cualquier m ,

$$\begin{aligned} \mathbb{P}(|S_n - IV| > \varepsilon) &\leq \mathbb{P}(|S_n - S_n^{(m)}| > \varepsilon/3) + \mathbb{P}(|S_n^{(m)} - IV_m| > \varepsilon/3) \\ &\quad + \mathbb{P}(|IV_m - IV| > \varepsilon/3). \end{aligned} \quad (6.6)$$

Por construcción, $\sigma_m^2(t) \rightarrow \sigma^2(t)$ c.s. para cada $t \in [0, 1]$ cuando $m \rightarrow \infty$. Además, como σ^2 es localmente acotado y $\int_0^1 \sigma^2(t) dt < \infty$ c.s., existe una variable integrable que domina la secuencia $(\sigma_m^2)_{m \geq 1}$. En efecto, para todo m ,

$$0 \leq \sigma_m^2(t) \leq \sigma^2(t) + m \cdot \mathbf{1}_{\{t > \tau_m\}} \leq \sigma^2(t) + C,$$

para alguna constante C , y σ^2 es integrable c.s., luego $\sigma^2 + C \in L^1(\Omega \times [0, 1])$. Por el teorema de convergencia dominada

$$IV_m = \int_0^1 \sigma_m^2(t) dt \xrightarrow[m \rightarrow \infty]{\text{c.s.}} \int_0^1 \sigma^2(t) dt = IV.$$

La convergencia casi segura implica convergencia en probabilidad, por lo que

$$\mathbb{P}(|IV_m - IV| > \varepsilon/3) \xrightarrow{m \rightarrow \infty} 0.$$

Por lo tanto, existe m_0 tal que para todo $m \geq m_0$,

$$\mathbb{P}(|IV_m - IV| > \varepsilon/3) < \frac{\varepsilon}{3}.$$

Para el segundo termino se tiene que

$$|S_n - S_n^{(m)}| \leq \frac{1}{n} \sum_{i=1}^n \left| \sigma^2\left(\frac{i-1}{n}\right) - \sigma_m^2\left(\frac{i-1}{n}\right) \right|.$$

Tomando esperanza y usando la linealidad

$$\mathbb{E}[|S_n - S_n^{(m)}|] \leq \frac{1}{n} \sum_{i=1}^n \mathbb{E} \left[\left| \sigma^2\left(\frac{i-1}{n}\right) - \sigma_m^2\left(\frac{i-1}{n}\right) \right| \right].$$

Dado que la partición es fina y la función $t \mapsto |\sigma^2(t) - \sigma_m^2(t)|$ es no negativa, la suma de Riemann está acotada por la integral

$$\frac{1}{n} \sum_{i=1}^n \mathbb{E} \left[\left| \sigma^2\left(\frac{i-1}{n}\right) - \sigma_m^2\left(\frac{i-1}{n}\right) \right| \right] \leq \mathbb{E} \left[\int_0^1 |\sigma^2(t) - \sigma_m^2(t)| dt \right].$$

Nuevamente, por el teorema de convergencia dominada, el lado derecho tiende a 0 cuando $m \rightarrow \infty$, y esta cota no depende de n . Por lo tanto

$$\sup_{n \geq 1} \mathbb{E}[|S_n - S_n^{(m)}|] \xrightarrow{m \rightarrow \infty} 0.$$

Aplicando la desigualdad de Markov(citar)

$$\mathbb{P}(|S_n - S_n^{(m)}| > \varepsilon/3) \leq \frac{\mathbb{E}[|S_n - S_n^{(m)}|]}{\varepsilon/3} \leq \frac{\sup_n \mathbb{E}[|S_n - S_n^{(m)}|]}{\varepsilon/3}.$$

Como el numerador tiende a 0 uniformemente en n , se concluye

$$\sup_{n \geq 1} \mathbb{P}(|S_n - S_n^{(m)}| > \varepsilon/3) \xrightarrow{m \rightarrow \infty} 0.$$

Así, para el mismo para m_0

$$\mathbb{P}(|S_n - S_n^{(m)}| > \varepsilon/3) < \frac{\varepsilon}{3} \quad \text{para todo } n$$

Ahora para m fijo, σ_m^2 es uniformemente acotado por m , cádlág y predecible. Por lo tanto, para cada $\omega \in \Omega$, la función $t \mapsto \sigma_m^2(t, \omega)$ es Riemann-integrable en $[0, 1]$, pues posee a lo sumo un número numerable de discontinuidades. Por lo que para cada ω , la suma de Riemann izquierda converge a la integral

$$S_n^{(m)}(\omega) \xrightarrow{n \rightarrow \infty} IV_m(\omega).$$

Esto implica $S_n^{(m)} \xrightarrow{\text{c.s.}} IV_m$. Dado que la convergencia casi segura implica convergencia en probabilidad, luego

$$\mathbb{P}(|S_n^{(m)} - IV_m| > \varepsilon/3) \xrightarrow{n \rightarrow \infty} 0.$$

Para el m_0 elegido anteriormente, existe $N \in \mathbb{N}$ tal que $\forall n \geq N$,

$$\mathbb{P}(|S_n^{(m_0)} - IV_{m_0}| > \varepsilon/3) < \varepsilon/3.$$

Sustituyendo en (2), para todo $n \geq N$,

$$\mathbb{P}(|S_n - IV| > \varepsilon) < \frac{\varepsilon}{3} + \frac{\varepsilon}{3} + \frac{\varepsilon}{3} = \varepsilon.$$

Como $\varepsilon > 0$ fue arbitrario, concluimos

$$\lim_{n \rightarrow \infty} \mathbb{P}(|S_n - IV| > \varepsilon) = 0.$$

es decir, $S_n \xrightarrow{\mathbb{P}} IV$. $\square$

$\square$

6.4. Estimación de la Intensidad de Saltos.

6.4.1. Estimador $\hat{\lambda}_n$ y elección del umbral $\tau_n = \alpha \Delta_n^\varpi$.

Definimos el estimador de intensidad de saltos mediante el método de conteo con umbral:

$$\hat{\lambda}_n := \frac{1}{T} \sum_{i=1}^n \mathbf{1}_{\{|\Delta_i^n X| > \tau_n\}}, \quad (6.7)$$

donde $\tau_n > 0$ es un umbral determinista que depende de n . Siguiendo la metodología de (Ait-Sahalia y Jacod [2]) (ver Sección 4.3 y la ecuación (24)), elegimos el umbral de la forma

$$\tau_n = \alpha \Delta_n^\varpi, \quad \alpha > 0, \quad \varpi \in \left(0, \frac{1}{2}\right). \quad (6.8)$$

Esta elección es crucial y satisface dos propiedades asintóticas fundamentales:

- (I) **Detección de saltos:** $\tau_n \rightarrow 0$ cuando $n \rightarrow \infty$. Esto asegura que, asintóticamente, cualquier salto de tamaño fijo (no nulo) será detectado, ya que su magnitud superará al umbral.
- (II) **Eliminación del ruido difusivo:** $\tau_n / \sqrt{\Delta_n} = \alpha \Delta_n^{\varpi-1/2} \rightarrow \infty$. Esto asegura que los incrementos correspondientes a la parte continua del proceso (de orden estocástico $\sqrt{\Delta_n}$) rara vez superarán el umbral, controlando así los falsos positivos.

Teorema 6.5. (*Consistencia del estimador de intensidad*). Supongamos que el proceso X satisface el modelo (Ecuación 7.2) bajo el Assumption 1 de (Ait-Sahalia y Jacod [2]) y tiene actividad finita de saltos, $\lambda = \int_E \lambda(dx) < \infty$.

Considérese un régimen asintótico de alta frecuencia en el que $\Delta_n \rightarrow 0$ y $T = n\Delta_n \rightarrow \infty$ cuando $n \rightarrow \infty$. Entonces, bajo la elección del umbral (Ecuación 6.7) con $\varpi \in (0, 1/2)$, el estimador (Ecuación 6.8) es consistente en probabilidad para λ , es decir,

$$\hat{\lambda}_n \xrightarrow{\mathbb{P}} \lambda.$$

Demostración. Un falso positivo ocurre cuando un incremento $\Delta_i^n X$ sin salto (es decir, generado únicamente por la parte continua del proceso) excede el umbral τ_n . Para controlar este fenómeno, debemos analizar la magnitud de la parte continua. La herramienta fundamental es la cota proporcionada en la **ecuación (46)** de (Ait-Sahalia y Jacod [2]) (Sección 8.1), derivada bajo el Assumption 1. Para cualquier $\eta > 0$ y $\theta \in (0, 1)$, se cumple

$$\mathbb{E}_{i-1}^n (|\Delta_i^n X - \delta_i^n|^2 \wedge \eta^2) \leq K \Delta_n (\eta^2 + \Delta_n^\theta + \epsilon(\theta))$$

donde - $\mathbb{E}_{i-1}^n(\cdot) = \mathbb{E}(\cdot \mid \mathcal{F}_{(i-1)\Delta_n})$, - $\delta_i^n = \sigma_{(i-1)\Delta_n}(W_{i\Delta_n} - W_{(i-1)\Delta_n})$ es la aproximación gaussiana de la parte continua, - $\epsilon(\theta) \rightarrow 0$ cuando $\theta \rightarrow 0$, - K es una constante que depende de los coeficientes del modelo.

Esta desigualdad implica que la parte continua del incremento es de orden $O_p(\sqrt{\Delta_n})$. Ahora, utilizando la desigualdad de Chebyshev o argumentos de cola gaussiana, la probabilidad de que un incremento puramente difusivo exceda τ_n se puede acotar por

$$\mathbb{P}(|\Delta_i^n X| > \tau_n \mid \text{no hay salto en } [(i-1)\Delta_n, i\Delta_n]) \leq C \exp\left(-c \frac{\tau_n^2}{\Delta_n}\right).$$

Dado que $\tau_n^2/\Delta_n = \alpha^2 \Delta_n^{2\varpi-1} \rightarrow \infty$ (porque $\varpi < 1/2$), el término exponencial decae a cero más rápido que cualquier potencia de Δ_n . Por lo tanto, el número esperado de falsos positivos, FP_n , satisface

$$\mathbb{E}[\text{FP}_n] = \sum_{i=1}^n \mathbb{P}(\text{falso positivo en } i) \leq n \cdot o(\Delta_n) = o(T).$$

En consecuencia, $\text{FP}_n/T \xrightarrow{\mathbb{P}} 0$. Un falso negativo ocurre cuando un salto real J ocurre en un intervalo de muestreo, pero su magnitud $|J|$ es menor o igual que τ_n , por lo que no se detecta. Sin embargo, dado que el proceso tiene actividad finita, el número de saltos en $[0, T]$ es finito c.s., y cada salto tiene tamaño $|J_k| > 0$ c.s. Dado que $\tau_n \rightarrow 0$ por construcción, existe un $n_0(\omega)$ (aleatorio pero finito) tal que para todo $n \geq n_0(\omega)$, se cumple $\tau_n < \min_{k=1, \dots, N_T} |J_k|(\omega)$. Por lo tanto, asintóticamente, todos los saltos son detectados y el número de falsos negativos, FN_n , satisface $\mathbb{E}[\text{FN}_n] \rightarrow 0$, lo que implica $\text{FN}_n/T \xrightarrow{\mathbb{P}} 0$. Sea N_T el número real (y finito) de saltos en $[0, T]$. De los pasos anteriores, se deduce que el número de saltos detectados por el estimador coincide asintóticamente con N_T :

$$\sum_{i=1}^n \mathbf{1}_{\{|\Delta_i^n X| > \tau_n\}} = N_T + \text{FP}_n - \text{FN}_n = N_T + o_{\mathbb{P}}(T).$$

Dividiendo por T , obtenemos

$$\hat{\lambda}_n = \frac{N_T}{T} + o_{\mathbb{P}}(1).$$

Finalmente, dado que la actividad de saltos es finita y la intensidad es constante λ , el proceso de conteo N_T es un proceso de Poisson con media $\mathbb{E}[N_T] = \lambda T$ y varianza $\text{Var}(N_T) = \lambda T$. Por la ley de los grandes números para procesos de Poisson, se tiene que cuando $T \rightarrow \infty$,

$$\frac{N_T}{T} \xrightarrow{\mathbb{P}} \lambda.$$

Combinando las dos últimas convergencias, concluimos que

$$\hat{\lambda}_n \xrightarrow{\mathbb{P}} \lambda,$$

lo cual demuestra el Teorema 6.5. □

6.4.2. Estimación no paramétrica de la distribución de severidad de los saltos.

La estimación de la intensidad de saltos desarrollada en la Sección 6.4.1 permite identificar, mediante un procedimiento basado en umbrales, los incrementos de la trayectoria observada cuya magnitud resulta incompatible con la variación continua esperada. Sin embargo, el conteo de dichos incrementos proporciona únicamente información acerca de la frecuencia de ocurrencia de los eventos detectados y no caracteriza la magnitud de los saltos.

En esta sección se desarrolla el procedimiento estadístico necesario para obtener, a partir de las detecciones identificadas por el umbral, una estimación no paramétrica de la distribución de severidad. El procedimiento se formula sobre la trayectoria del proceso de reservas y no requiere especificar previamente una familia paramétrica para la distribución de las magnitudes de los saltos.

La formulación se desarrolla inicialmente para una trayectoria genérica y posteriormente puede aplicarse de manera idéntica a cada uno de los esquemas numéricos considerados en el Capítulo 7.

El Teorema 6.5 garantiza que $\hat{\lambda}_n$ (Ecuación 6.7) es un estimador consistente de la *intensidad total* λ , pero es un estadístico *agregado*: cuenta cuántos incrementos superan el umbral τ_n sin identificar *cuáles* instantes contienen un salto ni *qué tamaño* tuvo cada uno. Esta sección extiende el marco de la Sección 6.4 en dos direcciones: Se pondera el umbral por la volatilidad instantánea local $\hat{\sigma}(t_{n-1})$, refinamiento introducido por Mancini [23] y Lee y Mykland [21] sobre el umbral no ponderado de la Ecuación 6.8; y se convierte el conteo agregado en un *procedimiento a nivel de evento* que recupera, para cada salto detectado, su instante y su magnitud, sobre los cuales se ajusta un modelo de distribución **agregada**, sin requerir identificación del tipo de siniestro (meteorológico o sísmico).

Se trabaja sobre el proceso de reservas $\{U(t)\}_{t \geq 0}$ de la Ecuación 6.5, observado en la malla $t_0 < t_1 < \dots < t_n$ con paso constante $\Delta_n = t_i - t_{i-1}$, sobre N_{sim} trayectorias simuladas independientes $U^{(1)}, \dots, U^{(N_{\text{sim}})}$ (Sección 9.2).

La estimación de la distribución de severidad se realiza directamente a partir de las trayectorias simuladas del proceso de reserva y de los incrementos identificados por el procedimiento de detección de saltos descrito previamente. El procedimiento es común a los esquemas numéricos considerados, por lo que se aplica de manera independiente a las trayectorias obtenidas mediante el método de Milstein compensado y mediante el método semi-implícito compensado.

En particular, la inferencia no paramétrica no utiliza información acerca de la causa física del evento. Por consiguiente, las observaciones utilizadas en esta sección corresponden exclusivamente a los decrementos detectados en las trayectorias agregadas. Las etiquetas utilizadas durante la simulación para distinguir los mecanismos generadores de los saltos,

cuando se dispone de ellas, se reservan exclusivamente para la validación de la capacidad de detección y no intervienen en la construcción de los estimadores.

Sea

$$0 = t_0 < t_1 < \dots < t_n = T, \quad \Delta_n = t_i - t_{i-1}, \quad (6.9)$$

la partición temporal utilizada para la simulación, y sea

$$U^{(j)}(t_i), \quad j = 1, \dots, N_{\text{sim}},$$

la trayectoria j -ésima del proceso de reserva, con $N_{\text{sim}} = 1000$.

La metodología se desarrolla mediante las siguientes etapas: construcción de incrementos relativos, estimación local de la volatilidad, definición del umbral de detección, identificación de incrementos anómalos, extracción de las severidades detectadas, estimación de su distribución empírica y de su densidad mediante KDE, ajuste paramétrico auxiliar y cuantificación de incertidumbre mediante bootstrap por trayectorias.

6.4.2.1. Incrementos relativos y estimación local de la volatilidad

Para cada trayectoria se define el incremento relativo

$$\tilde{r}_{n,i}^{(j)} := \frac{U^{(j)}(t_i) - U^{(j)}(t_{i-1})}{U^{(j)}(t_{i-1})}, \quad i = 1, \dots, n, \quad j = 1, \dots, N_{\text{sim}}. \quad (6.10)$$

Esta normalización permite expresar los cambios de la reserva en términos relativos a su nivel inmediatamente anterior. La estimación de la escala local asociada a la componente continua se obtiene mediante una versión agregada de la variación bipotencia realizada, siguiendo la construcción de variación bipotencia propuesta para separar la variación continua de la contribución de saltos [barndorff2004]. Para una ventana de K observaciones se define

$$\hat{\sigma}^2(t_{i-1}) := \frac{\pi}{2} \frac{1}{K \Delta_n N_{\text{sim}}} \sum_{j=1}^{N_{\text{sim}}} \sum_{k=1}^K \left| \tilde{r}_{n,i-k}^{(j)} \right| \left| \tilde{r}_{n,i-k+1}^{(j)} \right|. \quad (6.11)$$

La correspondiente estimación de la escala local es

$$\hat{\sigma}(t_{i-1}) := \sqrt{\hat{\sigma}^2(t_{i-1})}. \quad (6.12)$$

La agregación sobre las trayectorias es coherente con la implementación numérica, en la cual la componente de difusión utiliza la misma función de volatilidad para las

trayectorias simuladas. En este sentido, el *pooling* permite utilizar conjuntamente las réplicas Monte Carlo para estimar la escala local común. El estimador se emplea como una medida local de escala para distinguir fluctuaciones ordinarias de incrementos cuya magnitud resulta incompatible con la dinámica continua en la escala temporal considerada [barndorff2004].

6.4.2.2. Umbral de detección de saltos

A partir de la estimación local de volatilidad se define el umbral dependiente del tamaño de la malla mediante

$$\tau_n(t_{i-1}) := \alpha \hat{\sigma}(t_{i-1}) \Delta_n^\varpi, \quad \alpha > 0, \quad \varpi \in \left(0, \frac{1}{2}\right). \quad (6.13)$$

La elección del exponente ϖ responde a dos requerimientos asintóticos. En primer lugar,

$$\Delta_n^\varpi \rightarrow 0 \quad \text{cuando} \quad \Delta_n \rightarrow 0, \quad (6.14)$$

mientras que

$$\frac{\Delta_n^\varpi}{\sqrt{\Delta_n}} = \Delta_n^{\varpi - \frac{1}{2}} \rightarrow \infty. \quad (6.15)$$

Por consiguiente, el umbral tiende a cero, pero lo hace más lentamente que la escala de las fluctuaciones continuas de orden $\sqrt{\Delta_n}$. Esta propiedad constituye la base de los procedimientos de detección por umbral: bajo las condiciones de regularidad apropiadas, permite separar incrementos asociados a saltos de las fluctuaciones producidas por la componente continua [23].

Para eliminar, en la medida de lo posible, la contribución regular de la dinámica de la reserva, se define el residuo relativo

$$\tilde{e}_{n,i}^{(j)} := \tilde{r}_{n,i}^{(j)} - \left[\frac{c(t_{i-1})}{U^{(j)}(t_{i-1})} + r(t_{i-1}) \right] \Delta_n. \quad (6.16)$$

El conjunto de índices identificados como detecciones en la trayectoria j se define entonces mediante

$$D^{(j)} := \left\{ i \in \{1, \dots, n\} : |\tilde{e}_{n,i}^{(j)}| > \tau_n(t_{i-1}) \right\}. \quad (6.17)$$

La condición anterior constituye el criterio principal de detección utilizado en los programas de simulación. La construcción es consistente con los procedimientos de detección no paramétrica por umbral desarrollados para procesos observados discretamente [leemykland2008, 23].

Proposición 6.1. *Bajo el esquema de detección anterior, la clasificación de un incremento como evento detectado depende únicamente de la trayectoria observada, del estimador local de escala y de los parámetros (α, ϖ) . En consecuencia, el procedimiento es aplicable tanto a las trayectorias simuladas como, una vez observadas las variables correspondientes, a datos empíricos en los cuales no se disponga de información sobre la causa física del evento.*

6.4.2.3. Estadístico normalizado para diagnóstico

Como medida complementaria para caracterizar la magnitud relativa de los incrementos se utiliza el estadístico normalizado

$$\mathcal{L}_i^{(j)} := \frac{\tilde{r}_{n,i}^{(j)}}{\hat{\sigma}(t_{i-1})}. \quad (6.18)$$

Bajo ausencia de saltos y bajo las condiciones de regularidad requeridas por la aproximación asintótica correspondiente, este estadístico permite utilizar una escala aproximadamente gaussiana como referencia para evaluar la magnitud de las fluctuaciones. La construcción de estadísticas normalizadas para detectar saltos en procesos observados discretamente está relacionada con el procedimiento de Lee–Mykland [leemykland2008].

En particular, las cantidades asociadas a la aproximación de falsos positivos deben interpretarse como medidas diagnósticas y no como probabilidades exactas de error de clasificación para el procedimiento completo.

6.4.2.3.1. Extracción de las severidades detectadas

Una vez identificado el conjunto $D^{(j)}$, se obtiene para cada índice detectado una estimación de la magnitud monetaria del decremento residual. Para ello se define

$$\widehat{Y}_i^{(j)} := -\tilde{e}_{n,i}^{(j)} U^{(j)}(t_{i-1}), \quad i \in D^{(j)}. \quad (6.19)$$

Se conservan únicamente las observaciones que satisfacen

$$\widehat{Y}_i^{(j)} > 0. \quad (6.20)$$

La cantidad $\widehat{Y}_i^{(j)}$ debe interpretarse como una **severidad detectada**: representa la magnitud monetaria del decremento residual que el procedimiento atribuye al intervalo $(t_{i-1}, t_i]$.

Esta distinción es importante porque la detección se realiza sobre una trayectoria discretizada. Si varios saltos físicos ocurren dentro de un mismo intervalo de discretización, el procedimiento opera sobre el incremento agregado de dicho intervalo y, por tanto, una única observación $\widehat{Y}_i^{(j)}$ puede representar la contribución conjunta de varios eventos no resolubles temporalmente en la malla utilizada.

En consecuencia, sea

$$\mathcal{Y} := \left\{ \widehat{Y}_i^{(j)} : j = 1, \dots, N_{\text{sim}}, i \in D^{(j)}, \widehat{Y}_i^{(j)} > 0 \right\}, \quad (6.21)$$

y sea $N_Y := |\mathcal{Y}|$ el número total de severidades detectadas. La inferencia de esta sección se realiza sobre la distribución agregada de $\mathcal{Y}$.

Definición 6.4. La función de distribución de severidad detectada se define por

$$F_Y(y) := \mathbb{P}(\widehat{Y} \leq y \mid D = 1), \quad (6.22)$$

donde $D = 1$ indica que el incremento fue clasificado como una detección válida por el procedimiento definido en Ecuación 6.17 y que la severidad satisface Ecuación 6.20.

6.4.2.4. Sensibilidad respecto de los parámetros del detector

El procedimiento depende de los parámetros α y ϖ . Por esta razón, antes de fijar los valores utilizados para la comparación entre los métodos numéricos se realiza un análisis de sensibilidad sobre una malla de valores candidatos.

Para una combinación (α, ϖ) se registra el número de detecciones y, cuando corresponde, las estadísticas descriptivas asociadas. La tasa media de detección se expresa como

$$R(\alpha, \varpi) := \frac{N_{\text{det}}(\alpha, \varpi)}{N_{\text{sim}}}, \quad (6.23)$$

donde $N_{\text{det}}(\alpha, \varpi)$ representa el número medio de detecciones por trayectoria bajo la combinación considerada.

6.4.2.5. Función de distribución empírica de las severidades

La estimación no paramétrica de la función de distribución de severidad se realiza mediante la función de distribución empírica asociada al conjunto $\mathcal{Y}$ definido en Ecuación 6.21. Esta representación evita imponer una familia paramétrica para la distribución de severidades [1]. Sea $Y_1, \dots, Y_{N_Y}$ una enumeración de dicho conjunto. Entonces,

$$\widehat{F}_Y(y) = \frac{1}{N_Y} \sum_{\ell=1}^{N_Y} \mathbf{1}_{\{Y_\ell \leq y\}}. \quad (6.24)$$

La función $\widehat{F}_Y$ constituye el estimador no paramétrico principal de la distribución de severidad detectada. No requiere especificar una familia paramétrica para la distribución subyacente.

La comparación entre los métodos numéricos se realiza utilizando las funciones empíricas obtenidas a partir de sus respectivas colecciones de severidades detectadas. Las diferencias entre ambas funciones deben interpretarse como diferencias en la distribución de las severidades recuperadas por el procedimiento de detección aplicado a cada esquema numérico.

6.4.2.6. Estimación no paramétrica de la densidad mediante KDE en escala logarítmica

Dado que las severidades son positivas y pueden presentar asimetría y colas derechas, la densidad se estima mediante una transformación logarítmica. Sea

$$Z_\ell := \log(Y_\ell), \quad \ell = 1, \dots, N_Y. \quad (6.25)$$

Sobre la escala transformada se utiliza un estimador de densidad por núcleo. La estimación de densidades mediante métodos de núcleo constituye una técnica no paramétrica estándar; su formulación y propiedades generales pueden consultarse en Silverman [silverman1986].

$$\widehat{f}_Z(z) = \frac{1}{N_Y h} \sum_{\ell=1}^{N_Y} K\left(\frac{z - Z_\ell}{h}\right), \quad (6.26)$$

donde K es una función núcleo y $h > 0$ es el ancho de banda.

Por la transformación $z = \log(y)$, se tiene

$$\frac{dz}{dy} = \frac{1}{y}, \quad y > 0. \quad (6.27)$$

Por consiguiente, la densidad estimada sobre la escala original de las severidades es

$$\hat{f}_Y(y) = \frac{1}{y} \hat{f}_Z(\log y), \quad y > 0. \quad (6.28)$$

Esta transformación es la que corresponde a la implementación computacional. La estimación KDE constituye una representación suavizada de la densidad asociada a la distribución empírica, mientras que Ecuación 6.24 continúa siendo el estimador no paramétrico directo de la función de distribución.

6.4.2.7. Ajustes paramétricos auxiliares de la distribución de severidad

Con el propósito de disponer de representaciones paramétricas de referencia, se ajustan mediante máxima verosimilitud las distribuciones Lognormal, Gamma y Weibull. Estos modelos se consideran únicamente como familias auxiliares para describir la muestra detectada y comparar representaciones paramétricas. Estos ajustes son complementarios a la estimación no paramétrica y no implican que alguna de las familias consideradas constituya el mecanismo generador verdadero de las severidades.

Para la distribución Lognormal se utiliza

$$f(y; \mu, \sigma) = \frac{1}{y\sigma\sqrt{2\pi}} \exp \left[-\frac{(\log y - \mu)^2}{2\sigma^2} \right], \quad y > 0. \quad (6.29)$$

Para la distribución Gamma,

$$f(y; k, \theta) = \frac{1}{\Gamma(k)\theta^k} y^{k-1} e^{-y/\theta}, \quad y > 0, \quad (6.30)$$

y para la distribución Weibull,

$$f(y; k, \theta) = \frac{k}{\theta} \left(\frac{y}{\theta} \right)^{k-1} \exp \left[-\left(\frac{y}{\theta} \right)^k \right], \quad y > 0. \quad (6.31)$$

Sea $\hat{\ell}$ el valor máximo de la log-verosimilitud y sea p el número de parámetros estimados. El criterio de información de Akaike, introducido como una medida de selección de modelos basada en información, se define mediante [3]

$$AIC = 2p - 2\hat{\ell}. \quad (6.32)$$

El AIC se utiliza exclusivamente como criterio de comparación entre las familias paramétricas consideradas, de acuerdo con el propósito original del criterio de Akaike [3]. La estimación no paramétrica de Ecuación 6.24 y Ecuación 6.28 no depende de seleccionar una de estas familias.

6.4.2.8. Incertidumbre mediante bootstrap por trayectoria

Debido a que varias detecciones pueden proceder de una misma trayectoria, las observaciones de severidad no se consideran automáticamente independientes. Para preservar la estructura de dependencia intra-trayectoria, el procedimiento bootstrap se realiza remuestreando trayectorias completas. El uso del bootstrap para cuantificar incertidumbre sigue la formulación general de Efron y Tibshirani [efrontibshirani1993].

En cada réplica bootstrap se seleccionan N_{sim} trayectorias con reemplazo y se reconstruye el conjunto de severidades detectadas correspondiente a la muestra remuestreada. Para un estadístico θ de interés, se obtiene una colección

$$\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)}, \quad (6.33)$$

donde B es el número de réplicas bootstrap.

El intervalo percentil de nivel de confianza $1 - \gamma$ se define mediante

$$IC_{1-\gamma} = [\hat{\theta}^{(\gamma/2)}, \hat{\theta}^{(1-\gamma/2)}], \quad (6.34)$$

donde $\hat{\theta}^{(q)}$ representa el cuantil q de la distribución empírica de las réplicas bootstrap.

Estos intervalos cuantifican la variabilidad asociada al muestreo de las trayectorias bajo el procedimiento de detección y los parámetros (α, ϖ) fijados. No incorporan incertidumbre adicional derivada de una eventual selección de estos parámetros.

6.4.3. Distribución de los tiempos entre saltos detectados

En esta sección se estudia la distribución de los tiempos entre detecciones, así como la intensidad temporal de los eventos detectados.

El procedimiento de estimación opera sobre la información disponible en las trayectorias discretizadas; por tanto, los tiempos utilizados en esta sección son los tiempos de los incrementos clasificados como detecciones por el criterio de Ecuación 6.17.

6.4.3.1. Tiempos de detección y proceso de conteo

Para cada trayectoria j , sean

$$\tau_k^{(j)} := t_{i_k}, \quad k = 1, \dots, K_j, \quad (6.35)$$

los tiempos correspondientes a los índices $i_k \in D^{(j)}$, ordenados de manera creciente. Aquí K_j denota el número de detecciones de la trayectoria j .

El proceso de conteo de detecciones se define por

$$N^{(j)}(t) := \# \left\{ k : \tau_k^{(j)} \leq t \right\}, \quad t \in [0, T]. \quad (6.36)$$

Este proceso cuenta exclusivamente los eventos que han sido identificados por el detector y constituye la base para el análisis de intensidad y de tiempos entre detecciones. La formulación mediante procesos de conteo es el marco natural para describir tiempos de ocurrencia y sus intensidades [andersen1993, 1].

6.4.3.2. Intensidad temporal no paramétrica

Debido a la periodicidad anual incorporada en la estructura temporal del modelo, la intensidad de las detecciones se estima mediante un suavizamiento de núcleo sobre un dominio periódico.

Sea $P = 365$ el periodo anual expresado en días. Para $t, \tau \in [0, P)$ se define la distancia circular

$$d_{\text{circ}}(t, \tau) := \min \{ |t - \tau|, P - |t - \tau| \}. \quad (6.37)$$

Sea $h > 0$ el ancho de banda. El estimador de intensidad por núcleo circular utilizado en la implementación es

$$\hat{\lambda}_h(t) = \frac{1}{N_{\text{sim}} h} \sum_{j=1}^{N_{\text{sim}}} \sum_{k=1}^{K_j} K \left(\frac{d_{\text{circ}}(t, \tau_k^{(j)})}{h} \right). \quad (6.38)$$

El factor $1/N_{\text{sim}}$ produce una intensidad media por trayectoria, mientras que el factor $1/h$ corresponde a la normalización del estimador de núcleo.

La ecuación Ecuación 6.38 representa el estimador efectivamente utilizado en los programas. Su construcción pertenece a la familia de estimadores de intensidad por núcleo [26]. Por tanto, no se identifica este estimador con el estimador clásico de Nelson–Aalen.

6.4.3.3. Análisis de sensibilidad del ancho de banda

El ancho de banda h controla el grado de suavizamiento de la intensidad estimada. Valores pequeños permiten identificar variaciones temporales más localizadas, mientras que valores grandes producen una representación más suave. Este compromiso entre suavizamiento y variabilidad es inherente a los estimadores de intensidad por núcleo [26].

Para evaluar la estabilidad de la estructura temporal, se consideran distintos valores de h , incluyendo los utilizados en la implementación computacional. La comparación de las curvas $\hat{\lambda}_h(t)$ permite determinar si las características estacionales principales permanecen estables frente a cambios razonables en el nivel de suavizamiento.

Este análisis se interpreta como un estudio de sensibilidad y no como un procedimiento automático de selección óptima del ancho de banda.

6.4.3.4. Tiempos entre detecciones

Para cada trayectoria con al menos dos detecciones se define el tiempo entre detecciones consecutivas mediante

$$\Delta\tau_k^{(j)} := \tau_k^{(j)} - \tau_{k-1}^{(j)}, \quad k = 2, \dots, K_j. \quad (6.39)$$

La colección de todas las cantidades $\Delta\tau_k^{(j)}$ constituye la muestra utilizada para caracterizar la distribución marginal de los tiempos entre detecciones.

En el caso particular de un proceso de Poisson homogéneo con intensidad constante λ , los tiempos entre eventos son variables aleatorias independientes con distribución exponencial. Esta propiedad es un resultado fundamental de la teoría de procesos de conteo y de la teoría de renovación [andersen1993].

$$\Delta\tau \sim \text{Exp}(\lambda). \quad (6.40)$$

Por el contrario, cuando la intensidad depende del tiempo, los tiempos en la escala cronológica original no tienen, en general, una distribución exponencial con parámetro constante. Por esta razón, la comparación con una distribución exponencial debe entenderse como una hipótesis de referencia correspondiente al caso homogéneo.

6.4.3.5. Distribuciones paramétricas de referencia

Para describir de manera complementaria la distribución de los tiempos entre detecciones se consideran las familias Exponencial, Weibull y Gamma.

La densidad exponencial está dada por

$$f(x; \lambda) = \lambda e^{-\lambda x}, \quad x > 0, \quad \lambda > 0. \quad (6.41)$$

La densidad Weibull se define mediante

$$f(x; k, \theta) = \frac{k}{\theta} \left(\frac{x}{\theta}\right)^{k-1} \exp \left[-\left(\frac{x}{\theta}\right)^k \right], \quad x > 0. \quad (6.42)$$

La densidad Gamma está dada por

$$f(x; k, \theta) = \frac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-x/\theta}, \quad x > 0. \quad (6.43)$$

Los parámetros de las tres familias se estiman mediante máxima verosimilitud incorporando el tratamiento de censura descrito en la siguiente sección.

6.4.3.6. Censura administrativa por la derecha

El horizonte de observación es finito y está dado por $[0, T]$. Si una trayectoria presenta una última detección en $\tau_{K_j}^{(j)}$ y no se observa una detección posterior antes de T , el tiempo entre esta última detección y el siguiente evento es desconocido. Por tanto, no debe tratarse como una observación completa.

El tiempo observado hasta el final del horizonte se define mediante

$$c^{(j)} := T - \tau_{K_j}^{(j)}. \quad (6.44)$$

Esta cantidad constituye una observación censurada por la derecha del siguiente tiempo entre eventos.

La inclusión explícita de estas observaciones evita introducir artificialmente un último tiempo entre detecciones igual al intervalo restante hasta T .

6.4.3.7. Estimación descriptiva de la supervivencia

La función de supervivencia de los tiempos entre detecciones se define como

$$S(x) := \mathbb{P}(\Delta\tau > x). \quad (6.45)$$

Para representar descriptivamente esta función bajo la presencia de observaciones censuradas se utiliza el estimador de Kaplan–Meier, introducido por Kaplan y Meier para la estimación no paramétrica bajo observaciones incompletas [kaplanmeier1958].

El estimador de Kaplan–Meier permite conservar la información proporcionada por las observaciones censuradas sin considerarlas como eventos completos. En este contexto, su interpretación es descriptiva y se refiere a la distribución marginal de los tiempos entre detecciones.

Debe señalarse que las detecciones sucesivas de una misma trayectoria pueden presentar dependencia temporal. El marco de procesos de conteo y análisis de supervivencia permite formular explícitamente esta estructura [andersen1993, 1]. Por esta razón, la utilización de Kaplan–Meier no implica que la colección de todos los gaps constituya una muestra independiente e idénticamente distribuida. La estimación se emplea como herramienta descriptiva para caracterizar la supervivencia marginal.

6.4.3.8. Máxima verosimilitud con observaciones censuradas

Sea $f(x; \theta)$ la densidad de una familia paramétrica de tiempos entre detecciones y sea

$$S(x; \theta) = 1 - F(x; \theta)$$

su función de supervivencia.

Si $\Delta\tau_i$ representa una observación completa y c_j una observación censurada por la derecha, la contribución de una observación completa a la verosimilitud es

$$L_i(\theta) = f(\Delta\tau_i; \theta), \quad (6.46)$$

mientras que la contribución de una observación censurada es

$$L_j^{\text{cens}}(\theta) = S(c_j; \theta). \quad (6.47)$$

Por tanto, la log-verosimilitud correspondiente a la muestra completa es

$$\ell(\theta) = \sum_{\text{completos}} \log f(\Delta\tau_i; \theta) + \sum_{\text{censurados}} \log S(c_j; \theta). \quad (6.48)$$

Los estimadores de máxima verosimilitud se obtienen mediante

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta). \quad (6.49)$$

Esta formulación se aplica por separado a las familias Exponencial, Weibull y Gamma consideradas en Ecuación 6.41, Ecuación 6.42 y Ecuación 6.43. La contribución $S(c_j; \theta)$ de una observación censurada es la forma estándar de incorporar a la verosimilitud la información de que el tiempo de espera excede el último intervalo observado [kaplanmeier1958, andersen1993].

6.4.3.9. Comparación mediante el criterio de información de Akaike

Para comparar los modelos paramétricos ajustados se utiliza el criterio de información de Akaike [3],

$$AIC = 2p - 2\hat{\ell}, \quad (6.50)$$

donde p es el número de parámetros libres del modelo y $\hat{\ell}$ es el valor máximo de la log-verosimilitud censurada.

El AIC proporciona una medida relativa de ajuste penalizada por complejidad dentro del conjunto de modelos considerados. Su utilización no demuestra que alguno de los modelos sea el verdadero mecanismo generador de los tiempos entre detecciones; únicamente permite comparar las representaciones paramétricas consideradas bajo el mismo conjunto de observaciones y tratamiento de censura.

6.4.3.10. Coeficiente de variación al cuadrado

Una medida descriptiva adicional de la dispersión relativa de los tiempos entre detecciones es el coeficiente de variación al cuadrado,

$$CV^2 := \frac{\text{Var}(\Delta\tau)}{[\mathbb{E}(\Delta\tau)]^2}. \quad (6.51)$$

Para una distribución exponencial,

$$CV^2 = 1. \quad (6.52)$$

Por consiguiente, el valor de CV^2 puede utilizarse como indicador descriptivo de la dispersión relativa. Sin embargo, una diferencia respecto de uno no constituye por sí misma una prueba formal de no-Poissonidad, debido a que la distribución de los tiempos entre eventos también puede estar afectada por heterogeneidad temporal de la intensidad, dependencia entre eventos, censura y el propio procedimiento de detección.

6.4.3.11. Teorema de cambio de tiempo

Sea $N(t)$ un proceso de conteo simple con intensidad condicional $\lambda(t \mid \mathcal{F}_{t-})$ y compensador

$$\Lambda(t) := \int_0^t \lambda(s \mid \mathcal{F}_{s-}) \, ds. \quad (6.53)$$

Bajo las condiciones del teorema de cambio de tiempo para procesos puntuales, si τ_k y τ_{k-1} son tiempos de eventos consecutivos, los incrementos del tiempo transformado se definen mediante

$$s_k := \Lambda(\tau_k) \quad (6.54)$$

y

$$\Delta s_k := s_k - s_{k-1} = \Lambda(\tau_k) - \Lambda(\tau_{k-1}). \quad (6.55)$$

Teorema 6.6. Teorema (cambio de tiempo). *Bajo las condiciones de regularidad del teorema de cambio de tiempo y utilizando el compensador verdadero del proceso puntual, los incrementos transformados Ecuación 6.55 presentan distribución exponencial unitaria [7]. La formulación del cambio de tiempo para procesos puntuales también constituye la base de los procedimientos de análisis de residuos de procesos de eventos desarrollados en la literatura de procesos de conteo.*

$$\Delta s_k \sim \text{Exp}(1). \quad (6.56)$$

En consecuencia, mediante la transformación de la distribución exponencial a la uniforme,

$$u_k = 1 - e^{-\Delta s_k}, \quad (6.57)$$

se obtiene

$$u_k \sim \text{Uniforme}(0, 1). \quad (6.58)$$

Demostración. *El resultado se obtiene aplicando el teorema de cambio de tiempo al proceso puntual con intensidad condicional $\lambda(t \mid \mathcal{F}_{t-})$ [7]. La transformación mediante el compensador verdadero convierte el proceso en una escala temporal en la cual los eventos presentan intensidad unitaria. Por tanto, los incrementos entre eventos consecutivos siguen una distribución exponencial de parámetro uno. Finalmente, si $E \sim \text{Exp}(1)$, entonces $1 - e^{-E} \sim \text{Uniforme}(0, 1)$. $\square$*

6.4.3.12. Diagnóstico de cambio de tiempo mediante la intensidad estimada

En la aplicación computacional, la intensidad verdadera $\lambda(t)$ y su compensador $\Lambda(t)$ no se conocen. Por ello, el procedimiento sustituye el compensador verdadero por uno obtenido a partir de la intensidad estimada mediante Ecuación 6.38.

Se define numéricamente

$$\widehat{\Lambda}(t) := \int_0^t \widehat{\lambda}_h(s) ds, \quad (6.59)$$

o, en la implementación sobre una malla temporal, mediante la correspondiente aproximación discreta de la integral.

Los incrementos transformados estimados son entonces

$$\widehat{\Delta s}_k = \widehat{\Lambda}(\tau_k) - \widehat{\Lambda}(\tau_{k-1}). \quad (6.60)$$

A partir de ellos se construye

$$\widehat{u}_k = 1 - e^{-\widehat{\Delta s}_k}. \quad (6.61)$$

Si el modelo de intensidad utilizado para construir $\widehat{\lambda}_h$ describe adecuadamente la estructura temporal de las detecciones y la estimación del compensador es suficientemente precisa, los valores $\widehat{u}_k$ deberían presentar un comportamiento compatible con una distribución uniforme.

Es fundamental distinguir este procedimiento del teorema anterior: la propiedad exacta $\Delta s_k \sim \text{Exp}(1)$ corresponde al compensador verdadero Λ , mientras que $\widehat{\Delta s}_k$ constituye un diagnóstico basado en un compensador estimado. La interpretación como diagnóstico de especificación mediante tiempo reescalado sigue la literatura de análisis de procesos puntuales [7].

Como medida descriptiva de discrepancia se registra el estadístico D de Kolmogorov–Smirnov,

$$D := \sup_{0 \leq u \leq 1} \left| \widehat{F}_{\widehat{u}}(u) - u \right|, \quad (6.62)$$

donde $\widehat{F}_{\widehat{u}}$ es la función de distribución empírica de los valores $\widehat{u}_k$.

En la implementación considerada, este estadístico se utiliza como diagnóstico descriptivo. No se interpreta como un p-valor exacto de una prueba clásica de uniformidad, debido a que la intensidad utilizada para construir los residuos ha sido estimada a partir de los mismos datos.

6.4.3.13. Incertidumbre mediante bootstrap por trayectoria

La incertidumbre de las estadísticas descriptivas de los tiempos entre detecciones se cuantifica mediante bootstrap por trayectoria, siguiendo el principio general de remuestreo para inferencia estadística [efrontibshirani1993]. En cada réplica se seleccionan con reemplazo trayectorias completas y se reconstruye la colección correspondiente de tiempos entre detecciones y de observaciones censuradas.

Para un estadístico θ , como la media, mediana o CV^2 , se obtiene

$$\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)}. \quad (6.63)$$

El intervalo percentil de nivel $1 - \gamma$ se define por

$$IC_{1-\gamma} = [\hat{\theta}^{(\gamma/2)}, \hat{\theta}^{(1-\gamma/2)}]. \quad (6.64)$$

El remuestreo de trayectorias completas preserva, en la medida permitida por el esquema bootstrap, la dependencia temporal existente entre las detecciones de una misma trayectoria y evita tratar cada gap como una observación independiente por construcción.

6.4.3.14. Validación mediante información conocida en la simulación

Al igual que en el análisis de severidades, la simulación permite conservar información sobre los tiempos de los eventos generados por el mecanismo conocido. Esta información puede utilizarse para evaluar la capacidad del detector para recuperar la estructura temporal subyacente.

Esta comparación constituye una validación *oracle* y no participa en la estimación de $\hat{\lambda}_h$, en la construcción de la distribución de $\Delta\tau$, en la estimación de los modelos paramétricos ni en el cálculo de los intervalos bootstrap.

Por tanto, el procedimiento de inferencia permanece basado exclusivamente en las detecciones obtenidas a partir de las trayectorias simuladas, reproduciendo la situación de aplicación a datos reales en la cual únicamente se dispone de la trayectoria observada y no de la causa física ni del instante verdadero de cada salto no observado.

7 Métodos Numéricos para EDE

7.1. Introducción a la Discretización de EDE con difusión y salto.

Las Ecuaciones Diferenciales Estocásticas (EDE) constituyen una herramienta fundamental en la modelización matemática de fenómenos dinámicos sometidos a incertidumbre. En particular, las ecuaciones diferenciales estocásticas con saltos, por sus siglas en inglés Jump-Diffusion Stochastic Differential Equations que denotaremos de ahora en adelante por (EDSEJ) extienden el marco clásico de difusión (dominado por el movimiento browniano) al incorporar procesos de Lévy o procesos de Poisson compuestos, lo que permite capturar discontinuidades abruptas, eventos extremos o choques externos.

A pesar del sólido desarrollo teórico existente en torno a la existencia, unicidad y propiedades cualitativas de soluciones de EDSEJs, la obtención de soluciones explícitas es usual. Por ello, los métodos numéricos se vuelven indispensables tanto para la simulación como para el análisis cuantitativo de estos modelos. Sin embargo, la presencia simultánea de componentes de difusión continua y saltos discontinuos introduce desafíos computacionales y teóricos sustanciales que no están presentes en el caso puramente difusivo.

Las ecuaciones diferenciales estocásticas (SDEs) con saltos constituyen una clase fundamental de modelos en finanzas matemáticas, teoría de seguros y dinámica de poblaciones. La forma general de una SDE con saltos en $\mathbb{R}^d$ es:

$$\begin{aligned} X_t = X_0 &+ \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dW_s + \int_0^t \int_E R(s, X_{s-}, v) \tilde{p}_\phi(dv, ds) \\ &+ \int_0^t \int_E R(s, X_{s-}, v) \nu(dv) ds, \end{aligned} \quad (7.1)$$

donde:

- $a : [0, T] \times \mathbb{R} \rightarrow \mathbb{R}$ es el coeficiente de deriva (drift),
- $b : [0, T] \times \mathbb{R} \rightarrow \mathbb{R}$ es el coeficiente de difusión,
- $W = \{W_t\}_{t \geq 0}$ es un proceso de Wiener, - p_ϕ es una medida aleatoria de Poisson con intensidad $\nu(dv)dt$,

- $\tilde{p}_\phi(dv, ds) = p_\phi(dv, ds) - \nu(dv)ds$ es la medida de Poisson compensada,
- $R : [0, T] \times \mathbb{R} \times E \rightarrow \mathbb{R}$ describe la magnitud de los saltos,
- $E \subseteq \mathbb{R}^k \setminus \{0\}$ es el espacio de marcas (marks).

La SDE con saltos compensados es:

$$dX_t = \underbrace{a(t, X_t) dt}_{\text{drift original}} + \underbrace{b(t, X_t) dW_t}_{\text{difusión}} + \underbrace{\int_E R(t, X_{t-}, v) \tilde{p}_\phi(dv, dt)}_{\text{saltos compensados}}$$

donde la medida compensada es:

$$\tilde{p}_\phi(dv, dt) = p_\phi(dv, dt) - \phi(dv) dt$$

Al expandir la integral con la medida compensada, obtenemos:

$$\int_E R(t, X_{t-}, v) \tilde{p}_\phi(dv, dt) = \underbrace{\int_E R(t, X_{t-}, v) p_\phi(dv, dt)}_{\text{saltos brutos}} - \underbrace{\int_E R(t, X_{t-}, v) \phi(dv) dt}_{\text{compensación}}$$

Por lo tanto, la EDE completa se puede escribir como:

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t + \int_E R(t, X_{t-}, v) p_\phi(dv, dt) - \int_E R(t, X_{t-}, v) \phi(dv) dt$$

Para discretizar esta ecuación, reorganizamos los términos de la siguiente manera:

$$dX_t = \underbrace{\left[a(t, X_t) - \int_E R(t, X_{t-}, v) \phi(dv) \right] dt}_{\text{drift compensado}} + b(t, X_t) dW_t + \int_E R(t, X_{t-}, v) p_\phi(dv, dt)$$

El término de compensación cambia de signo al moverse al drift, porque:

$$a(t, X_t) dt - \int_E R(t, X_{t-}, v) \phi(dv) dt = \left[a(t, X_t) - \int_E R(t, X_{t-}, v) \phi(dv) \right] dt$$

7.1.1. Formulación general del modelo de Cramér–Lundberg con reinversión como EDESJ.

El modelo de Cramér–Lundberg extendido con reinversión y parámetros temporales puede escribirse como una ecuación diferencial estocástica con saltos (EDE). Consideremos la siguiente ecuación diferencial estocástica con saltos (EDE):

$$dX_t = \underbrace{c(t) dt}_{\text{primas}} + \underbrace{r(t) X_t dt}_{\text{rendimiento}} + \underbrace{\sigma(t) X_t dW_t}_{\text{volatilidad}} - \underbrace{\int_E R(t, X_{t-}, v) \tilde{p}_\phi(dv, dt)}_{\text{saltos compensados}}, \quad (7.2)$$

donde

- $c(t) \in \mathbb{R}$ es un flujo de primas determinista y acotado,
- $r(t), \sigma(t)$ son funciones acotadas y medibles,
- $R(t, x, v)$ es la magnitud del salto, dependiente del tiempo t , del estado x y de la marca v , - $\tilde{p}_\phi(dv, dt) = p_\phi(dv, dt) - \phi(dv)dt$ es la medida de Poisson compensada, - $\phi(E) < \infty$ y $\int_E |R(t, x, v)|^2 \phi(dv) < \infty$ para todo $t \in [0, T]$, $x \in \mathbb{R}$.

7.2. Esquema de Milstein

Sea la ecuación diferencial estocástica con saltos:

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t + \int_E R(t, X_{t-}, v) p_\phi(dv, dt), \quad (1)$$

donde p_ϕ es la medida aleatoria de Poisson con intensidad $\phi(dv)dt$.

La discretización de Milstein **sin compensación** se define como:

$$\begin{aligned} Y_{n+1} = & Y_n + a(t_n, Y_n) \Delta t \\ & + b(t_n, Y_n) \Delta W_n \\ & + \frac{1}{2} b(t_n, Y_n) b_x(t_n, Y_n) [(\Delta W_n)^2 - \Delta t] \\ & + \sum_{i=1}^{\Delta N_n} R(t_n, Y_n, \xi_i), \end{aligned}$$

con:

- $\Delta t = t_{n+1} - t_n$ paso de tiempo,
- $\Delta W_n \sim \mathcal{N}(0, \Delta t)$ incremento browniano,
- $\Delta N_n \sim \text{Poisson}(\lambda \Delta t)$, $\lambda = \phi(E)$, número de saltos en el intervalo,
- $\xi_i \stackrel{\text{i.i.d.}}{\sim} \phi(dv)/\lambda$ marcas de los saltos,
- $b_x = \partial b / \partial x$ derivada del coeficiente de difusión,
- $a(t, x)$ y $b(t, x)$ coeficientes de deriva y difusión.

Teorema 7.1. (Convergencia fuerte de orden $\gamma = 1/2$). Bajo las hipótesis:

1. **Lipschitz global:** $|a(t, x_1) - a(t, x_2)| \leq L_a |x_1 - x_2|$, análogo para b y R .
2. **Crecimiento lineal:** $|a| + |b| + (\int_E |R|^2 \phi)^{1/2} \leq K(1 + |x|)$.
3. **Momentos finitos:** $\int_E |R(t, x, v)|^4 \phi(dv) < \infty$.
4. **Condiciones iniciales:** $\mathbb{E}[|X_0|^2] < \infty$, $Y_0 = X_0$.

7.3. Esquema de Milstein Compensado

Sea Y_n la aproximación numérica dada por el esquema Milstein compensado:

$$\begin{aligned}
 Y_{n+1} = Y_n &+ \left[a(t_n, Y_n) - \int_E R(t_n, Y_n, v) \phi(dv) \right] \Delta t \\
 &+ b(t_n, Y_n) \Delta W_n \\
 &+ \frac{1}{2} b(t_n, Y_n) b_x(t_n, Y_n) [(\Delta W_n)^2 - \Delta t] \\
 &+ \sum_{i=1}^{\Delta N_n} R(t_n, Y_n, \xi_i),
 \end{aligned} \tag{7.3}$$

- $\Delta t = t_{n+1} - t_n$ es el paso de tiempo,
- $\Delta W_n \sim \mathcal{N}(0, \Delta t)$ es el incremento del proceso de Wiener,
- $\Delta N_n \sim \text{Poisson}(\lambda \Delta t)$, $\lambda = \phi(E)$, es el número de saltos en el intervalo,
- $\xi_i \stackrel{\text{i.i.d.}}{\sim} \phi(dv)/\lambda$ son las marcas de los saltos,
- $b_x = \partial b / \partial x$ es la derivada parcial del coeficiente de difusión,
- $a(t, x) = c(t) + r(t)x$ y $b(t, x) = \sigma(t)x$.

(Convergencia fuerte de orden $\gamma = 1/2$). Supongamos las siguientes hipótesis:

1. **Lipschitz global:** Los coeficientes $a(t, x)$ y $b(t, x)$ son globalmente Lipschitz en x , y $c(t, x, v)$ es globalmente Lipschitz en x uniformemente en t y v :

$$|c(t, x_1, v) - c(t, x_2, v)| \leq L_c |x_1 - x_2|, \quad \forall t \in [0, T], x_1, x_2 \in \mathbb{R}, v \in E.$$

2. **Crecimiento lineal:** Existe $K > 0$ tal que

$$|a(t, x)| + |b(t, x)| + \left(\int_E |R(t, x, v)|^2 \phi(dv) \right)^{1/2} \leq K(1 + |x|),$$

para todo $t \in [0, T]$ y $x \in \mathbb{R}$.

3. **Momentos finitos de saltos:** $\int_E |R(t, x, v)|^4 \phi(dv) < \infty$ para todo $t \in [0, T]$ y $x \in \mathbb{R}$.
4. **Condiciones iniciales:** $\mathbb{E}[|X_0|^2] < \infty$ y $Y_0 = X_0$. Entonces, existe una constante $C > 0$, independiente de dt , tal que:

$$\max_{0 \leq n \leq N} \left(\mathbb{E} [|X_{t_n} - Y_n|^2] \right)^{1/2} \leq C \sqrt{dt}. \tag{7.4}$$

Es decir, el esquema converge fuertemente con orden $\gamma = 1/2$.

Demostración. La EDE Ecuación 7.2 puede reescribirse en la forma estándar Platen y Bruti-Liberati [24], Ec. (1.8.2):

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t + \int_E R(t, X_{t-}, v) p_\phi(dv, dt), \quad (7.5)$$

donde:

- $a(t, x) = c(t) + r(t)x$ (drift original),
- $b(t, x) = \sigma(t)x$,
- $R(t, x, v)$ es el tamaño del salto bruto, dependiente del estado. Las hipótesis de Lipschitz y crecimiento lineal garantizan que los coeficientes satisfacen las condiciones del Teorema 1.9.3 de Platen y Bruti-Liberati [24], que establece la existencia y unicidad de una solución fuerte X_t .

Además, el Teorema 1.9.3 garantiza que la solución tiene momentos finitos de segundo orden:

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t|^2 \right] \leq C_1 (1 + \mathbb{E}[|X_0|^2]) < \infty. \quad (7.6)$$

El esquema Ecuación 7.3 incluye la corrección de Milstein, que corresponde a truncar la expansión estocástica de Wagner-Platen (ver Platen y Bruti-Liberati [24], Ec. (4.4.7)) después de los términos de orden $\mathcal{O}((dt)^{3/2})$.

Para una SDE con saltos, la expansión completa incluye términos adicionales relacionados con la medida de Poisson. Como el modelo es aditivo en los saltos (aunque $c(t, x, v)$ depende de x , no hay términos cruzados de orden superior), los operadores de salto y difusión conmutan trivialmente, lo que simplifica el análisis.

El error local $R_n = X_{t_{n+1}} - Y_{n+1}$ puede descomponerse como:

$$R_n = R_n^{\text{dif}} + R_n^{\text{jump}}, \quad (7.7)$$

donde

- R_n^{dif} es el error de la parte difusiva,
- R_n^{jump} es el error de la parte de saltos.

Por la expansión de Wagner-Platen para difusiones puras (Platen y Bruti-Liberati [24], Ec. (5.3.19)), el error local de la parte difusiva satisface:

$$\mathbb{E} \left[|R_n^{\text{dif}}|^2 \mid \mathcal{F}_{t_n} \right] \leq K_1 (1 + |Y_n|^2) (dt)^3. \quad (7.8)$$

Para la parte de saltos, el error local es:

$$R_n^{\text{jump}} = \int_{t_n}^{t_{n+1}} \int_E R(s, X_{s-}, v) \tilde{p}_\phi(dv, ds) - \sum_{i=1}^{\Delta N_n} R(t_n, Y_n, \xi_i) - \int_E R(t_n, Y_n, v) \phi(dv) dt \quad (7.9)$$

Usando propiedades de la medida de Poisson compensada (ver Platen y Bruti-Liberati [24], Ec. (4.2.1)) y la condición de Lipschitz para c , se tiene:

$$\mathbb{E} \left[|R_n^{\text{jump}}|^2 \mid \mathcal{F}_{t_n} \right] \leq K_2 dt + K_3 |X_{t_n} - Y_n|^2 dt. \quad (7.10)$$

Combinando Ecuación 7.8 y Ecuación 7.10 usando la desigualdad $(a + b)^2 \leq 2a^2 + 2b^2$, obtenemos:

$$\begin{aligned} \mathbb{E} \left[|R_n|^2 \mid \mathcal{F}_{t_n} \right] &\leq 2K_1(1 + |Y_n|^2)(dt)^3 + 2K_2 dt + 2K_3 |e_n|^2 dt \\ &\leq K_4(1 + |Y_n|^2 + |e_n|^2)(dt)^2, \end{aligned} \quad (7.11)$$

donde en el último paso usamos que $dt \leq 1$ (paso de tiempo pequeño) y $e_n = X_{t_n} - Y_n$ es el error global.

Para demostrar que el esquema tiene momentos finitos, usamos un argumento de tipo Grönwall discreto. Definimos:

$$M_n = \mathbb{E} \left[\sup_{0 \leq k \leq n} |Y_k|^2 \right]. \quad (7.12)$$

Tomando cuadrados en Ecuación 7.3 y esperanza, y usando las cotas de Lipschitz y crecimiento lineal, se obtiene:

$$M_{n+1} \leq (1 + K_5 dt) M_n + K_6 dt. \quad (7.13)$$

Iterando esta desigualdad y usando que $M_0 = \mathbb{E}[|Y_0|^2] < \infty$, se obtiene:

$$M_N \leq M_0 e^{K_5 T} + \frac{K_6}{K_5} (e^{K_5 T} - 1) < \infty. \quad (7.14)$$

Por lo tanto, el esquema numérico tiene momentos finitos uniformes.

Definimos el error global $e_n = X_{t_n} - Y_n$. Usando la fórmula de Itô para la solución exacta y la definición del esquema, podemos escribir:

$$e_{n+1} = e_n + \delta a_n dt + \delta b_n dW_n + \delta c_n + R_n, \quad (7.15)$$

donde

- $\delta a_n = a(t_n, X_{t_n}) - a(t_n, Y_n)$,
- $\delta b_n = b(t_n, X_{t_n}) - b(t_n, Y_n)$,

- $\delta c_n = \int_E [c(t_n, X_{t_n}, v) - c(t_n, Y_n, v)] \phi(Dv) dt$,
- R_n es el residuo total (error local).

Por la condición de Lipschitz:

$$|\delta a_n| \leq L_a |e_n|, \quad |\delta b_n| \leq L_b |e_n|, \quad |\delta c_n| \leq L_c |e_n| dt, \quad (7.16)$$

donde L_a, L_b, L_c son las constantes de Lipschitz de a, b y c , respectivamente.

Tomamos cuadrados en Ecuación 7.15 :

$$\begin{aligned} |e_{n+1}|^2 &= |e_n|^2 + 2e_n \cdot \delta a_n dt + 2e_n \cdot \delta b_n dW_n + 2e_n \cdot \delta c_n \\ &\quad + |\delta a_n|^2 (dt)^2 + 2\delta a_n \cdot \delta b_n dt dW_n + 2\delta a_n \cdot \delta c_n dt \\ &\quad + |\delta b_n|^2 (dW_n)^2 + 2\delta b_n \cdot \delta c_n dW_n + |\delta c_n|^2 \\ &\quad + 2e_n \cdot R_n + 2\delta a_n \cdot R_n dt + 2\delta b_n \cdot R_n dW_n + 2\delta c_n \cdot R_n + |R_n|^2. \end{aligned} \quad (7.17)$$

Tomamos esperanza condicional dado $\mathcal{F}_{t_n}$. Notamos que:

- $\mathbb{E}[dW_n | \mathcal{F}_{t_n}] = 0$,
- $\mathbb{E}[(dW_n)^2 | \mathcal{F}_{t_n}] = dt$,
- Los términos con dW_n tienen esperanza cero.

Por lo tanto:

$$\begin{aligned} \mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] &\leq |e_n|^2 + 2e_n \cdot \delta a_n dt + 2e_n \cdot \delta c_n + |\delta b_n|^2 dt \\ &\quad + |\delta a_n|^2 (dt)^2 + 2|\delta a_n||\delta c_n| dt + |\delta c_n|^2 \\ &\quad + 2|e_n||R_n| + 2|\delta a_n||R_n| dt + 2|\delta c_n||R_n| + |R_n|^2. \end{aligned} \quad (7.18)$$

Usando las cotas de Lipschitz Ecuación 7.16 y la desigualdad $2ab \leq a^2 + b^2$, obtenemos:

$$\begin{aligned} \mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] &\leq |e_n|^2 + 2L_a |e_n|^2 dt + 2L_c |e_n|^2 dt + L_b^2 |e_n|^2 dt \\ &\quad + L_a^2 |e_n|^2 (dt)^2 + 2L_a L_c |e_n|^2 (dt)^2 + L_c^2 |e_n|^2 (dt)^2 \\ &\quad + |e_n|^2 + |R_n|^2 + L_a^2 |e_n|^2 (dt)^2 + |R_n|^2 (dt)^2 \\ &\quad + L_c^2 |e_n|^2 (dt)^2 + |R_n|^2 + |R_n|^2. \end{aligned} \quad (7.19)$$

Simplificando y usando que $dt \leq 1$:

$$\mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] \leq (1 + K_7 dt) |e_n|^2 + K_8 |R_n|^2, \quad (7.20)$$

donde $K_7 = 2L_a + 2L_c + L_b^2 + L_a^2 + 2L_a L_c + L_c^2 + 1$ y $K_8 = 4 + (dt)^2 \leq 5$. Usando la cota del error local Ecuación 7.11 :

$$\mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] \leq (1 + K_7 dt) |e_n|^2 + K_8 K_4 (1 + |Y_n|^2 + |e_n|^2) (dt)^2.$$

Usando la desigualdad $|Y_n|^2 \leq 2|X_{t_n}|^2 + 2|e_n|^2$ y tomando esperanza total:

$$\mathbb{E}[|e_{n+1}|^2] \leq (1 + K_7 dt + 2K_8 K_4 (dt)^2) \mathbb{E}[|e_n|^2] + 2K_8 K_4 (dt)^2 \mathbb{E}[|X_{t_n}|^2] + K_8 K_4 (dt)^2. \quad (7.21)$$

Definiendo $E_n = \mathbb{E}[|e_n|^2]$ y usando la cota de momentos de la solución exacta Ecuación 7.6:

$$E_{n+1} \leq (1 + K_9 dt) E_n + K_{10} (dt)^2, \quad (7.22)$$

donde $K_9 = K_7 + 2K_8 K_4 dt \leq K_7 + 2K_8 K_4$ y $K_{10} = 2K_8 K_4 C_1 (1 + \mathbb{E}[|X_0|^2]) + K_8 K_4$.

Iteramos la desigualdad Ecuación 7.22:

$$\begin{aligned} E_1 &\leq (1 + K_9 dt) E_0 + K_{10} (dt)^2, \\ E_2 &\leq (1 + K_9 dt)^2 E_0 + K_{10} (dt)^2 [1 + (1 + K_9 dt)], \\ &\vdots \\ E_N &\leq (1 + K_9 dt)^N E_0 + K_{10} (dt)^2 \sum_{k=0}^{N-1} (1 + K_9 dt)^k. \end{aligned} \quad (7.23)$$

Como $E_0 = 0$ (condiciones iniciales iguales), el primer término se anula. La suma geométrica se puede acotar:

$$\sum_{k=0}^{N-1} (1 + K_9 dt)^k = \frac{(1 + K_9 dt)^N - 1}{K_9 dt}. \quad (7.24)$$

Usando la desigualdad $(1 + x)^N \leq e^{Nx}$ para $x \geq 0$, y notando que $N dt = T$, obtenemos:

$$(1 + K_9 dt)^N \leq e^{K_9 T} \quad (7.25)$$

donde $C = K_{10}(e^{K_9 T} - 1)/K_9$ es una constante independiente de dt . Tomando raíz cuadrada, obtenemos finalmente:

$$(\mathbb{E}[|X_T - Y_N|^2])^{1/2} \leq C \sqrt{dt}. \quad (7.26)$$

□

7.4. Esquema Semi-Implicito Compensado

El método semi-implícito compensado se define aplicando una regla de Euler implícita en el drift y explícita en la difusión y el salto compensado

$$U_{n+1} = U_n + [c_{n+1} + r_{n+1} U_{n+1}] \Delta t + \sigma_n U_n \Delta W_n - \tilde{J}_n, \quad (7.27)$$

donde $c_{n+1} = c(t_{n+1})$, $r_{n+1} = r(t_{n+1})$, $\sigma_n = \sigma(t_n)$, y $\Delta W_n = W_{t_{n+1}} - W_{t_n}$.

Reordenando algebraicamente para despejar U_{n+1} :

$$U_{n+1}(1 - r_{n+1}\Delta t) = U_n(1 + \sigma_n\Delta W_n) + c_{n+1}\Delta t + \mathbb{E}[\Delta J_n] - \Delta J_n,$$

lo que da lugar a la fórmula cerrada central:

$$U_{n+1} = \frac{U_n(1 + \sigma(t_n)\Delta W_n) + c(t_n)\Delta t + \int_E c(t_n, U_n, v)\phi(dv)\Delta t - \sum_{i=1}^{\Delta N_n} c(t_n, U_n, \xi_i)}{1 - r(t_{n+1})\Delta t} \quad (7.28)$$

donde:

- $\Delta t = t_{n+1} - t_n$,
- $\Delta W_n \sim \mathcal{N}(0, \Delta t)$,
- $\Delta N_n \sim \text{Poisson}(\lambda\Delta t)$, $\lambda = \phi(E)$,
- $\xi_i \stackrel{\text{i.i.d.}}{\sim} \phi(dv)/\lambda$.

Teorema 7.2. (Convergencia fuerte de orden $\gamma = 1/2$) Supongamos las siguientes hipótesis:

- (H1) **Lipschitz global:** Los coeficientes $a(t, u) = c(t) + r(t)u$ y $b(t, u) = \sigma(t)u$ son globalmente Lipschitz en u , y $c(t, u, v)$ es globalmente Lipschitz en u uniformemente en t y v :

$$|c(t, u_1, v) - c(t, u_2, v)| \leq L_c |u_1 - u_2|, \quad \forall t \in [0, T], u_1, u_2 \in \mathbb{R}, v \in E. \quad (\text{H1})$$

- (H2) **Crecimiento lineal:** Existe $K > 0$ tal que

$$|a(t, u)| + |b(t, u)| + \left(\int_E |c(t, u, v)|^2 \phi(dv) \right)^{1/2} \leq K(1 + |u|), \quad (\text{H2})$$

para todo $t \in [0, T]$ y $u \in \mathbb{R}$ (Platen y Bruti-Liberati [24], Ec. (1.9.3)).

- (H3) **Momentos finitos de saltos:** $\int_E |c(t, u, v)|^4 \phi(dv) < \infty$ para todo $t \in [0, T]$ y $u \in \mathbb{R}$ (Wang, Mei y Xue [30], Hipótesis 3.1).
- (H4) **Estabilidad numérica:** Existe $\Delta t_0 > 0$ y $\delta > 0$ tales que $1 - r(t_{n+1})\Delta t \geq \delta > 0$ para todo $\Delta t \leq \Delta t_0$ (Higham y Kloeden [13], Lema 2.1).
- (H5) **Condiciones iniciales:** $\mathbb{E}[|U_0|^2] < \infty$ y $U_0 = 0$.

Bajo las hipótesis (H1)–(H5), existe una constante $C > 0$, independiente de Δt , tal que:

$$\max_{0 \leq n \leq N} \left(\mathbb{E}[|U_{t_n} - U_n|^2] \right)^{1/2} \leq C\sqrt{\Delta t}. \quad (7.29)$$

Demostración. Reescribimos la SDEJ (Ecuación 7.2) en forma estándar (Platen y Bruti-Liberati [24], Ec. (1.8.2)):

$$dU_t = a(t, U_t) dt + b(t, U_t) dW_t + \int_E c(t, U_{t-}, v) p_\phi(dv, dt), \quad (7.30)$$

donde $a(t, u) = c(t) + r(t)u$ y $b(t, u) = \sigma(t)u$. Las hipótesis (H1) y (H2) satisfacen las condiciones del **Teorema 1.9.4** de Platen y Bruti-Liberati [24], que garantiza la existencia y unicidad de una solución fuerte U_t . Además asegura que la solución tiene momentos finitos de segundo orden:

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |U_t|^2 \right] \leq C_1 (1 + \mathbb{E}[|U_0|^2]) < \infty. \quad (7.31)$$

Esta cota es esencial para controlar el crecimiento de la solución exacta durante la propagación del error.

Definimos el error local $R_n = U_{t_{n+1}} - U_{n+1}$ y lo descomponemos como:

$$R_n = R_n^{\text{dif}} + R_n^{\text{jump}} + R_n^{\text{implicit}}, \quad (7.32)$$

donde R_n^{dif} es el error de difusión, R_n^{jump} el error de saltos y R_n^{implicit} el error de implicitidad.

Por la expansión de Euler-Maruyama para difusiones puras (Higham y Kloeden [13], Ec. (2.3)), el error local de la parte difusiva satisface:

$$\mathbb{E} \left[|R_n^{\text{dif}}|^2 \mid \mathcal{F}_{t_n} \right] \leq K_1 (1 + |U_n|^2) (\Delta t)^2 \quad (7.33)$$

Esta cota es de orden $(\Delta t)^3$ en L^2 debido a que el esquema semi-implícito utiliza una aproximación de Euler para la parte difusiva, cuyo error local en L^2 es $\mathcal{O}((\Delta t)^{3/2})$. El error local asociado a los saltos es:

$$\begin{aligned} R_n^{\text{jump}} &= \int_{t_n}^{t_{n+1}} \int_E c(s, U_{s-}, v) \tilde{p}_\phi(dv, ds) \\ &\quad - \sum_{i=1}^{\Delta N_n} c(t_n, U_n, \xi_i) \\ &\quad + \int_E c(t_n, U_n, v) \phi(dv) \Delta t. \end{aligned} \quad (7.34)$$

Aplicando la desigualdad de Cauchy-Schwarz, la condición de Lipschitz (H1) y las propiedades de la medida compensada (Platen y Bruti-Liberati [24], Ec. (4.2.1)), obtenemos:

$$\begin{aligned}
\mathbb{E} \left[|R_n^{\text{jump}}|^2 \mid \mathcal{F}_{t_n} \right] &\leq 2\mathbb{E} \left[\left| \int_{t_n}^{t_{n+1}} \int_E [c(s, U_{s-}, v) - c(t_n, U_n, v)] \tilde{p}_\phi(dv, ds) \right|^2 \mid \mathcal{F}_{t_n} \right] \\
&\quad + 2\mathbb{E} \left[\left| \int_{t_n}^{t_{n+1}} \int_E c(t_n, U_n, v) \tilde{p}_\phi(dv, ds) - \sum_{i=1}^{\Delta N_n} c(t_n, U_n, \xi_i) \right. \right. \\
&\quad \left. \left. + \int_E c(t_n, U_n, v) \phi(dv) \Delta t \right|^2 \mid \mathcal{F}_{t_n} \right] \\
&\leq 2L_c^2 \mathbb{E} \left[\int_{t_n}^{t_{n+1}} |U_s - U_n|^2 ds \mid \mathcal{F}_{t_n} \right] \int_E \phi(dv) + 2 \int_E |c(t_n, U_n, v)|^2 \phi(dv) \Delta t \\
&\leq K_2 \Delta t + K_3 |U_{t_n} - U_n|^2 \Delta t,
\end{aligned}$$

donde en la última desigualdad usamos la cota de momentos de la solución exacta Ecuación 7.31 y la condición de crecimiento lineal (H2). El primer término proviene de la variación del estado durante el intervalo, y el segundo de la diferencia entre el estado exacto y el numérico. Expandiendo el denominador mediante serie de Taylor (Wang, Mei y Xue [30], Lema 3.1):

$$\frac{1}{1 - r(t_{n+1})\Delta t} = 1 + r(t_{n+1})\Delta t + \mathcal{O}((\Delta t)^2), \quad (7.35)$$

lo que implica que el error introducido por la implicitidad satisface:

$$\mathbb{E} \left[|R_n^{\text{implicit}}|^2 \mid \mathcal{F}_{t_n} \right] \leq K_4 (1 + |U_n|^2) (\Delta t)^4. \quad (7.36)$$

Este término es de orden superior y no afectará el orden global de convergencia.

Combinando la Ecuación 7.33, Ecuación 7.35 y Ecuación 7.36, y usando $(a + b + c)^2 \leq 3a^2 + 3b^2 + 3c^2$:

$$\mathbb{E} \left[|R_n|^2 \mid \mathcal{F}_{t_n} \right] \leq K_5 (1 + |U_n|^2 + |e_n|^2) \Delta t, \quad (7.37)$$

donde $e_n = U_{t_n} - U_n$ es el error global y usamos que $\Delta t \leq 1$ para absorber los términos de orden superior. Definiendo $M_n = \mathbb{E} \left[\sup_{0 \leq k \leq n} |U_k|^2 \right]$, y tomando cuadrados en Ecuación 7.28 seguido de esperanza, aplicamos las cotas de Lipschitz (H1), crecimiento lineal (H2) y la cota de estabilidad (H4). Siguiendo el argumento del Teorema 3.2 de Higham y Kloeden [13], obtenemos:

$$M_{n+1} \leq (1 + K_6 \Delta t) M_n + K_7 \Delta t. \quad (7.38)$$

Iterando esta desigualdad y usando $M_0 = \mathbb{E}[|U_0|^2] < \infty$:

$$M_N \leq M_0 e^{K_6 T} + \frac{K_7}{K_6} (e^{K_6 T} - 1) < \infty. \quad (7.39)$$

Por lo tanto, el esquema numérico tiene momentos finitos uniformes, condición esencial para la convergencia fuerte. Para la descomposición del error global definimos $e_n = U_{t_n} - U_n$. Usando la fórmula de Itô para la solución exacta y la definición del esquema Ecuación 7.28, obtenemos:

$$e_{n+1} = e_n + \delta a_n \Delta t + \delta b_n \Delta W_n + \delta c_n + R_n, \quad (7.40)$$

donde:

$$\begin{aligned} \delta a_n &= a(t_n, U_{t_n}) - a(t_n, U_n), \\ \delta b_n &= b(t_n, U_{t_n}) - b(t_n, U_n), \\ \delta c_n &= \int_E [c(t_n, U_{t_n}, v) - c(t_n, U_n, v)] \phi(dv) \Delta t. \end{aligned}$$

Por la condición de Lipschitz (H1):

$$|\delta a_n| \leq L_a |e_n|, \quad |\delta b_n| \leq L_b |e_n|, \quad |\delta c_n| \leq L_c |e_n| \Delta t. \quad (7.41)$$

Tomamos cuadrados en Ecuación 7.40 y esperanza condicional $\mathbb{E}[\cdot | \mathcal{F}_{t_n}]$. Usando $\mathbb{E}[\Delta W_n | \mathcal{F}_{t_n}] = 0$, $\mathbb{E}[(\Delta W_n)^2 | \mathcal{F}_{t_n}] = \Delta t$, y que los términos con ΔW_n tienen esperanza cero:

$$\begin{aligned} \mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] &\leq |e_n|^2 + 2e_n \cdot \delta a_n \Delta t + 2e_n \cdot \delta c_n + |\delta b_n|^2 \Delta t + \mathbb{E}[|R_n|^2 | \mathcal{F}_{t_n}] \\ &\leq |e_n|^2 + 2L_a |e_n|^2 \Delta t + 2L_c |e_n|^2 \Delta t + L_b^2 |e_n|^2 \Delta t + K_5(1 + |U_n|^2 + |e_n|^2) \Delta t \\ &\leq (1 + K_8 \Delta t) |e_n|^2 + K_9(1 + |U_n|^2) \Delta t, \end{aligned}$$

donde $K_8 = 2L_a + 2L_c + L_b^2 + K_5$ y $K_9 = K_5$. Usando la desigualdad $|U_n|^2 \leq 2|U_{t_n}|^2 + 2|e_n|^2$ y la cota de momentos de la solución exacta Ecuación 7.31:

$$\mathbb{E}[|e_{n+1}|^2 | \mathcal{F}_{t_n}] \leq (1 + K_{10} \Delta t) |e_n|^2 + K_{11} \Delta t,$$

donde $K_{10} = K_8 + 2K_9$ y $K_{11} = 2K_9 C_1(1 + \mathbb{E}[|U_0|^2]) + K_9$. Tomando esperanza total y definiendo $E_n = \mathbb{E}[|e_n|^2]$:

$$E_{n+1} \leq (1 + K_{10} \Delta t) E_n + K_{11} \Delta t. \quad (7.42)$$

Iteramos la desigualdad Ecuación 7.42 con $E_0 = 0$:

$$E_N \leq K_{11} \Delta t \sum_{k=0}^{N-1} (1 + K_{10} \Delta t)^k = K_{11} \Delta t \frac{(1 + K_{10} \Delta t)^N - 1}{K_{10} \Delta t}. \quad (7.43)$$

Usando la desigualdad $(1 + x)^N \leq e^{Nx}$ para $x \geq 0$ y $N \Delta t = T$ Platen y Bruti-Liberati [24], (Lema 1.2.1):

$$(1 + K_{10} \Delta t)^N \leq e^{K_{10} T}. \quad (7.44)$$

Sustituyendo en Ecuación 7.43:

$$E_N \leq K_{11} \frac{e^{K_{10} T} - 1}{K_{10}} \Delta t = C \Delta t, \quad (7.45)$$

donde $C = K_{11}(e^{K_{10} T} - 1)/K_{10}$ es independiente de Δt . Tomando raíz cuadrada:

$$(\mathbb{E}[|U_T - U_N|^2])^{1/2} \leq C \sqrt{\Delta t}.$$

□

7.5. Método Monte Carlo

El método Monte Carlo (MC) constituye una clase de algoritmos computacionales que se basan en el muestreo aleatorio repetido para obtener resultados numéricos. En el contexto de esta tesis, el objetivo fundamental es aproximar cantidades de interés deterministas, tales como integrales multidimensionales o valores esperados de sistemas estocásticos complejos, mediante la simulación de un sistema un gran número de veces bajo condiciones aleatorias.

7.5.1. Estimador de Monte Carlo

La base teórica del método reside en la construcción de un estimador no sesgado basado en muestras independientes.

Definición 7.1. (Estimador de Monte Carlo). Sean $X_1, X_2, \dots, X_N$ variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con la misma distribución que X . Definimos el estimador de Monte Carlo $\hat{I}_N$ como la media muestral de las realizaciones de la función f :

$$\hat{I}_N = \frac{1}{N} \sum_{i=1}^N f(X_i). \quad (7.46)$$

La validez de este estimador se sustenta en dos propiedades estadísticas fundamentales: su insesgamiento y su consistencia.

El estimador $\hat{I}_N$ es un estimador insesgado de I . Es decir, $\mathbb{E}[\hat{I}_N] = I$.

Demostración. Dado que la esperanza es un operador lineal y las variables X_i son i.i.d.:

$$\begin{aligned} \mathbb{E}[\hat{I}_N] &= \mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N f(X_i) \right] \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{E}[f(X_i)] \\ &= \frac{1}{N} \sum_{i=1}^N I = \frac{1}{N} \cdot N \cdot I = I. \end{aligned}$$

lo que prueba el resultado. □

7.5.2. Convergencia y rigor asintótico.

Para justificar teóricamente por qué simular el sistema “miles o millones de veces” (es decir, hacer tender $N \rightarrow \infty$) nos permite aproximar el valor real del sistema, debemos recurrir a los teoremas límite de la teoría de la probabilidad.

7.5.2.1. Ley Fuerte de los Grandes Números.

La convergencia casi segura del estimador está garantizada por la Ley Fuerte de los Grandes Números.

Teorema 7.3. (*Ley Fuerte de los Grandes Números*). Sea $\{X_i\}_{i \geq 1}$ una sucesión de variables aleatorias i.i.d. con $\mathbb{E}[|f(X_1)|] < \infty$. Entonces, el estimador de Monte Carlo converge casi seguramente (c.s.) al valor verdadero I :

$$\mathbb{P} \left(\lim_{N \rightarrow \infty} \hat{I}_N = I \right) = 1.$$

Este teorema proporciona la garantía teórica de que, al aumentar el número de simulaciones, el error de aproximación tiende a cero con probabilidad unitaria. Sin embargo, la SLLN no cuantifica la tasa de convergencia ni la distribución del error para un N finito.

Para evaluar la precisión del método y construir intervalos de confianza, utilizamos el Teorema del Límite Central. Asumamos que la varianza de la función es finita, es decir, $\sigma^2 = \mathbb{V}[f(X)] < \infty$.

Teorema 7.4. (*Teorema del Límite Central para MC*) Bajo las condiciones de varianza finita, la distribución del error normalizado converge en distribución a una normal estándar:

$$\sqrt{N} \frac{\hat{I}_N - I}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{cuando } N \rightarrow \infty.$$

De este resultado se desprende una conclusión crítica para la simulación computacional: el error estándar del estimador decae proporcionalmente a $N^{-1/2}$, independientemente de la dimensión del problema.

$$\text{Error}(\hat{I}_N) \approx \frac{\sigma}{\sqrt{N}}. \quad (7.47)$$

Esta propiedad es distintiva del método Monte Carlo. Mientras que los métodos deterministas sufren una degradación exponencial en su precisión a medida que aumenta la dimensionalidad del espacio de integración, la tasa de convergencia $O(N^{-1/2})$ de Monte Carlo permanece invariante ante la dimensionalidad, lo que lo hace superior para sistemas complejos de alta dimensión.

7.5.3. Generación de variables aleatorias.

La implementación práctica de la ecuación Ecuación 7.46 requiere la capacidad de generar muestras X_i de una distribución de probabilidad específica P . Matemáticamente, esto se logra a menudo mediante el Método de la Transformada Inversa.

Sea $U \sim \text{Uniforme}(0, 1)$ una variable aleatoria uniforme. Si $F_X(x) = \mathbb{P}(X \leq x)$ es la función de distribución acumulada (CDF) de X , y F_X^{-1} es su inversa generalizada definida como:

$$F_X^{-1}(u) = \inf\{x \in \mathbb{R} : F_X(x) \geq u\},$$

entonces la variable aleatoria $Y = F_X^{-1}(U)$ tiene la misma distribución que X .

En sistemas complejos donde F_X^{-1} no tiene forma cerrada, se emplean métodos de rechazo (Rejection Sampling) o cadenas de Markov (MCMC), los cuales garantizan que la distribución estacionaria de la cadena generada coincida con la distribución objetivo P .

7.5.4. Técnicas de Reducción de Varianza.

Dado que la convergencia es lenta ($1/\sqrt{N}$), reducir la varianza σ^2 es tan importante como aumentar N . Una varianza menor implica que se requieren menos simulaciones para alcanzar un nivel de precisión deseado.

7.5.4.1. Variables de control.

Una de las técnicas más rigurosas es el uso de variables de control. Supongamos que existe una variable aleatoria Y correlacionada con $f(X)$ cuya esperanza $\mu_Y = \mathbb{E}[Y]$ es conocida analíticamente. Definimos un nuevo estimador:

$$\hat{I}_{CV}(c) = \hat{I}_N - c(\hat{Y}_N - \mu_Y),$$

donde $\hat{Y}_N = \frac{1}{N} \sum Y_i$ y c es una constante. Este estimador sigue siendo insesgado para cualquier $c \in \mathbb{R}$. La varianza de este nuevo estimador es:

$$\mathbb{V}[\hat{I}_{CV}(c)] = \mathbb{V}[\hat{I}_N] + c^2 \mathbb{V}[\hat{Y}_N] - 2c \text{Cov}(\hat{I}_N, \hat{Y}_N).$$

Minimizando esta expresión respecto a c , obtenemos el coeficiente óptimo:

$$c^* = \frac{\text{Cov}(f(X), Y)}{\mathbb{V}(Y)}.$$

Sustituyendo c^* , se demuestra que la varianza se reduce en un factor de $(1 - \rho^2)$, donde ρ es el coeficiente de correlación entre $f(X)$ e Y . Si existe una alta correlación, la eficiencia del método mejora drásticamente.

8 Implementación Numérica.

8.1. Estimación de Parámetros para el mercado de seguros de bienes raíces Mexicano

8.1.1. Función de Primas Ajustadas por Inflación: $c(t)$.

La prima base para enero de 2024 se establece en $c_0 = 283.00$, derivada del consenso de fuentes sectoriales (AMIS, CNSF). El ajuste por inflación se realiza mediante capitalización compuesta:

$$c(t) = c_0 \prod_{i=1}^t (1 + \pi_i), \quad (8.1)$$

donde π_i representa la tasa de inflación mensual reportada por el INEGI [16].

8.1.1.1. Datos de Inflación Mensual

La Tabla 8.1 presenta las tasas de inflación utilizadas para el periodo enero 2024 – diciembre 2025. Los datos de 2024 son observados, mientras que las proyecciones de 2025 se basan en el consenso de analistas del Banco de México Banco de México [6].

Tabla 8.1: Tasas de inflación mensual en México (variación porcentual del INPC Enero 2024- Diciembre 2025).

Mes	Prima mensual ajustada (MXN)
Ene 2024	283.00
Feb 2024	284.47
Mar 2024	285.55
Abr 2024	286.72
May 2024	288.01
Jun 2024	289.42
Jul 2024	291.02
Ago 2024	292.79
Sep 2024	294.49
Oct 2024	295.87
Nov 2024	297.12

Mes	Prima mensual ajustada (MXN)
Dic 2024	298.28
Ene 2025	299.32
Feb 2025	300.82
Mar 2025	301.93
Abr 2025	303.14
May 2025	304.47
Jun 2025	305.93
Jul 2025	307.55
Ago 2025	309.37
Sep 2025	311.10
Oct 2025	312.53
Nov 2025	313.81
Dic 2025	315.01

Aplicando Ecuación 8.1, las primas mensuales ajustadas evolucionan de 283.00 en enero 2024 a 315.01 en diciembre 2025, representando un incremento acumulado del 11.3 %, consistente con la inflación proyectada

8.1.2. Modelado de la tasa de inversión: $r(t)$.

Las aseguradoras mexicanas mantienen carteras conservadoras con asignación aproximada de 70 % en instrumentos locales (CETES, Mbonos) y 30 % en activos globales ([9]). Siguiendo el marco regulatorio de la CNSF y la estructura conservadora de las carteras aseguradoras mexicanas (informe anual CNSF), modelamos $r(t)$ como combinación convexa ponderada:

$$r(t) = \rho \cdot r_{\text{CETES}}(t) + (1 - \rho) \cdot r_{\text{USD}}(t) \quad (8.2)$$

- $\rho = 0.70$,
- $r_{\text{CETES}}(t)$ la tasa de CETES a 28 días mensualizada,
- $r_{\text{USD}}(t)$ el rendimiento de bonos del Tesoro de EE.UU.,
- $\rho = 0.75$ refleja la asignación típica de carteras (70 – 80 %) en activos locales según CNSF)

Para el periodo 2024-2025, con tasas de Banxico estables en 11.0 % anual y bonos USD en 4.8 % anual:

$$r(t) = 0.75 \cdot \frac{0.110}{12} + 0.25 \cdot \frac{0.048}{12} = 0.007875 \text{ mensual} \quad (9.45 \% \text{ anual})$$

Este valor se ajusta a 0.78 % mensual para incorporar costos operativos y fiscales (1.5 p.p. anuales), resultando en un rendimiento neto anual de 8.9 %.

8.1.3. Modelado de la volatilidad de Inversiones $\sigma(t)$.

8.1.3.1. Combinación Convexa de Volatilidades

La volatilidad total se estima como combinación ponderada de componentes globales y locales:

$$\sigma(t)F = w_g \cdot \sigma_g(t) + w_l \cdot \sigma_l, \quad (8.3)$$

Los informes anuales de la CNSF sobre la composición de las inversiones del sector asegurador en México indican que, en promedio, las compañías mantienen:

- 30 % de sus inversiones en instrumentos del extranjero.
- 70 % en instrumentos del mercado nacional.

Dado que no hay datos mensuales oficiales públicos, se asume una asignación constante durante el periodo, basada en el último informe disponible (2023) con $w_g = 0 \cdot 30$, $w_l = 0 \cdot 70$.

La componente local $\sigma_l(t)$ respecta a la Volatilidad de CETES a 28 días que es el activo de referencia para las inversiones conservadoras en México, estimada mediante desviación estándar móvil de 30 días de las tasas diarias de Banxico:

$$\sigma_l(t) = 0.05 \% \text{ mensual (constante)}$$

Mientras que la componente global $\sigma_g(t)$ es dada por la Volatilidad del índice ILS (Artemis.bm), calculada como desviación estándar móvil de 3 meses de los rendimientos mensuales. Presenta estacionalidad marcada por la temporada de huracanes (junio-noviembre):

Tabla 8.2: Tasas de volatilidad mensual en el mercado global, $\sigma_g(t)$ (Enero 2024- Diciembre 2025).

Mes	Volatilidad global $\sigma_g(t)$
Ene 2024	0.08 %
Feb 2024	0.09 %
Mar 2024	0.10 %
Abr 2024	0.11 %
May 2024	0.12 %

Mes	Volatilidad global $\sigma_g(t)$
Jun 2024	0.15 %
Jul 2024	0.18 %
Ago 2024	0.35 %
Sep 2024	0.30 %
Oct 2024	0.25 %
Nov 2024	0.20 %
Dic 2024	0.18 %
Ene 2025	0.16 %
Feb 2025	0.14 %
Mar 2025	0.13 %
Abr 2025	0.14 %
May 2025	0.16 %
Jun 2025	0.20 %
Jul 2025	0.25 %
Ago 2025	0.22 %
Sep 2025	0.28 %
Oct 2025	0.24 %
Nov-25	0.20 %
Dic 2025	0.18 %

Los valores están expresados en forma decimal. Por ejemplo, $\sigma(Ene2024) = 0.059\% = 0.00059$ en notación decimal. Por tanto la volatilidad total mensual resultante es:

Tabla 8.3: Tasas de volatilidad mensual en el mercado total, σ (Enero 2024- Diciembre 2025).

Mes	σ_g	σ_l	$\sigma(t)$
Ene 2024	0.08	0.05	0.059
Feb 2024	0.09	0.05	0.062
Mar 2024	0.10	0.05	0.065
Abr 2024	0.11	0.05	0.068
May 2024	0.12	0.05	0.071
Jun 2024	0.15	0.05	0.080
Jul 2024	0.18	0.05	0.089
Ago 2024	0.35	0.05	0.140
Sep 2024	0.30	0.05	0.125
Oct 2024	0.25	0.05	0.110
Nov 2024	0.20	0.05	0.095
Dic 2024	0.18	0.05	0.089
Ene 2025	0.16	0.05	0.083
Feb 2025	0.14	0.05	0.077

Mes	σ_g	σ_l	$\sigma(t)$
Mar 2025	0.13	0.05	0.074
Abr 2025	0.14	0.05	0.077
May 2025	0.16	0.05	0.083
Jun 2025	0.20	0.05	0.095
Jul 2025	0.25	0.05	0.110
Ago 2025	0.22	0.05	0.101
Sep 2025	0.28	0.05	0.119
Oct 2025	0.24	0.05	0.107
Nov-25	0.20	0.05	0.095
Dic 2025	0.18	0.05	0.089

con promedio anual $\bar{\sigma} = 0.092\%$ con picos superiores a 0.14% en meses de alta actividad catastrófica.

8.1.4. Función de Costos de Saltos: Eventos Meteorológicos y Sísmicos.

El proceso de siniestros $S(t)$ se descompone en dos componentes independientes que reflejan la naturaleza bimodal del riesgo en México:

$$S(t) = S_{\text{meteo}}(t) + S_{\text{sismo}}(t) = \sum_{i=1}^{N_{\text{meteo}}(t)} Y_i^{\text{meteo}} + \sum_{j=1}^{N_{\text{sismo}}(t)} Y_j^{\text{sismo}}$$

donde $N_{\text{meteo}}(t)$ sigue un proceso de Poisson no homogéneo con intensidad $\lambda_{\text{meteo}}(t) = \lambda_{\text{meteo}}^{\text{anual}} \cdot \phi(t)$, siendo $\phi(t)$ una función estacional mensual normalizada ($\frac{1}{12} \int_0^{12} \phi(s) ds = 1$), y $N_{\text{sismo}}(t)$ es un proceso de Poisson homogéneo con intensidad constante λ_{sismo} debido a la ausencia de estacionalidad significativa en la ocurrencia de sismos de magnitud relevante para siniestros asegurados.

8.1.4.1. Estimación de la Intensidad de Siniestro.

8.1.4.1.1. Componente Hidrometeorológico

La intensidad mensual $\lambda_{\text{meteo}}(m)$ para el mes $m \in 1, \dots, 12$ se estima mediante:

$$\lambda_{\text{meteo}}(m) = \frac{\lambda_{\text{meteo}}^{\text{anual}}}{12} \cdot \phi(m)$$

donde $\lambda_{\text{meteo}}^{\text{anual}} = 8.0$ eventos/año se calibra a partir de los registros históricos de la CONAGUA (Comisión Nacional del Agua (CONAGUA) [10]) de fenómenos hidrometeorológicos

que generaron reclamaciones superiores a USD 100,000 en viviendas aseguradas en la CDMX. La función estacional $\phi(m)$ se obtiene normalizando los datos mensuales de frecuencia relativa:

$$\phi(m) = \frac{f_m}{\frac{1}{12} \sum_{k=1}^{12} f_k}, \quad f = [0.3, 0.3, 0.4, 0.6, 1.0, 1.8, 2.2, 2.5, 2.8, 2.3, 1.2, 0.5]$$

Esta calibración refleja el pico estacional en septiembre (huracanes y lluvias intensas) y el mínimo en enero-febrero, consistente con el patrón climatológico del centro de México.




Figura 8.1: Costo mensual esperado de siniestros en seguros de vivienda (México).

8.1.4.1.2. Componente Sísmico

Para sismos, utilizamos $\lambda_{\text{sismo}} = 0.08$ eventos/año, derivado del catálogo del Servicio Sismológico Nacional (SSN Servicio Sismológico Nacional (SSN), Instituto de Geofísica, UNAM [28]) considerando únicamente eventos con magnitud $M_w \geq 6.0$ y epicentro a menos de 300km de la CDMX que históricamente han generado siniestralidad asegurada significativa (ej. sismos de 1985, 2017). Dado que la ocurrencia de sismos no presenta estacionalidad estadísticamente significativa (p -valor > 0.15) en test de Kolmogorov-Smirnov para uniformidad mensual), mantenemos intensidad constante:

$$\lambda_{\text{sismo}}(m) = \frac{\lambda_{\text{sismo}}}{12} = 0.0067 \text{ eventos/mes}$$

8.1.4.2. Estimación de la Distribución de Severidad.

8.1.4.2.1. Severidad meteorológica

Modelamos la severidad de los siniestros hidrometeorológicos Y_{meteo} mediante una distribución normal truncada en $[0, \infty)$, denotada como

$$Y_{\text{meteo}} \sim \mathcal{N}_+(\mu, \sigma^2),$$

donde $\mathcal{N}_+$ indica una normal truncada inferiormente en 0.

Los parámetros μ y σ se estiman por máxima verosimilitud a partir de las 1,247 reclamaciones hidrometeorológicas reportadas en el FES 2024 para la Ciudad de México:

$$\hat{\mu} = 12.5 \quad (\text{IC}_{95\%} : [12.3, 12.7]), \quad \hat{\sigma} = 1.0 \quad (\text{IC}_{95\%} : [0.92, 1.08]).$$

Estos valores corresponden a la media y desviación estándar de la distribución subyacente no truncada (es decir, la normal que se trunca para obtener la distribución de severidad positiva). El valor esperado de una normal truncada en $[0, \infty)$ es:

$$\mathbb{E}[Y_{\text{meteo}}] = \mu + \sigma \cdot \frac{\varphi(\alpha)}{1 - \Phi(\alpha)}, \quad \alpha = -\frac{\mu}{\sigma},$$

donde φ y Φ son la función de densidad y la función de distribución acumulada de la normal estándar, respectivamente.

8.1.4.2.2. Severidad sísmica.

Para los siniestros sísmicos, adoptamos también una distribución normal truncada ($\mathcal{N}_+$) en $[0, \infty)$, es decir:

$$Y_{\text{sismo}} \sim \mathcal{N}_+(\mu_s, \sigma_s^2).$$

Los parámetros se estiman por máxima verosimilitud robusta (M-estimador Definición 5.5 o regresión cuantílica Definición 5.6) sobre las 43 reclamaciones sísmicas registradas en el periodo 2000–2023 en la CDMX:

$$\hat{\mu}_s = \ln(1,750,000) \approx 14.37, \quad \hat{\sigma}_s = 0.65 \quad (\text{IC}_{95\%} : [0.55, 0.75]).$$

Estos valores se obtienen al ajustar una normal en escala logarítmica (como es común en modelado de severidad), y luego se interpreta como una normal truncada en la escala original. Nuevamente, dado que $\mu_s/\sigma_s \approx 22.1 \geq 1$, la probabilidad de que la variable no

truncada sea negativa es astronómicamente pequeña ($< 10^{-100}$), por lo que la truncación no modifica significativamente la media.

El valor esperado es entonces aproximadamente:

$$\begin{aligned}\mathbb{E}[Y_{\text{sismo}}] &\approx \exp\left(\mu_s + \frac{\sigma_s^2}{2}\right) = \exp\left(14.37 + \frac{0.65^2}{2}\right) \\ &= \exp(14.37 + 0.21125) = \exp(14.58125) \approx \text{USD } 2,160,000.\end{aligned}$$

Sin embargo, si queremos mantener coherencia con el valor anterior de USD 1,750,000 con $\alpha = 1.4$, $x_{\min} = 500,000$, podemos calibrar la normal truncada para que tenga exactamente esa media. Resolvemos:

$$\mathbb{E}[Y] = \mu + \sigma \cdot \lambda(\alpha) = 1,750,000,$$

con $\alpha = -\mu/\sigma$, y $\lambda(\alpha) = \varphi(\alpha)/(1 - \Phi(\alpha))$. Dado que μ y σ están en escala *lineal* (no log), proponemos una calibración directa:

- Supongamos que la severidad sísmica tiene media $\mu_s = 1,750,000$ y desviación estándar $\sigma_s = 875,000$ (coeficiente de variación 0.5), lo cual es consistente con la dispersión observada en eventos catastróficos (ej. sismo 2017: reclamaciones entre 0.8 y 3.2) millones de dolares (USD).
- Entonces, la distribución normal truncada $\mathcal{N}_+(1,750,000, ; 875,000^2)$ tiene:

$$\alpha = -\frac{1,750,000}{875,000} = -2.0, \quad \lambda(\alpha) = \frac{\varphi(-2)}{1 - \Phi(-2)} = \frac{0.0540}{0.9772} \approx 0.0553,$$

y por tanto

$$\mathbb{E}[Y] = \mu + \sigma\lambda(\alpha) = 1,750,000 + 875,000 \cdot 0.0553 \approx 1,798,400,$$

muy cercano a 1.75M. Si ajustamos ligeramente $\mu = 1,742,000$, obtenemos $\mathbb{E}[Y] \approx 1,750,000$.

Así, proponemos finalmente:

$$Y_{\text{sismo}} \sim \mathcal{N}_+(\mu_s = 1,742,000, \sigma_s = 875,000),$$

con $\mathbb{E}[Y_{\text{sismo}}] = \text{USD } 1,750,000$, y coeficiente de variación = 0.50.

8.2.

Puesto que los saltos que salen de la reserva son exactamente los siniestros agregados como se presenta en Sección 8.1.4 se tiene J_T de la siguiente manera:

$$J_t = S(t) = S_{\text{meteo}}(t) + S_{\text{sismo}}(t) = \sum_{i=1}^{N_{\text{meteo}}(t)} Y_i^{\text{meteo}} + \sum_{j=1}^{N_{\text{sismo}}(t)} Y_j^{\text{sismo}}, \quad J_0 = 0. \quad (8.4)$$

donde $N_{\text{meteo}}(t)$ y $N_{\text{sismo}}(t)$ son procesos de conteo de Poisson independientes, con intensidades $\lambda_{\text{meteo}}(t)$ (no homogénea) y λ_{sismo} y $Y_i^{\text{meteo}}, Y_j^{\text{sismo}}$ son sucesiones i.i.d. de severidades, independientes entre sí y de los procesos de conteo, con distribuciones F_{meteo} y F_{sismo} respectivamente.

al incorporar simultáneamente el tiempo y el monto del siniestro, se introducen dos medidas aleatorias de Poisson.

Sea

$$N_{\text{meteo}}(dt, dy)$$

la medida aleatoria de Poisson asociada a los siniestros meteorológicos y

$$N_{\text{sismo}}(dt, dy)$$

la correspondiente a los eventos sísmicos, ambas definidas sobre el espacio de estados $[0, \infty) \times \mathbb{R}_+$.

El costo acumulado de los siniestros meteorológicos hasta el instante t puede escribirse como

$$J_t^{\text{meteo}} = \int_0^t \int_{\mathbb{R}_+} y N_{\text{meteo}}(ds, dy),$$

mientras que la componente sísmica viene dada por

$$J_t^{\text{sismo}} = \int_0^t \int_{\mathbb{R}_+} y N_{\text{sismo}}(ds, dy).$$

Suponiendo independencia entre ambas fuentes de riesgo, el proceso agregado de pérdidas se define como

$$J_t = J_t^{\text{meteo}} + J_t^{\text{sismo}},$$

es decir,

$$J_t = \int_0^t \int_{\mathbb{R}_+} y N_{\text{meteo}}(ds, dy) + \int_0^t \int_{\mathbb{R}_+} y N_{\text{sismo}}(ds, dy).$$

En forma diferencial,

$$dJ_t = \int_{\mathbb{R}_+} y N_{\text{meteo}}(dt, dy) + \int_{\mathbb{R}_+} y N_{\text{sismo}}(dt, dy).$$

Con el fin de separar el componente determinista asociado al costo esperado de los siniestros del componente puramente aleatorio, se introducen las medidas compensadas

$$\tilde{N}_{\text{meteo}}(dt, dy) = N_{\text{meteo}}(dt, dy) - \nu_{\text{meteo}}(t, dy) dt,$$

y

$$\tilde{N}_{\text{sismo}}(dt, dy) = N_{\text{sismo}}(dt, dy) - \nu_{\text{sismo}}(t, dy) dt.$$

Sustituyendo estas expresiones en la representación diferencial de J_t , se obtiene

$$\begin{aligned} dJ_t &= \int_{\mathbb{R}_+} y \tilde{N}_{\text{meteo}}(dt, dy) + \int_{\mathbb{R}_+} y \tilde{N}_{\text{sismo}}(dt, dy) \\ &\quad + \lambda_{\text{meteo}}(t) \left(\int_{\mathbb{R}_+} y F_t^{\text{meteo}}(dy) \right) dt \\ &\quad + \lambda_{\text{sismo}} \left(\int_{\mathbb{R}_+} y F_t^{\text{sismo}}(dy) \right) dt. \end{aligned}$$

8.3. Aproximación numérica del modelo de Crámer Lundberg extendido

La EDE

$$dX_t = a(X_{t-})dt + b(X_{t-})dW_t - dJ_t$$

Consideramos el proceso de reservas bajo el modelo extendido de Cramér-Lundberg con inversión estocástica y saltos reescribimos Ecuación 6.5 en forma diferencial estocástica:

$$dX_t = \underbrace{[c(t) + r(t)X_t - \lambda_{\text{meteo}}(t)\mathbb{E}[Y_t^{\text{meteo}} | \mathcal{F}_t] - \lambda_{\text{sismo}}\mathbb{E}[Y_t^{\text{sismo}} | \mathcal{F}_t]]}_{\mu(t, X_t)} dt + \underbrace{\sigma(t)X_t}_{\sigma(t, X_t)} dW_t - dJ_t \quad (8.5)$$

La compensación $\lambda\mathbb{E}[Y | \mathcal{F}_t]$ garantiza que el proceso sin saltos reales sea una semimartingala (Definición 6.1) con la deriva correcta, esencial para la convergencia del esquema numérico.

Se ha desarrollado un modelo Cramér-Lundberg extendido para aproximar las reservas de una aseguradora de vivienda en la Ciudad de México. Este modelo incorpora parámetros dependientes del tiempo, primas ajustadas por inflación (Sección 8.1.1), tasas de interés estocásticas (Sección 8.1.2), volatilidad mediante combinación convexa (Sección 8.1.3) y un proceso de saltos compuesto que modela siniestros catastróficos meteorológicos y sísmicos con intensidades estacionales (Sección 8.1.4).

Dada la complejidad de la ecuación diferencial estocástica con saltos resultante (EDE), cuya solución analítica no es viable ante la no estacionariedad de los parámetros y la estructura de saltos, se requiere métodos numéricos robustos.

Para la simulación, discretizamos con paso $\Delta t = 1/12$ (mensual) y consideramos dos esquemas numéricos.

8.4. Implementación Numérica Métodos Milstein y Semi-Implícito.

Presentando el algoritmo de Milstein compensado (Sección 7.3), escrito en lenguaje natural estructurado (es decir, como un pseudocódigo), diseñado específicamente para aproximar soluciones de ecuaciones diferenciales estocásticas (EDS) con difusión y salto (Capítulo 6), como las que surgen en el modelo de Cramér-Lundberg (Ecuación 6.5) por ejemplo, con componentes de procesos compuestos de Poisson)

El pseudocódigo siguiente está pensado para ser puente conceptual entre la teoría y la implementación, y se enfoca en la versión compensada (es decir, usando el proceso de salto compensado (Definición 5.18) $\tilde{N} = N_t - \lambda t$) para garantizar que el término de salto tenga esperanza cero y sea adecuado para esquemas numéricos estables.

8.4.1. Pseudocódigo: Esquema de Milstein Compensado para EDE con Difusión y Salto.

Algorithm 8.1. *Algoritmo 1: Datos de Entrada - Simulación de Reservas Cramér-Lundberg con Método de Milstein Compensado*

Tipo	Parámetro	Descripción
Entrada	U_0^{hist}	Capital inicial histórico (USD)
	T_{hist}	Horizonte temporal histórico (años)
	T_{fc}	Horizonte de pronóstico (días)
	Δt	Paso de tiempo (1/365)
	$M_{\text{hist}}, M_{\text{fc}}$	Número de trayectorias Monte Carlo
	$N_{\text{pólizas}}$	Número total de pólizas vigentes
	$\text{ceiling}_{\text{póliza}}$	Tope máximo de pérdida por póliza
	$\text{CV}_{\text{meteo}}, \text{CV}_{\text{sismo}}$	Coefficientes de variación
	Parámetros históricos interpolados	$c_{\text{hist}}[i], r_{\text{hist}}[i], \sigma_{\text{hist}}[i], \lambda_{m,\text{hist}}[i]$
	Parámetros pronóstico (enero)	$c_{\text{ene}}, r_{\text{ene}}, \sigma_{\text{ene}}, \lambda_{m,\text{ene}}, \lambda_s$
Salida	$\text{median}_{\text{hist}}, \text{IC}_{5,95}^{\text{hist}}$	Estadísticas periodo histórico
	$\text{median}_{\text{fc}}, \text{IC}_{5,95}^{\text{fc}}$	Estadísticas pronóstico
	$\text{saltos}_{\text{hist}}, \text{saltos}_{\text{fc}}$	Puntos de salto detectados

Algorithm 8.2. *Algoritmo 2: Fase 1 - Simulación histórica con Milstein compensado*

```

#| label: alg-fase1-code
#| eval: false
N_hist ← T_hist / Δt
Inicializar X[M_hist][N_hist + 1] ← 0

for m ← 1 to M_hist do
    X[m][0] ← U_0^hist

    for i ← 0 to N_hist - 1 do
        delta ← |X[m][i] - U_0^hist| / N_polizas

        if delta > ceiling_poliza then
            delta ← ceiling_poliza

        # Generación y compensación de saltos
        total_saltos ← 0
        comp ← 0

        n_meteo ← Poisson(lambda_m,hist[i])

```

```

if n_meteo > 0 then
  p_af ← Uniforme(0.005, 0.02)
  n_af ← max(1, N_polizas · p_af)
  mu_pol ← delta
  sigma_pol ← CV_meteo · mu_pol

  for j ← 1 to n_af do
    perdida ← max(0, Normal(mu_pol, sigma_pol))
    total_saltos ← total_saltos + perdida

E_meteo ← ((0.005 + 0.02) / 2 · N_polizas) · delta
comp ← comp - lambda_m,hist[i] · E_meteo

n_sismo ← Poisson(lambda_s / 365)

if n_sismo > 0 then
  p_af ← Uniforme(0.01, 0.10)
  n_af ← max(1, N_polizas · p_af)
  mu_pol ← delta
  sigma_pol ← CV_sismo · mu_pol

  for j ← 1 to n_af do
    perdida ← max(0, Normal(mu_pol, sigma_pol))
    total_saltos ← total_saltos + perdida

E_sismo ← ((0.01 + 0.10) / 2 · N_polizas) · delta
comp ← comp - (lambda_s / 365) · E_sismo

# Actualización Milstein con compensación
ΔW ← √Δt · Normal(0, 1)

drift ← c_hist[i] · Δt + r_hist[i] · X[m][i] · Δt + comp

diff ← sigma_hist[i] · X[m][i] · ΔW

corr ← (1/2) · (sigma_hist[i])2 · X[m][i] · (ΔW2 - Δt)

X[m][i + 1] ← X[m][i] + drift + diff + corr - total_saltos

# Calcular estadísticas históricas
for i ← 0 to N_hist do
  median_hist[i] ← Mediana(X[·][i])
  IC_5,95^hist[i] ← [Percentil , Percentil ](X[·][i])

```

```

U_0^fc ← median_hist[N_hist]

# FASE 2: Simulación pronóstico
# (estructura idéntica, parámetros constantes enero)
N_fc ← T_fc
Inicializar U[M_fc][N_fc + 1] ← 0

for m ← 1 to M_fc do
    U[m][0] ← U_0^fc

    for i ← 0 to N_fc - 1 do
        delta ← |U[m][i] - U_0^fc| / N_polizas

        if delta > ceiling_poliza then
            delta ← ceiling_poliza

        # Saltos con parámetros constantes de enero
        n_meteo ← Poisson(lambda_m, ene)
        n_sismo ← Poisson(lambda_s / 365)

        # ... (mismos pasos de simulación y compensación que Fase 1)

        ΔW ← √Δt · Normal(0, 1)
        drift ← c_ene · Δt + r_ene · U[m][i] · Δt + comp
        diff ← sigma_ene · U[m][i] · ΔW
        corr ← (1/2) · sigma_ene² · U[m][i] · (ΔW² - Δt)
        U[m][i + 1] ← U[m][i] + drift + diff + corr - total_saltos

# Calcular estadísticas pronóstico
for i ← 0 to N_fc do
    median_fc[i] ← Mediana(U[·][i])
    IC_5,95^fc[i] ← [Percentil , Percentil ](U[·][i])

# Detección de saltos en medianas
log_ret_hist ← ln(median_hist[1:] / median_hist[:-1])

_hist ← 3 · DesvEst(log_ret_hist)

saltos_hist ← {(t_i, median_hist[i]) | |log_ret_hist[i]| > _hist}

# ... (mismo procedimiento para median_fc)

retornar median_hist, IC_5,95^hist, median_fc,

```

IC_{5,95}^{fc}, saltos_hist, saltos_fc

8.4.2. Pseudocódigo: Esquema Semi-Implícito Compensado para EDE con Difusión y Salto

Algorithm 8.3. *Algoritmo 3: Simulación de Reservas Cramér-Lundberg con Método Semi-Implícito Compensado*

Tipo	Parámetro	Descripción
Entrada	U_0	Capital inicial (USD)
	T	Horizonte temporal (años)
	Δt	Paso de tiempo (ej. 1/365 para diario)
	M	Número de trayectorias Monte Carlo
	$N_{\text{pólizas}}$	Número total de pólizas vigentes
	$\text{ceiling}_{\text{póliza}}$	Tope máximo de pérdida por póliza
	$\text{CV}_{\text{meteo}}, \text{CV}_{\text{sismo}}$	Coefficientes de variación para severidad
	Funciones temporales $c(t)$	Tasa de prima ajustada por inflación
	Funciones temporales $r(t)$	Tasa de interés de inversiones
	Funciones temporales $\sigma(t)$	Volatilidad de inversiones
	Funciones temporales $\lambda_m(t)$	Intensidad estacional eventos meteorológicos
	Funciones temporales λ_s	Intensidad constante eventos sísmicos (0.08–0.15 eventos/año)
Salida	$\mathbf{U}[M][N + 1]$	Matriz de trayectorias simuladas de reservas
	$\tilde{U}[N + 1]$	Pronóstico robusto mediante mediana
	$\text{IC}_{5,95}[N + 1]$	Intervalo de confianza al 90 %

Algorithm 8.4. *Algoritmo 4: Fase 1 - Preprocesamiento de parámetros temporales*

```

#| label: alg-semi-fase1-code
#| eval: false
for i ← 0 to N do
  mes ← DeterminarMes(t_i)
  # Prima mensual ajustada por inflación
  c_i ← c(t_i)
  # Tasa CETES + componente global
  r_i ← r(t_i)
  # Combinación convexa de volatilidades
  sigma_i ← sigma(t_i)
  # Intensidad eventos meteorológicos
  lambda_m,i ← (lambda_meteo_anual / 365) × factor_estacional[mes]
  # Intensidad eventos sísmicos
  lambda_s,i ← lambda_sismo / 365

# Almacenar parámetros en vectores indexados por i
Inicializar U[M][N + 1] ← 0

for m ← 1 to M do
  U[m][0] ← U_0

  for i ← 0 to N - 1 do
    # 2.1: Generación de saltos
    n_meteo ← Poisson(lambda_m,i)
    n_sismo ← Poisson(lambda_s,i)

    # 2.2: Cálculo de saltos brutos
    total_saltos ← 0
    delta ← |U[m][i] - U_0| / N_polizas

    if delta > ceiling_poliza then
      delta ← ceiling_poliza

    # Eventos meteorológicos
    if n_meteo > 0 then
      p_af ← Uniforme(0.005, 0.02)
      n_af ← max(1, N_polizas × p_af)
      mu_pol ← delta
      mu_pol ← CV_meteo × mu_pol

      for j ← 1 to n_af do
        perdida ← max(0, Normal(mu_pol, sigma_pol))

```

```

        total_saltos ← total_saltos + perdida

# Eventos sísmicos
if n_sismo > 0 then
    p_af ← Uniforme(0.01, 0.10)
    n_af ← max(1, N_polizas × p_af)
    mu_pol ← delta
    sigma_pol ← CV_sismo × mu_pol

    for j ← 1 to n_af do
        perdida ← max(0, Normal(mu_pol, sigma_pol))
        total_saltos ← total_saltos + perdida

# 2.3: Cálculo de compensación (reducción de varianza)
E_meteo ← (N_polizas × 0.0125) × delta
E_sismo ← (N_polizas × 0.055) × delta
comp ← (-lambda_m,i × E_meteo) + (-lambda_s,i × E_sismo)

# 2.4: Actualización semi-implícita con compensación
ΔW ← √Δt × Normal(0, 1)
numerador ← U[m][i] × (1 + sigma_i ΔW) + c_i Δt + comp - total_saltos
denominador ← 1 - r_i Δt

if denominador ≤ 0 then
    denominador ← 10-12 # Evitar división por cero

U[m][i + 1] ← numerador / denominador

for i ← 0 to N do
    Û[i] ← Mediana(U[1..M][i])
    IC_5,95[i][0] ← Percentil_5(U[1..M][i])
    IC_5,95[i][1] ← Percentil_95(U[1..M][i])

# FASE 4: Detección de saltos en la trayectoria mediana (opcional)
Inicializar log_ret[N]

for i ← 1 to N do
    log_ret[i] ← ln(Û[i] / Û[i - 1])

    ← 3 × DesvEst(log_ret)

Inicializar puntos_salto ←

```

```
for i ← 1 to N do
  if |log_ret[i]| >  then
    Añadir t_i a puntos_salto
retornar  $\tilde{U}$ , IC_5,95, puntos_salto
```


9 Análisis de Resultados.

En este capítulo se presentan y discuten los resultados numéricos obtenidos de la simulación numérica del modelo de Cramér-Lundberg extendido con difusión y saltos, descrito en la Sección 6.2.2, propuesto para la ecuación diferencial estocástica con saltos (EDE) que modela las reservas de la aseguradora. El objetivo central es validar la robustez computacional de los métodos Milstein Compensado (Ecuación 9.1) y Semi-Implicito Compensado (Ecuación 9.2), evaluando su desempeño bajo las condiciones de mercado del sector asegurador de vivienda en la Ciudad de México.

9.1. Simulación Milstein sin Compensación.

Aunque ambos esquemas comparten el **mismo orden de convergencia fuerte** ($\gamma = 1/2$) y satisfacen las condiciones de Lipschitz y crecimiento lineal, la versión compensada fue seleccionada por razones técnicas, numéricas y regulatorias alineadas con el objetivo actuarial del trabajo:

1. **Menor constante de error y cancelación de sesgo:** La compensación introduce explícitamente $-\int_E R(t_n, Y_n, v)\phi(dv)\Delta t$ en la deriva. Esto garantiza $\mathbb{E}[\text{término de saltos}] = 0$, eliminando el sesgo de primer orden y reduciendo la constante C en la cota de convergencia. En la práctica, el error RMS entre mallas se mantiene acotado incluso con Δt relativamente grandes.
2. **Consistencia con la dinámica actuarial del modelo extendido:** La Ecuación 8.5 de la tesis define la deriva neta como $\mu(t, X_t) = c(t) + r(t)X_t - \lambda_{\text{meteo}}(t)\mathbb{E}[Y^{\text{meteo}}] - \lambda_{\text{sismo}}\mathbb{E}[Y^{\text{sismo}}]$. El esquema compensado preserva esta estructura a nivel discreto, asegurando que la simulación refleje fielmente el principio de equivalencia actuarial (primas = siniestros esperados + margen).
3. **Estabilidad numérica con deriva lineal $r(t)X_t$:** Al combinar Milstein compensado con el esquema semi-implícito (Ecuación 7.28), el denominador $1 - r(t_{n+1})\Delta t$ opera sobre un ruido de saltos de media cero. Esto evita amplificaciones explosivas cuando $r(t) > 0$ (caso real en México con $r \approx 8.9\%$ anual). El esquema no compensado arrastra la media de los saltos a la deriva, pudiendo violar la condición de estabilidad $1 - r\Delta t > 0$ en periodos de alta siniestralidad.

4. **Eficiencia en inferencia Monte Carlo y cumplimiento regulatorio:** La CNSF exige proyecciones de reservas robustas y no sesgadas. La versión compensada reduce la varianza intrínseca del estimador, permitiendo alcanzar el IC 90 % con $M = 1000$ trayectorias (como se reporta en la Sección 9.4). Además, facilita la aplicación de técnicas de reducción de varianza (variables de control) al mantener la estructura de martingala.

El código Milstein proporcionado implementado con $a(t, x) = \mu x$, $b(t, x) = \sigma x$ y saltos exponenciales restados directamente. Al comparar con la teoría y los resultados, se identifican limitaciones críticas.




Figura 9.1: Comparación del método de Milstein con saltos para diferentes refinamientos de malla. Panel superior izquierdo: Trayectorias simuladas con malla gruesa ($N=256$) y malla fina ($N=1024$) mostrando la convergencia del esquema numérico. Panel superior derecho: Error absoluto entre la trayectoria de malla gruesa interpolada y la malla fina, evidenciando la precisión del método. Panel inferior: Trayectoria de alta resolución con los saltos del proceso de Poisson compensado marcados con líneas verticales rojas discontinuas.

La gráfica muestra la evolución de las reservas de una aseguradora de vivienda en la CDMX simulada mediante el método de Milstein con saltos compensados durante 2 años (2024-2025).




Figura 9.2: Metodo de Milstein con difusión y saltos aplicados al modelo modelo de Cramér–Lundberg con difusión y saltos, adaptado específicamente para aseguradoras de viviendas.

El esquema de Milstein sin compensación es teóricamente válido y converge con orden $1/2$, pero introduce un sesgo de deriva, aumenta la varianza y degrada la estabilidad en presencia de saltos frecuentes o de magnitud significativa, como los modelados para siniestros hidrometeorológicos y sísmicos en la CDMX. La versión compensada conserva el mismo orden de convergencia, pero elimina el sesgo de primer orden, preserva la estructura de martingala necesaria para las cotas de error, y se alinea con la dinámica actuarial del modelo de Cramér–Lundberg extendido.

9.2. Milstein compensado.

El esquema de Milstein para la componente difusiva, combinado con compensación de saltos, se define como:

$$U_{n+1}^{\text{Mil}} = U_n + \mu(t_n, U_n)\Delta t + \sigma(t_n, U_n)\Delta W_n + \frac{1}{2}\sigma(t_n, U_n)\sigma_U(t_n, U_n) [(\Delta W_n)^2 - \Delta t] - \Delta J_n + \mathcal{C}_n \Delta t, \quad (9.1)$$

donde $\mathcal{C}_n = -[\lambda_{\text{meteo},n}\mathbb{E}[Y_n^{\text{meteo}}] + \lambda_{\text{sismo},n}\mathbb{E}[Y_n^{\text{sismo}}]]$ es el término de compensación. Bajo las condiciones de Lipschitz y crecimiento lineal verificadas este esquema garantiza

convergencia fuerte de orden $\mathcal{O}(\Delta t)$ para la parte continua Kloeden y Platen [20]. El término de corrección $\frac{1}{2}\sigma\sigma_U[(\Delta W)^2 - \Delta t]$ es esencial para capturar la no linealidad de la difusión $\sigma(t)U(t)$, especialmente relevante ante la volatilidad estacional observada en σ_t (Tabla 8.3).

9.3. Semi-Implícito compensado.

El esquema semi-implícito trata el término de interés $r(t)U(t)$ de forma implícita:

$$U_{n+1}^{\text{SI}} = \frac{U_n [1 + \sigma(t_n, U_n)\Delta W_n] + c(t_n)\Delta t + \mathcal{C}_n\Delta t - \Delta J_n^{\text{bruto}}}{1 - r(t_n)\Delta t}, \quad (9.2)$$

donde $\Delta J_n^{\text{bruto}}$ es la suma no compensada de saltos ocurridos. Este esquema es incondicionalmente estable para $r(t) > 0$ Higham, Mao y Stuart [12], ya que el denominador $1 - r(t_n)\Delta t > 0$ (dado $r_{\text{máx}} \approx 0.6\%$ mensual y $\Delta t = 1/365$). La estabilidad numérica es crítica ante la alta sensibilidad de las reservas a fluctuaciones en $r(t)$, como se observa en la estructura de tasas de Banxico (Banco de México [6]).

9.4. Análisis Cuantitativo de la Simulación

Se presentan las definiciones operativas de los esquemas numéricos, destacando sus fundamentos teóricos: la corrección de Milstein para la parte difusiva y el tratamiento implícito del término de interés para garantizar estabilidad incondicional.

En el cual se ejecutaron $N_{\text{sim}} = 1000$ trayectorias Monte Carlo para el periodo histórico (enero 2024 - diciembre 2025) y pronóstico de enero 2026, con semilla fija (2024–2025 para histórico, 2026 para pronóstico) para reproducibilidad. La cartera simulada corresponde a $N_{\text{pólizas}} = 6,800$ pólizas, representando aproximadamente el 40 % del mercado total de seguros de vivienda en la CDMX

Tabla 9.1: Comparación cuantitativa de resultados para enero 2026 Milstein vs. Semi-Implícito (millones USD).

Métrica	Milstein Compensado	Semi-Implícito Compensado	Diferencia Relativa
Reserva inicial (U_0)	520.00	520.00	0.00 %
Mediana final	528.45	540.60	+2.30 %
Límite inferior IC 90 % (5 %)	512.30	521.50	+1.80 %
Límite superior IC 90 % (95 %)	545.80	559.20	+2.46 %

Métrica	Milstein Compensado	Semi-Implicito Compensado	Diferencia Relativa
Ancho IC 90 %	33.50	37.70	+12.54 %
Desviación estándar final	8.21	9.15	+11.45 %
Error estándar de la mediana	0.26	0.29	+11.54 %

9.4.1. Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein vs Semi-Implicito y Compensación.

Reservas de la Aseguradora: Histórico (2024–2025) + Pronóstico Ene 2026




Figura 9.3: Trayectorias implementadas por el método Milstein, medianas e intervalos de confianza 90 % (5 %-95 %) para ambos esquemas. Los marcadores ✕ (rojos) y ★ (azules) indican saltos detectados en las medianas histórica y de pronóstico, respectivamente. La línea vertical discontinua marca el inicio del pronóstico (enero 2026).

Reservas de la Aseguradora: Histórico (2024–2025) + Pronóstico Ene 2026




Figura 9.4: Trayectorias implementadas por el método Semi-Implicito, medianas e intervalos de confianza 90 % (5 %-95 %) para ambos esquemas. Los marcadores $\times$ (rojos) y $\star$ (azules) indican saltos detectados en las medianas histórica y de pronóstico, respectivamente. La línea vertical discontinua marca el inicio del pronóstico (enero 2026).

9.5. Análisis de la Trayectoria Mediana y Estructura de Saltos

La Figura 9.15 y la Figura 9.4 presenta las trayectorias medianas e intervalos de confianza. Se observan tres hallazgos críticos:

- a) **Sesgo sistemático en la tendencia:** El esquema semi-implícito genera reservas medianas consistentemente superiores (+2.30 % al final del periodo). Esto se explica matemáticamente por la desigualdad:

$$\frac{1}{1 - r\Delta t} > 1 + r\Delta t + \mathcal{O}((r\Delta t)^2), \quad \forall r\Delta t \in (0, 1), \quad (9.3)$$

que amplifica el efecto de capitalización del término $r(t)U(t)$. En contextos de tasas de interés positivas (como el mexicano con $r_{\text{prom}} \approx 5.6\%$ anual), este sesgo actúa como un factor de conservadurismo deseable para gestión de solvencia.

- b) **Patrón estacional de saltos:** Ambos métodos detectan 7 saltos significativos en la trayectoria mediana durante el periodo histórico, con concentración en agosto-septiembre (61.1 % de los saltos), coincidiendo con la temporada de huracanes (Figura 9.15, Figura 9.4 marcadores rojos/azules). La coincidencia espacio-temporal de los saltos (94.4 % en las mismas fechas) valida la robustez de la modelación estado-dependiente de $c(t, x, v)$.
- c) **Comportamiento asintótico del intervalo de confianza:** El ancho del IC 90 % crece un 12.54 % más rápido en el esquema Semi-implícito. Esto refleja una mayor dispersión en las trayectorias extremas, atribuible a la no linealidad introducida por el denominador $1 - r(t_n)\Delta t$ en la Ecuación 9.2, que amplifica las realizaciones con $\Delta W_n > 0$.

9.5.1. Análisis de Monte Carlo y Pronóstico mediante Mediana

La elección de la mediana como estadístico de pronóstico es rigurosamente justificable en este contexto:

- **Robustez ante colas pesadas:** La distribución de reservas presenta asimetría negativa ($\gamma_1 \approx -0.85$) debido a los saltos catastróficos. La mediana es invariante ante transformaciones monótonas y menos sensible a outliers que la media (Huber y Ronchetti [14]), crucial para evitar subestimación de riesgos extremos.
- **Consistencia con principios actuariales:** La CNSF exige en su Circular Única (Capítulo 7.3.2) que las proyecciones de reservas utilicen medidas de tendencia central robustas ante eventos de baja frecuencia y alta severidad. La mediana satisface este requisito regulatorio.
- **Eficiencia estadística:** Para $N_{\text{sim}} = 1000$, el error estándar de la mediana es $EE(\tilde{U}) \approx \frac{1.253\sigma}{\sqrt{N_{\text{sim}}}}$ [19], comparable al error de la media ($\sigma/\sqrt{N_{\text{sim}}}$) pero con menor sesgo ante no normalidad. Los resultados muestran $EE^{\text{Mil}} = 0.26$ y $EE^{\text{SI}} = 0.29$, dentro de márgenes aceptables para toma de decisiones.

9.6. Distribución de severidad de los saltos detectados y distribución de los tiempos entre detecciones

La presente sección constituye la continuación del análisis de la trayectoria mediana desarrollado en las Secciones 9.5.1–9.5.4 y de la formulación metodológica establecida en las Secciones Sección 6.4.2 y 6.4.3. Mientras que en la Sección 9.5 se estudia la trayectoria agregada mediante estadísticos del ensamble, en esta sección se utiliza la información completa de las $N_{\text{sim}} = 1000$ trayectorias simuladas mediante los esquemas de **Milstein compensado** y **Semi-Implícito compensado**.

Los resultados presentados corresponden directamente a las salidas generadas por los programas. Ambos experimentos emplean la misma semilla aleatoria 2026, $N_{\text{sim}} = 1000$, horizonte $T = 2$ años, paso temporal $\Delta t = 1/365$ y ventana local de bipotencia $K = 27$.

9.6.1. Configuración común y calibración del detector

La detección de saltos se realiza sobre las trayectorias completas de cada esquema. Para cada observación se utiliza el umbral

$$\tau_n(t_{i-1}) = \alpha \hat{\sigma}(t_{i-1}) \Delta_n^\varpi, \quad (9.4)$$

donde $\hat{\sigma}$ es la estimación local de escala obtenida mediante la construcción de variación bipotencia agregada y (α, ϖ) determina el nivel de sensibilidad del detector. La formulación está relacionada con los procedimientos de detección no paramétrica mediante umbral desarrollados para procesos con difusión estocástica y saltos [23], mientras que la utilización de estadísticos normalizados para detectar saltos constituye un antecedente relacionado en [leemykland2008].

El cual genera una tabla de sensibilidad para

$$\alpha \in \{2.00, 2.25, \dots, 5.00\}, \quad \varpi \in \{0.40, 0.45, 0.49\}. \quad (9.5)$$

El par $(\alpha, \varpi) = (3.5, 0.45)$ se fija como configuración de referencia para el resto del análisis. Por tanto, $(3.5, 0.45)$ constituye una configuración de referencia del experimento reproducible y no un estimador universalmente óptimo.

En la configuración de referencia se obtuvieron 1,422 detecciones válidas en cada esquema.

Tabla 9.2: Configuración común y resultados del detector en la configuración de referencia.

Parámetro	Milstein compensado	Semi-Implícito compensado
Semilla	2026	2026
N_{sim}	1000	1000
T (años)	2	2
Δt	1/365	1/365
K	27	27
α	3.50	3.50
ϖ	0.45	0.45
Detecciones válidas	1,422	1,422
Trayectorias con detección	749	749
Detecciones por trayectoria	1.422	1.422
Detecciones descartadas por signo/no finitas	1	1

9.6.1.1. Sensibilidad del detector

La tabla siguiente reproduce la salida completa de sensibilidad del programa de Milstein compensado. Además del número de detecciones, se reportan los estadísticos de severidad y las cantidades auxiliares calculadas por el programa. El patrón observado es el esperado para un detector por umbral: al aumentar α , disminuye el número de detecciones retenidas y aumenta la magnitud típica de las severidades seleccionadas. Esta relación describe el comportamiento de la regla de detección; no debe interpretarse como evidencia de que un valor particular de α sea óptimo.

9.6.1.2. Milstein compensado

Tabla 9.3: Tabla completa de sensibilidad del detector para Milstein compensado.

ϖ	α	De- tec- cio- nes	Tra- yectorias con detección	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- carta- das	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.40	2.00	2,285	890	1,188,180	1,459,492	2,396,172	87	3.09e-04	0.1982	0.1294
0.40	2.25	1,832	838	1,341,930	1,608,722	2,589,948	18	4.93e-05	0.1610	0.0794
0.40	2.50	1,537	776	1,448,471	1,734,602	2,718,100	2	6.49e-06	0.1601	0.0989
0.40	2.75	1,291	723	1,591,738	1,868,482	2,891,753	0	7.02e-07	0.1387	0.0607
0.40	3.00	1,112	670	1,688,293	1,992,383	3,041,564	0	6.24e-08	0.1223	0.0496
0.40	3.25	976	625	1,772,013	2,090,033	3,165,280	0	4.55e-09	0.1291	0.0503
0.40	3.50	850	570	1,861,064	2,204,433	3,337,568	0	2.72e-10	0.1024	0.0454
0.40	3.75	763	531	1,945,562	2,300,702	3,452,258	0	1.33e-11	0.1153	0.0513
0.40	4.00	675	491	2,045,362	2,407,683	3,583,428	0	5.36e-13	0.0963	0.0368
0.40	4.25	610	456	2,120,692	2,494,183	3,697,444	0	1.76e-14	0.1148	0.0372
0.40	4.50	540	420	2,199,604	2,597,833	3,869,699	0	4.74e-16	0.0833	0.0342

ϖ	α	De- tec- cio- nes	Tra- yectorias con detección	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- cartas	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.40	4.75	495	395	2,274,883	2,681,563	3,908,596	0	1.05e-17	0.0909	0.0451
0.40	5.00	450	366	2,377,570	2,769,513	3,993,264	0	1.88e-19	nan	nan
0.45	2.00	5,843	998	726,124	947,711	1,668,682	151	7.23e-03	0.3635	0.2822
0.45	2.25	3,719	975	931,050	1,161,681	1,995,860	761	2.51e-03	0.2772	0.1762
0.45	2.50	2,688	930	1,095,063	1,354,402	2,258,920	228	7.86e-04	0.1853	0.1102
0.45	2.75	2,190	881	1,215,784	1,488,582	2,445,464	63	2.21e-04	0.1534	0.1001
0.45	3.00	1,854	842	1,337,496	1,599,652	2,586,237	21	5.59e-05	0.1327	0.0632
0.45	3.25	1,608	790	1,421,993	1,701,443	2,698,448	5	1.27e-05	0.1157	0.0640
0.45	3.50	1,422	749	1,513,050	1,792,983	2,799,988	1	2.59e-06	0.1301	0.0807
0.45	3.75	1,237	705	1,635,111	1,905,202	2,938,307	0	4.74e-07	0.0946	0.0292
0.45	4.00	1,120	673	1,682,821	1,985,893	3,040,664	0	7.77e-08	0.0902	0.0378
0.45	4.25	1,019	639	1,746,482	2,056,953	3,127,344	0	1.14e-08	0.0883	0.0363
0.45	4.50	929	604	1,809,892	2,129,503	3,214,114	0	1.50e-09	0.0990	0.0347
0.45	4.75	837	565	1,872,652	2,217,963	3,345,080	0	1.77e-10	0.0753	0.0325
0.45	5.00	774	536	1,933,572	2,288,783	3,437,259	0	1.87e-11	nan	nan
0.49	2.00	16,232	1,000	514,047	642,930	1,012,392	984	3.39e-02	0.3938	0.1649
0.49	2.25	9,840	1,000	598,821	769,667	1,296,064	951	1.70e-02	0.3710	0.1845
0.49	2.50	6,189	998	709,280	924,610	1,638,372	370	8.00e-03	0.3236	0.2302

ϖ	α	De- tec- cio- nes	Tra- yecto- rias con detec- ción	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- carta- das	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.49	2.75	4,186	984	872,521	1,099,688	1,899,086	1,048	3.53e-03	0.2525	0.1657
0.49	3.00	3,129	960	1,017,089	1,258,802	2,141,951	438	1.46e-03	0.1978	0.1138
0.49	3.25	2,510	915	1,132,826	1,397,782	2,304,595	166	5.66e-04	0.1367	0.0796
0.49	3.50	2,167	880	1,223,026	1,495,812	2,458,423	59	2.05e-04	0.1269	0.0812
0.49	3.75	1,892	851	1,322,306	1,585,572	2,570,102	23	6.95e-05	0.1015	0.0522
0.49	4.00	1,700	809	1,391,370	1,662,262	2,657,854	6	2.20e-05	0.0959	0.0410
0.49	4.25	1,537	776	1,448,471	1,734,602	2,718,100	3	6.54e-06	0.0995	0.0605
0.49	4.50	1,384	743	1,536,058	1,813,512	2,824,381	0	1.81e-06	0.1069	0.0647
0.49	4.75	1,236	704	1,635,489	1,905,872	2,938,473	0	4.69e-07	0.0744	0.0209
0.49	5.00	1,144	680	1,669,660	1,966,258	3,001,393	0	1.13e-07	nan	nan

9.6.1.3. Semi-Implicito compensado

Tabla 9.4: Tabla completa de sensibilidad del detector para Semi-Implicito compensado.

ϖ	α	De- tec- cio- nes	Tra- yecto- rias con detec- ción	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- carta- das	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.40	2.00	2,286	890	1,188,249	1,459,222	2,395,559	85	3.09e-04	0.1986	0.1294
0.40	2.25	1,832	838	1,341,991	1,608,772	2,589,989	17	4.93e-05	0.1610	0.0794

ϖ	α	De- tec- cio- nes	Tra- yectorias con detección	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- cartas	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.40	2.50	1,537	776	1,448,486	1,734,642	2,718,111	2	6.49e-06	0.1601	0.0989
0.40	2.75	1,291	723	1,591,721	1,868,520	2,891,782	0	7.02e-07	0.1387	0.0607
0.40	3.00	1,112	670	1,688,304	1,992,423	3,041,655	0	6.24e-08	0.1223	0.0496
0.40	3.25	976	625	1,772,042	2,090,073	3,165,375	0	4.55e-09	0.1291	0.0502
0.40	3.50	850	570	1,861,032	2,204,473	3,337,681	0	2.72e-10	0.1012	0.0452
0.40	3.75	764	531	1,945,073	2,299,640	3,450,501	0	1.33e-11	0.1165	0.0516
0.40	4.00	675	491	2,045,363	2,407,723	3,583,530	0	5.36e-13	0.0963	0.0369
0.40	4.25	610	456	2,120,912	2,494,226	3,697,489	0	1.76e-14	0.1148	0.0372
0.40	4.50	540	420	2,199,743	2,597,878	3,869,722	0	4.74e-16	0.0833	0.0342
0.40	4.75	495	395	2,274,892	2,681,613	3,908,629	0	1.05e-17	0.0909	0.0451
0.40	5.00	450	366	2,377,590	2,769,563	3,993,400	0	1.88e-19	nan	nan
0.45	2.00	5,853	998	725,765	947,199	1,666,482	2,146	7.23e-03	0.3641	0.2828
0.45	2.25	3,722	975	930,995	1,161,249	1,994,714	757	2.51e-03	0.2773	0.1761
0.45	2.50	2,690	930	1,094,982	1,354,012	2,258,838	223	7.86e-04	0.1855	0.1102
0.45	2.75	2,191	881	1,215,699	1,488,270	2,444,827	63	2.21e-04	0.1538	0.1003
0.45	3.00	1,854	842	1,337,615	1,599,702	2,586,241	21	5.59e-05	0.1327	0.0631
0.45	3.25	1,608	790	1,421,994	1,701,482	2,698,451	5	1.27e-05	0.1157	0.0641
0.45	3.50	1,422	749	1,513,140	1,793,022	2,799,989	1	2.59e-06	0.1294	0.0803

ϖ	α	De- tec- cio- nes	Tra- yectorias con detección	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- cartas	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.45	3.75	1,238	706	1,634,652	1,904,872	2,938,140	0	4.74e-07	0.0953	0.0295
0.45	4.00	1,120	673	1,682,881	1,985,931	3,040,712	0	7.77e-08	0.0902	0.0378
0.45	4.25	1,019	639	1,746,453	2,056,992	3,127,354	0	1.14e-08	0.0883	0.0363
0.45	4.50	929	604	1,809,923	2,129,543	3,214,225	0	1.50e-09	0.0990	0.0347
0.45	4.75	837	565	1,872,662	2,217,993	3,345,130	0	1.77e-10	0.0753	0.0326
0.45	5.00	774	536	1,933,662	2,288,823	3,437,309	0	1.87e-11	nan	nan
0.49	2.00	16,248	1,000	514,115	642,941	1,012,463	9,960	3.39e-02	0.3937	0.1648
0.49	2.25	9,851	1,000	598,820	769,513	1,295,498	1,937	1.70e-02	0.3710	0.1845
0.49	2.50	6,196	998	709,298	924,372	1,637,565	2,366	8.00e-03	0.3236	0.2300
0.49	2.75	4,191	984	872,442	1,099,401	1,897,956	1,043	3.53e-03	0.2524	0.1647
0.49	3.00	3,133	960	1,016,114	1,257,932	1,141,707	438	1.46e-03	0.1982	0.1144
0.49	3.25	2,512	915	1,132,331	1,397,251	1,304,279	166	5.66e-04	0.1369	0.0798
0.49	3.50	2,168	880	1,222,719	1,495,482	1,457,328	59	2.05e-04	0.1268	0.0813
0.49	3.75	1,893	852	1,322,166	1,585,292	1,568,388	23	6.95e-05	0.1020	0.0524
0.49	4.00	1,700	809	1,391,441	1,662,312	1,657,916	6	2.20e-05	0.0959	0.0410
0.49	4.25	1,537	776	1,448,486	1,734,642	1,718,111	2	6.54e-06	0.0995	0.0605
0.49	4.50	1,384	743	1,536,061	1,813,552	1,824,381	0	1.81e-06	0.1069	0.0647
0.49	4.75	1,236	704	1,635,474	1,905,912	1,938,477	0	4.69e-07	0.0744	0.0209

ϖ	α	De- tec- cio- nes	Tra- yecto- rias con detec- ción	Me- diana (USD)	Me- dia (USD)	$q_{0.90}$ (USD)	Des- carta- das	P_{FP} aprox.	Cam- bio relati- vo N	Cam- bio relati- vo me- diana
0.49	5.00	1,144	680	1,669,659	1,966,298	3,001,510	0	1.13e- 07	nan	nan

9.6.2. Distribución agregada de las severidades detectadas

Para cada esquema $q \in \{\text{Mil}, \text{SI}\}$ se construye una única muestra agregada de severidades positivas detectadas,

$$y_q = \left\{ \widehat{Y}_i^{(q,j)} : i \in D^{(q,j)}, \widehat{Y}_i^{(q,j)} > 0 \right\}. \quad (9.6)$$

Esta muestra contiene las detecciones provenientes de las 1000 trayectorias. En consecuencia, la cantidad estimada es la distribución marginal de las severidades detectadas por el procedimiento estadístico.

Tabla 9.5: Estadísticos de la distribución agregada de severidades y sus intervalos bootstrap.

Estadístico	Milstein compensado	Semi-Implicito compensado
Número de severidades detectadas	1,422	1,422
Media (USD)	1,792,982.74	1,793,024.23
Mediana (USD)	1,513,050.23	1,513,140.12
IC 95 % de la media	[1,733,759.19; 1,854,807.13]	[1,733,800.71; 1,854,849.50]
IC 95 % de la mediana	[1,466,575.04; 1,566,256.61]	[1,466,569.85; 1,566,329.17]

La diferencia entre las medias de severidad es

$$\Delta \bar{Y} = \bar{Y}_{\text{SI}} - \bar{Y}_{\text{Mil}} = 41.489063 \text{USD}, \quad (9.7)$$

equivalente aproximadamente a 0.00231 % de la media de Milstein. Para las medianas,

$$\Delta \text{Med}(Y) = \text{Med}(Y_{\text{SI}}) - \text{Med}(Y_{\text{Mil}}) = 89.884675 \text{USD}, \quad (9.8)$$

equivalente aproximadamente a 0.00594 %. Por tanto, en esta realización las diferencias numéricas entre ambos esquemas son pequeñas en relación con la escala de las severidades detectadas.

9.6.3. Estimación no paramétrica mediante ECDF

La estimación no paramétrica de la función de distribución se obtiene mediante la función de distribución empírica,

$$\widehat{F}_{Y,q}(y) = \frac{1}{n_Y} \sum_{\ell=1}^{n_Y} \mathbf{1}_{\{Y_{\ell} \leq y\}}. \quad (9.9)$$

La ECDF no requiere seleccionar una familia paramétrica para describir la severidad y constituye, por tanto, la representación principal de la distribución acumulada estimada. La figura correspondiente permite comparar directamente la distribución empírica obtenida por ambos esquemas.




Figura 9.5: Función de distribución empírica de las severidades detectadas mediante el esquema de Milstein Compensado.




Figura 9.6: Función de distribución empírica de las severidades detectadas mediante el esquema Semi-Implícito Compensado.

9.7. 9.6.2.2. Estimación de densidad mediante KDE

Para representar suavemente la densidad de severidad, el programa transforma la variable mediante

$$Z = \log(Y), \quad (9.10)$$

y estima la densidad de Z mediante un estimador de núcleo. La transformación inversa requiere incorporar el jacobiano correspondiente,

$$\hat{f}_{Y,q}(y) = \frac{1}{y} \hat{f}_{Z,q}(\log y), \quad y > 0. \quad (9.11)$$

La utilización de métodos de núcleo para estimación no paramétrica de densidades se encuentra establecida en [silverman1986].

A partir del conjunto agregado de severidades de los saltos detectados en las (1000) trayectorias simuladas mediante cada uno de los esquemas numéricos, se obtuvo una estimación no paramétrica de la densidad de severidad mediante el método de estimación por núcleos (Kernel Density Estimation, KDE). La estimación se construyó directamente a partir de las observaciones detectadas, sin imponer una familia paramétrica para la distribución subyacente. En las figuras correspondientes, el histograma representa la distribución empírica de las severidades en términos de densidad, mientras que la curva suavizada corresponde a $\hat{f}_Y(y)$. La forma obtenida permite identificar las regiones de mayor concentración de severidades y observar el comportamiento de la cola derecha de la muestra




Figura 9.7: Estimación no paramétrica de la densidad de las severidades de los saltos detectados en las trayectorias generadas mediante el esquema Milstein compensado.




Figura 9.8: Estimación no paramétrica de la densidad de las severidades de los saltos detectados en las trayectorias generadas mediante el esquema Semi-Implicito Compensado.

9.7.1. Ajustes paramétricos auxiliares

Como complemento descriptivo de la estimación no paramétrica se ajustaron las familias Lognormal, Gamma y Weibull. Estos modelos no sustituyen la ECDF ni la KDE; se emplean para disponer de representaciones paramétricas comparables mediante máxima verosimilitud y el criterio de información de Akaike,

$$AIC = 2k - 2\hat{\ell}, \quad (9.12)$$

donde k es el número de parámetros estimados y $\hat{\ell}$ es la log-verosimilitud maximizada. El AIC se utiliza únicamente para comparar las tres familias implementadas en el programa [3].

Tabla 9.6: Ajustes paramétricos auxiliares de severidad: Milstein compensado.

Familia	Milstein: logLik	Milstein: AIC	Parámetros
Lognormal	-21,197.836650	42,399.673300	$\mu_{\log} = 14.276370$, $\sigma_{\log} = 0.454640$
Gamma	-21,350.264824	42,704.529647	shape = 4.223838, scale = 424, 491.405
Weibull	-21,572.054840	43,148.109681	shape = 1.664944, scale = 2, 020, 400.435

Tabla 9.7: Ajustes paramétricos auxiliares de severidad: Semi-Implícito compensado.

Familia	Semi-Implícito: logLik	Semi-Implícito: AIC	Parámetros
Lognormal	-21,197.860641	42,399.721281	$\mu_{\log} = 14.276395$, $\sigma_{\log} = 0.454636$
Gamma	-21,350.286911	42,704.573822	shape = 4.223916, scale = 424, 493.379
Weibull	-21,572.080175	43,148.160350	shape = 1.664955, scale = 2, 020, 447.324

En ambos esquemas la familia Lognormal presenta el menor AIC dentro del conjunto de tres familias consideradas. La diferencia de AIC respecto de Gamma es aproximadamente 304.86, mientras que respecto de Weibull es aproximadamente 748.44.

9.7.2. Distribución de los tiempos entre detecciones

Los tiempos entre detecciones se calculan exclusivamente dentro de cada trayectoria. Si

$$\tau_1^{(j)} < \tau_2^{(j)} < \dots < \tau_{K_j}^{(j)} \quad (9.13)$$

son los tiempos detectados en la trayectoria j , los gaps completos se definen mediante

$$\Delta\tau_k^{(j)} = \tau_k^{(j)} - \tau_{k-1}^{(j)}, \quad k = 2, \dots, K_j. \quad (9.14)$$

En la realización estudiada se obtuvieron 673 gaps completos y 749 observaciones censuradas al final del horizonte de observación.

Tabla 9.8: Estadísticos descriptivos de los tiempos entre detecciones.

Estadístico	Milstein compensado	Semi-Implicito compensado
<i>Gaps</i> completos	673	673
Censuras terminales	749	749
Media (días)	196.5973	196.5973
Mediana (días)	147	147
CV^2	0.677208	0.677208

El coeficiente de variación cuadrático se calcula mediante

$$CV^2 = \frac{\text{Var}(\Delta\tau)}{[\mathbb{E}(\Delta\tau)]^2}. \quad (9.15)$$

El valor $CV^2 = 0.677208$ es inferior a uno. Esta observación es puramente descriptiva: no constituye por sí misma una prueba de un proceso de Poisson ni permite ignorar la censura o la posible dependencia entre detecciones.




Figura 9.9: Histograma de *gaps* completos para Milstein compensado.




Figura 9.10: Histograma de *gaps* completos para Semi-Implicito compensado.

9.7.2.1. Censura administrativa y verosimilitud

Si una trayectoria presenta una última detección en $\tau_{K_j}^{(j)}$ y no se observa una detección posterior antes de T , el tiempo hasta el siguiente evento es desconocido. La información disponible es que dicho tiempo excede la duración restante

$$C^{(j)} = T - \tau_{K_j}^{(j)}. \quad (9.16)$$

La verosimilitud paramétrica utiliza la contribución de densidad para los intervalos completos y la función de supervivencia para las observaciones censuradas,

$$\ell_q(\theta) = \sum_{\text{completos}} \log f(\Delta\tau; \theta) + \sum_{\text{censurados}} \log S(C; \theta). \quad (9.17)$$

Este tratamiento corresponde a la formulación estándar de inferencia con censura por la derecha en procesos de conteo y análisis de supervivencia [andersen1993, kaplanmeier1958, 1].




Figura 9.11: Supervivencia de los tiempos entre detecciones para Milstein compensado.




Figura 9.12: Supervivencia de los tiempos entre detecciones para Semi-Implícito compensado.

9.7.2.2. Ajustes paramétricos auxiliares para los tiempos

El programa ajusta exclusivamente las familias Exponencial, Weibull y Gamma utilizando la verosimilitud censurada de Ecuación 9.17. Para el caso homogéneo de un proceso de Poisson con intensidad constante λ , los tiempos entre eventos presentan distribución Exponencial. Sin embargo, la sola comparación con una familia Exponencial no implica que el proceso de detecciones sea homogéneo [andersen1993].

Tabla 9.9: Ajustes temporales censurados: Milstein compensado.

Familia	Milstein: logLik	Milstein: AIC	Parámetros
Exponencial	-4,832.743080	9,667.486161	rate = 0.002068509
Weibull	-4,832.116455	9,668.232911	shape = 1.036538, scale = 476.216322

Familia	Milstein: logLik	Milstein: AIC	Parámetros
Gamma	-4,832.237563	9,668.475126	shape = 1.043957, scale = 454.015731

Tabla 9.10: Ajustes temporales censurados: Semi-Implicito compensado.

Familia	Semi-Implicito: logLik	Semi-Implicito: AIC	Parámetros
Exponencial	-4,832.743080	9,667.486161	rate = 0.002068509
Weibull	-4,832.116455	9,668.232911	shape = 1.036538, scale = 476.216322
Gamma	-4,832.237563	9,668.475126	shape = 1.043957, scale = 454.015731

La Exponencial presenta el menor AIC en ambos esquemas. La diferencia respecto de Weibull es aproximadamente 0.747 y respecto de Gamma aproximadamente 0.989. Las diferencias son pequeñas en escala absoluta de AIC; por ello, el resultado debe interpretarse como una comparación dentro del conjunto de familias implementadas y no como una identificación concluyente de la ley generadora de los tiempos.

9.7.2.3. Bootstrap de los tiempos

La incertidumbre de las estadísticas temporales se obtiene mediante bootstrap por trayectoria. Los intervalos percentiles reportados por el programa son

Tabla 9.11: Intervalos bootstrap de los estadísticos de los tiempos entre detecciones.

Estadístico	Milstein compensado	Semi-Implicito compensado
Media, IC 95 % (días)	[185.419; 209.735]	[185.419; 209.735]
Mediana, IC 95 % (días)	[132.000; 166.512]	[132.000; 166.512]
CV^2 , IC 95 %	[0.6108; 0.7445]	[0.6108; 0.7445]

9.7.3. Estimación de la intensidad estacional de las detecciones

La intensidad se estima mediante un kernel gaussiano circular anual. Para un día del año t y tiempos de detección $\tau_k^{(j)}$, se utiliza una distancia circular con periodo anual de 365 días y se consideran los anchos de banda

$$b \in \{30, 60, 91, 182\} \text{ días.} \quad (9.18)$$

La estimación mediante funciones núcleo pertenece al marco no paramétrico de estimación de intensidades de procesos de puntos [26]. El programa conserva las cuatro curvas y utiliza $b = 30$ días como referencia gráfica.

Tabla 9.12: Sensibilidad de la intensidad estimada al ancho de banda para las detecciones.

Ancho de banda b (días)	Mínimo	Máximo	Media
30	0.002372	0.005481	0.003896
60	0.002897	0.004835	0.003887
91	0.003188	0.004258	0.003721
182	0.002555	0.002777	0.002665




Figura 9.13: Intensidad circular anual estimada para Milstein compensado.




Figura 9.14: Intensidad circular anual estimada para Semi-Implícito compensado.

En la realización Monte Carlo estudiada, los índices temporales de detección de ambos esquemas coinciden, por lo que las curvas de intensidad obtenidas a partir de esas detecciones coinciden numéricamente. Esta igualdad es una propiedad de esta ejecución y no una propiedad teórica general de los dos esquemas.

9.7.4. Diagnóstico mediante el cambio de tiempo

Sea Λ el compensador verdadero del proceso de detecciones. El teorema de cambio de tiempo establece, bajo sus hipótesis de regularidad, que los incrementos del tiempo transformado construidos con el compensador verdadero presentan distribución Exponencial de parámetro uno [7].

En el análisis computacional, sin embargo, el compensador se estima a partir de las mismas detecciones. El programa calcula

$$\widehat{\Delta S}_k = \widehat{\Lambda}(\tau_k) - \widehat{\Lambda}(\tau_{k-1}), \quad (9.19)$$

y posteriormente

$$V_k = 1 - \exp\left(-\widehat{\Delta S}_k\right). \quad (9.20)$$

Si el modelo estuviera correctamente especificado y el compensador verdadero fuera conocido, la transformación produciría variables Uniforme(0, 1). En el presente experimento $\widehat{\Lambda}$ es estimado de las propias detecciones; por ello, el estadístico

$$D_{\text{TR},q} = \sup_{u \in [0,1]} \left| \widehat{F}_{V,q}(u) - u \right| \quad (9.21)$$

se utiliza únicamente como diagnóstico de cambio de tiempo.

Tabla 9.13: Diagnóstico basado en residuos de cambio de tiempo.

Diagnóstico	Milstein compensado	Semi-Implicito compensado
Número de residuos	673	673
Media de V_k	0.464129	0.464129
Mediana de V_k	0.459566	0.459566
D_{TR}	0.076027	0.076027

La igualdad observada en esta ejecución deriva de la coincidencia de las detecciones temporales entre ambos esquemas.

9.7.5. Comparación integrada de los resultados

Tabla 9.14: Comparación integrada de las distribuciones de severidad y tiempos entre detecciones.

Resultado	Milstein compensado	Semi-Implicito compensado
Detecciones válidas	1,422	1,422
Media de severidad (USD)	1,792,982.74	1,793,024.23
Mediana de severidad (USD)	1,513,050.23	1,513,140.12
Familia paramétrica auxiliar de severidad con menor AIC	Lognormal	Lognormal
<i>Gaps</i> completos	673	673
Censuras terminales	749	749
Media del <i>gap</i> (días)	196.5973	196.5973
Mediana del <i>gap</i> (días)	147	147

Resultado	Milstein compensado	Semi-Implícito compensado
CV^2	0.677208	0.677208
Familia temporal con menor AIC	Exponencial	Exponencial
D_{TR}	0.076027	0.076027

Los resultados muestran que, para esta realización, ambos esquemas producen exactamente el mismo número de detecciones y la misma estructura temporal de detecciones, mientras que las severidades agregadas presentan diferencias numéricas muy pequeñas. La diferencia relativa de las medias de severidad es aproximadamente 0.00231 %, y la diferencia relativa de las medianas es aproximadamente 0.00594 %. Asimismo, los ajustes paramétricos auxiliares presentan valores de AIC prácticamente coincidentes entre ambos métodos.

La coincidencia de los resultados temporales no debe confundirse con una equivalencia teórica de los esquemas numéricos. La inferencia aquí presentada es condicional a la realización Monte Carlo concreta y a la configuración del detector $(\alpha, \varpi) = (3.5, 0.45)$.

La interpretación estadística de los resultados se sustenta en el marco desarrollado en las Secciones 6.4.2 y 6.4.3 y en las referencias bibliográficas de la tesis: detección no paramétrica de saltos [leemykland2008, 23], variación bipotencia [barndorff2004], estimación de densidad mediante núcleos [silverman1986], procesos de conteo y análisis de supervivencia [andersen1993, 1], estimación de intensidades mediante funciones núcleo [26], tratamiento de censura [kaplanmeier1958], criterio de información de Akaike [3], bootstrap [efrontibshirani1993] y cambio de tiempo para procesos de eventos [7].

9.8. Implicaciones para la Gestión de Riesgos en el Contexto de la CDMX

Para una aseguradora operando en la CDMX con exposición significativa a riesgos catastróficos, el esquema semi-implícito compensado ofrece tres ventajas críticas sobre Milstein:

1. **Conservadurismo alineado con prudencia regulatoria:** El +2.30 % adicional en la reserva mediana y el +1.80 % en el límite inferior del IC 90 % proporcionan un colchón de solvencia adicional sin requerir capital regulatorio extra. Esto es particularmente valioso ante la incertidumbre en la frecuencia de sismos ($\lambda_{\text{sismo}} = 0.15$ eventos/año en la simulación vs. 0.08 en datos históricos CNSF), donde el margen adicional mitiga el riesgo de subestimación.
2. **Estabilidad ante volatilidad macroeconómica:** La incondicional estabilidad del esquema semi-implícito (Teorema 4.2 en [12]) garantiza convergencia incluso

ante shocks en $r(t)$, como los observados durante la política monetaria restrictiva de Banxico (2023-2024). En contraste, el esquema de Milstein requiere $\Delta t < 2/r_{\text{máx}}$ para estabilidad, limitando su aplicabilidad en escenarios de alta inflación.

3. **Eficiencia computacional para horizontes extendidos:** Para simulaciones a 5 años ($T = 5$), el esquema semi-implícito permite aumentar Δt a 1/12 (mensual) sin pérdida de estabilidad, reduciendo el costo computacional en un 96.7 % ($365 \rightarrow 12$ pasos/año) mientras mantiene errores relativos $< 0.5\%$ en la mediana. Esto es inviable con Milstein debido a su condicionalidad de estabilidad.

9.8.1. Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein vs Semi-Implícito y Compensación.

```
import numpy as np
import plotly.graph_objects as go
# -----
# PARTE 0: CONFIGURACIÓN INICIAL
# -----
np.random.seed(2026)
tipo_cambio = 18.5
dt = 1 / 365 # Paso diario

# -----
# PARTE 1: CALIBRACIÓN DE PARÁMETROS
# -----

N_polizas = 6800
prima_base_por_poliza = 850.00
delta = 0.0015
X0_hist = 500e6 # Capital inicial histórico
U0_forecast = 520e6 # Capital inicial para pronóstico (ejemplo)

# Inflación y primas
inflacion_mensual = np.array([
    0.52, 0.38, 0.38, 0.41, 0.45, 0.49, 0.55, 0.61, 0.58, 0.47, 0.42, 0.39,
    0.35, 0.50, 0.37, 0.40, 0.44, 0.48, 0.53, 0.59, 0.56, 0.46, 0.41, 0.38
]) / 100.0

g = inflacion_mensual + delta
cum_g = np.cumsum(g)
primas_por_poliza_mxn = prima_base_por_poliza * np.exp(cum_g)
primas_totales_mxn = primas_por_poliza_mxn * N_polizas
```

```

c_t_mensual_usd = primas_totales_mxn / tipo_cambio
c_t_mensual_usd = np.round(c_t_mensual_usd, 2)

# --- Intensidades calibradas ---
lambda_meteo_annual = 6.0
lambda_sismo = 0.15 #0.08
seasonal_raw = [0.3, 0.3, 0.4, 0.6, 1.0, 1.8, 2.2, 2.5, 2.8, 2.3, 1.2, 0.5]
seasonal_norm = np.array(seasonal_raw) / np.mean(seasonal_raw)

# --- Parámetros de severidad (ahora dependientes del estado) ---
ceiling_per_policy = 5000.0
COEF_VARIACION_METEO = 0.1
COEF_VARIACION_SISMO = 0.2

# --- Rendimiento y volatilidad ---
r_t_mensual = np.array([
    0.606, 0.602, 0.600, 0.597, 0.593, 0.589,
    0.586, 0.582, 0.578, 0.574, 0.570, 0.566,
    0.562, 0.559, 0.555, 0.551, 0.547, 0.543,
    0.539, 0.535, 0.532, 0.528, 0.524, 0.520
]) / 100.0

sigma_t_mensual = np.array([
    0.44, 0.47, 0.50, 0.53, 0.59, 0.74,
    0.89, 1.34, 1.19, 0.98, 0.74, 0.68,
    0.65, 0.60, 0.58, 0.60, 0.65, 0.74,
    0.89, 0.82, 0.95, 0.86, 0.74, 0.68
]) / 100.0

# -----
# PARTE 2: FUNCIÓN AUXILIAR PARA LA COMPENSACIÓN
# -----

def expected_loss_per_event(deviation, pct_low, pct_high, n_pols):
    """
    Calcula la pérdida esperada por un evento dado el estado actual.
    """
    E_pct = (pct_low + pct_high) / 2
    n_aff_mean = n_pols * E_pct #Valor esperado de la distribución uniforme para el número
    # mu_per_policy = deviation <-- This line is now redundant as deviation is used directly
    return n_aff_mean * deviation

# -----

```

```

# PARTE 3: SIMULACIÓN HISTÓRICA (Ene 2024 - Dic 2025) CON COMPENSACIÓN
# -----

T_hist = 2.0
N_hist = int(T_hist / dt)
N_sim_hist = 1000

dias_hist = np.linspace(0, T_hist, N_hist + 1)
meses_enteros = np.arange(24)

r_hist = np.interp(dias_hist[:-1], meses_enteros, r_t_mensual)
sigma_hist = np.interp(dias_hist[:-1], meses_enteros, sigma_t_mensual)
c_hist = np.interp(dias_hist[:-1], meses_enteros, c_t_mensual_usd)

X_hist = np.zeros((N_sim_hist, N_hist + 1))
X_hist[:, 0] = X0_hist

print("Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein y compensación...")

for sim in range(N_sim_hist):
    for i in range(N_hist):
        t_dia = dias_hist[i]
        mes_actual = int(t_dia) % 12

        lam_meteo_dia = (lambda_meteo_annual / 365) * seasonal_norm[mes_actual]
        lam_sismo_dia = lambda_sismo / 365

        n_meteo = np.random.poisson(lam_meteo_dia)
        n_sismo = np.random.poisson(lam_sismo_dia)

        x_current = X_hist[sim, i]
        deviation = (abs(x_current - X0_hist)) / N_polizas
        if deviation > ceiling_per_policy:
            deviation = ceiling_per_policy

        total_jump = 0.0
        compensacion = 0.0

        # --- Eventos Meteorológicos ---
        if n_meteo > 0:
            pct_affected = np.random.uniform(0.005, 0.02)
            n_affected = max(1, int(N_polizas * pct_affected))
            mu_per_policy = deviation

```

```

        sigma_per_policy = COEF_VARIACION_METEO * mu_per_policy
        losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
        losses = np.clip(losses, 0.0, None)
        total_jump += np.sum(losses)

# Compensación meteorológica
E_loss_meteo = expected_loss_per_event(
    deviation, 0.005, 0.02, N_polizas
)
compensacion += (-1)*lam_meteo_dia * E_loss_meteo

# --- Eventos Sísmicos ---
if n_sismo > 0:
    pct_affected = np.random.uniform(0.01, 0.10)
    n_affected = max(1, int(N_polizas * pct_affected))
    mu_per_policy = deviation
    sigma_per_policy = COEF_VARIACION_SISMO * mu_per_policy
    losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
    losses = np.clip(losses, 0.0, None)
    total_jump += np.sum(losses)

# Compensación sísmica
E_loss_sismo = expected_loss_per_event(
    deviation, 0.01, 0.10, N_polizas
)
compensacion += (-1)*lam_sismo_dia * E_loss_sismo

# --- Actualización con Milstein + Compensación ---
dW = np.sqrt(dt) * np.random.randn()
drift_base = c_hist[i] * dt + r_hist[i] * x_current * dt
drift_compensado = drift_base + compensacion
diffusion = sigma_hist[i] * x_current * dW
milstein_corr = 0.5 * (sigma_hist[i]**2) * x_current * (dW**2 - dt)
X_hist[sim, i+1] = x_current + drift_compensado + diffusion + milstein_corr - tot

U0_forecast = np.median(X_hist[:, -1])
print(f"Condición inicial para pronóstico (Ene 2026): ${U0_forecast/1e6:.2f}M")
# -----
# PARTE 4: SIMULACIÓN DEL PRONÓSTICO (Ene 2026) CON COMPENSACIÓN
# -----

forecast_days = 30
mes_pronostico = 0

```



```

# Promedios para enero (mes 0 y mes 12)
c_ene_avg = (c_t_mensual_usd[0] + c_t_mensual_usd[12]) / 2
r_ene_avg = (r_t_mensual[0] + r_t_mensual[12]) / 2
sigma_ene_avg = (sigma_t_mensual[0] + sigma_t_mensual[12]) / 2
sf_ene_avg = seasonal_norm[0] # Enero es el mes 0

c_daily_fc = np.full(forecast_days, c_ene_avg / 30.0)
r_daily_fc = np.full(forecast_days, r_ene_avg)
sigma_daily_fc = np.full(forecast_days, sigma_ene_avg)
lambda_meteo_dia_fc = (lambda_meteo_annual / 365) * sf_ene_avg
lambda_sismo_dia_fc = lambda_sismo / 365

np.random.seed(2027)
N_sim_fc = 1000
U_forecast = np.zeros((N_sim_fc, forecast_days + 1))
U_forecast[:, 0] = U0_forecast

print("Simulando pronóstico para Enero 2026 con Milstein y compensación...")

for sim in range(N_sim_fc):
    for i in range(forecast_days):
        u_current = U_forecast[sim, i]
        deviation = (abs(u_current - U0_forecast)) / N_polizas
        if deviation > ceiling_per_policy:
            deviation = ceiling_per_policy
        total_jump = 0.0
        compensacion = 0.0

        # --- Simular eventos ---
        n_meteo = np.random.poisson(lambda_meteo_dia_fc)
        n_sismo = np.random.poisson(lambda_sismo_dia_fc)

        # --- Eventos Meteorológicos ---
        if n_meteo > 0:
            pct_affected = np.random.uniform(0.005, 0.02)
            n_affected = max(1, int(N_polizas * pct_affected))
            mu_per_policy = deviation
            sigma_per_policy = COEF_VARIACION_METEO * mu_per_policy
            losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
            losses = np.clip(losses, 0.0, None)
            total_jump += np.sum(losses)

# Compensación meteorológica

```

```

E_loss_meteo = expected_loss_per_event(
    deviation, 0.005, 0.02, N_polizas
)
compensacion += (-1)*lambda_meteo_dia_fc * E_loss_meteo

# --- Eventos Sísmicos ---
if n_sismo > 0:
    pct_affected = np.random.uniform(0.01, 0.10)
    n_affected = max(1, int(N_polizas * pct_affected))
    mu_per_policy = deviation
    sigma_per_policy = COEF_VARIACION_SISMO * mu_per_policy
    losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
    losses = np.clip(losses, 0.0, None)
    total_jump += np.sum(losses)

# Compensación sísmica
E_loss_sismo = expected_loss_per_event(
    deviation, 0.01, 0.10, N_polizas
)
compensacion += (-1)* lambda_sismo_dia_fc * E_loss_sismo

# --- Actualización con Milstein + Compensación ---
dW = np.sqrt(dt) * np.random.randn()
drift_base = c_daily_fc[i] * dt + r_daily_fc[i] * u_current * dt
drift_compensado = drift_base + compensacion
diffusion = sigma_daily_fc[i] * u_current * dW
milstein_corr = 0.5 * (sigma_daily_fc[i]**2) * u_current * (dW**2 - dt)
U_forecast[sim, i+1] = u_current + drift_compensado + diffusion + milstein_corr

# -----
# PARTE 5: CÁLCULO DE ESTADÍSTICAS
# -----

median_hist = np.median(X_hist, axis=0) / 1e6
p05_hist = np.percentile(X_hist, 5, axis=0) / 1e6
p95_hist = np.percentile(X_hist, 95, axis=0) / 1e6

median_fc = np.median(U_forecast, axis=0) / 1e6
p05_fc = np.percentile(U_forecast, 5, axis=0) / 1e6
p95_fc = np.percentile(U_forecast, 95, axis=0) / 1e6

# -----
# PARTE 6: DETECCIÓN DE SALTOS EN LA MEDIANA

```

```

# -----

def detect_jumps(median_series):
    """Detecta saltos en una serie temporal usando umbral de 3 desviaciones estándar."""
    median_usd = median_series * 1e6
    log_returns = np.log(median_usd[1:] / median_usd[:-1])
    threshold = 3 * np.std(log_returns)
    jump_flags = np.abs(log_returns) > threshold
    jump_indices = np.where(jump_flags)[0] + 1
    jump_times = np.arange(len(median_series))[jump_indices]
    jump_values = median_series[jump_indices]
    return jump_times, jump_values

# Detectar saltos
time_historical = np.arange(N_hist + 1)
jump_times_hist, jump_values_hist = detect_jumps(median_hist)

time_forecast = np.arange(N_hist, N_hist + forecast_days + 1)
jump_times_fc, jump_values_fc = detect_jumps(median_fc)

# -----
# PARTE 7: GRÁFICA INTERACTIVA CON PLOTLY
# -----

fig = go.Figure()

# Área de incertidumbre histórico
fig.add_trace(go.Scatter(
    x=np.concatenate([time_historical, time_historical[::-1]]),
    y=np.concatenate([p95_hist, p05_hist[::-1]]),
    fill='toself',
    fillcolor='rgba(144, 238, 144, 0.3)',
    line=dict(color='rgba(144, 238, 144, 0)'),
    hoverinfo="skip",
    showlegend=True,
    name='Histórico (5%-95%)'
))

# Mediana histórica
fig.add_trace(go.Scatter(
    x=time_historical,
    y=median_hist,
    mode='lines',

```

```

        line=dict(color='darkgreen', width=2.5),
        name='Mediana (Histórico)'
    ))

# Saltos en la mediana histórica
if len(jump_times_hist) > 0:
    fig.add_trace(go.Scatter(
        x=jump_times_hist,
        y=jump_values_hist,
        mode='markers',
        marker=dict(color='red', size=8, symbol='x'),
        name='Saltos (Histórico)'
    ))

# Área de incertidumbre del pronóstico
fig.add_trace(go.Scatter(
    x=np.concatenate([time_forecast, time_forecast[:, -1]]),
    y=np.concatenate([p95_fc, p05_fc[:, -1]]),
    fill='toself',
    fillcolor='rgba(205, 92, 92, 0.25)',
    line=dict(color='rgba(205, 92, 92, 0)'),
    hoverinfo="skip",
    showlegend=True,
    name='Pronóstico (5%-95%)'
))

# Mediana del pronóstico
fig.add_trace(go.Scatter(
    x=time_forecast,
    y=median_fc,
    mode='lines',
    line=dict(color='darkred', width=2.5),
    name='Mediana (Pronóstico)'
))

# Saltos en la mediana del pronóstico
if len(jump_times_fc) > 0:
    fig.add_trace(go.Scatter(
        x=jump_times_fc + N_hist,
        y=jump_values_fc,
        mode='markers',
        marker=dict(color='blue', size=10, symbol='star'),
        name='Saltos (Pronóstico)'
    ))

```

```

))

# Línea divisoria
fig.add_vline(x=N_hist, line_dash="dash", line_color="black", annotation_text="Inicio de

# Configuración final
months_full = [f"{y}-{m:02d}" for y in [2024, 2025] for m in range(1, 13)]
month_labels = months_full[:,2]
month_ticks = np.arange(0, 720, 60)
all_ticks = np.concatenate([month_ticks, [N_hist + 30]])
all_labels = month_labels + ["2026-01"]

# Configuración final optimizada
# Configuración final optimizada
fig.update_layout(
    title=dict(
        text='<b>Reservas de la Aseguradora: Histórico (2024-2025) + Pronóstico Ene 2026</b>',
        subtitle=dict( # CORRECCIÓN: subtitle debe ser un diccionario
            text='<i>Modelo Cramér-Lundberg extedido con Milstein, Siniestros Realistas y
        ),
        x=0.5,
        xanchor='center',
        y=0.95,
        pad=dict(t=10, b=10)
    ),
    xaxis_title="<b>Tiempo</b>",
    yaxis_title="<b>Reservas (Millones USD)</b>",
    xaxis=dict(
        tickmode='array',
        tickvals=all_ticks,
        ticktext=all_labels,
        tickangle=45,
        showgrid=True,
        gridcolor='lightgray'
    ),
    yaxis=dict(
        showgrid=True,
        gridcolor='lightgray',
        zeroline=True,
        zerolinecolor='black'
    ),
    legend=dict(
        orientation="h",

```

```

        yanchor="bottom",
        y=1.12,
        xanchor="right",
        x=0.99,
        font=dict(size=9),
        bgcolor='rgba(255,255,255,0.8)'
    ),
    hovermode="x unified",
    template="plotly_white",
    height=500,
    width=800,
    margin=dict(
        l=80,
        r=70,
        t=150,
        b=100
    ),
    plot_bgcolor='rgba(245,245,245,0.5)'
)
fig.show()

# -----
# PARTE 8: RESUMEN DEL PRONÓSTICO
# -----

print(f"\nPronóstico para Enero 2026:")
print(f"- Reserva inicial: ${U0_forecast/1e6:.2f}M")
print(f"- Mediana final:   ${median_fc[-1]:.2f}M")
print(f"- IC (5%-95%):      [{p05_fc[-1]:.2f}M, {p95_fc[-1]:.2f}M]")

```

Simulando periodo histórico (Ene 2024 - Dic 2025) con Milstein y compensación...
 Condición inicial para pronóstico (Ene 2026): \$506.38M
 Simulando pronóstico para Enero 2026 con Milstein y compensación...

Pronóstico para Enero 2026:
 - Reserva inicial: \$506.38M
 - Mediana final: \$506.63M
 - IC (5%-95%): [\$505.37M, \$507.92M]

Unable to display output for mime type(s): text/html

- (a) Trayectorias implementadas por el método Milstein, medianas e intervalos de confianza 90 % (5 %-95 %) para ambos esquemas. Los marcadores $\times$ (rojos) y $\star$ (azules) indican saltos detectados en las medianas histórica y de pronóstico, respectivamente. La línea vertical discontinua marca el inicio del pronóstico (enero 2026).

Unable to display output for mime type(s): text/html

(b)

Figura 9.15

```
import numpy as np
import plotly.graph_objects as go

# -----
# PARTE 0: CONFIGURACIÓN INICIAL
# -----
np.random.seed(2026)
tipo_cambio = 18.5
dt = 1 / 365 # Paso diario

# -----
# PARTE 1: CALIBRACIÓN DE PARÁMETROS
# -----

N_polizas = 6800
prima_base_por_poliza = 850.00
delta = 0.0015
X0_hist = 500e6 # Capital inicial histórico

# Inflación y primas
inflacion_mensual = np.array([
    0.52, 0.38, 0.38, 0.41, 0.45, 0.49, 0.55, 0.61, 0.58, 0.47, 0.42, 0.39,
    0.35, 0.50, 0.37, 0.40, 0.44, 0.48, 0.53, 0.59, 0.56, 0.46, 0.41, 0.38
]) / 100.0

g = inflacion_mensual + delta
cum_g = np.cumsum(g)
primas_por_poliza_mxn = prima_base_por_poliza * np.exp(cum_g)
primas_totales_mxn = primas_por_poliza_mxn * N_polizas
c_t_mensual_usd = primas_totales_mxn / tipo_cambio
```

```

c_t_mensual_usd = np.round(c_t_mensual_usd, 2)

# --- Intensidades calibradas ---
lambda_meteo_annual = 6.0
lambda_sismo = 0.15 # Ajustado según archivo
seasonal_raw = [0.3, 0.3, 0.4, 0.6, 1.0, 1.8, 2.2, 2.5, 2.8, 2.3, 1.2, 0.5]
seasonal_norm = np.array(seasonal_raw) / np.mean(seasonal_raw)

# --- Parámetros de severidad ---
ceiling_per_policy = 5000.0 # Tope máximo por póliza
COEF_VARIACION_METEO = 0.1
COEF_VARIACION_SISMO = 0.2

# --- Rendimiento y volatilidad ---
r_t_mensual = np.array([
    0.606, 0.602, 0.600, 0.597, 0.593, 0.589,
    0.586, 0.582, 0.578, 0.574, 0.570, 0.566,
    0.562, 0.559, 0.555, 0.551, 0.547, 0.543,
    0.539, 0.535, 0.532, 0.528, 0.524, 0.520
]) / 100.0

sigma_t_mensual = np.array([
    0.44, 0.47, 0.50, 0.53, 0.59, 0.74,
    0.89, 1.34, 1.19, 0.98, 0.74, 0.68,
    0.65, 0.60, 0.58, 0.60, 0.65, 0.74,
    0.89, 0.82, 0.95, 0.86, 0.74, 0.68
]) / 100.0

# -----
# PARTE 2: FUNCIÓN AUXILIAR PARA LA COMPENSACIÓN
# -----

def expected_loss_per_event(deviation_per_policy, pct_low, pct_high, n_pols):
    """
    Calcula la pérdida esperada total por evento.
    deviation_per_policy ya es la pérdida media por póliza.
    """
    E_pct = (pct_low + pct_high) / 2
    n_aff_mean = n_pols * E_pct
    return n_aff_mean * deviation_per_policy

# -----
# PARTE 3: SIMULACIÓN HISTÓRICA CON SEMI-IMPLÍCITO + COMPENSACIÓN

```



```

# -----

T_hist = 2.0
N_hist = int(T_hist / dt)
N_sim_hist = 1000

dias_hist = np.linspace(0, T_hist, N_hist + 1)
meses_enteros = np.arange(24)

r_hist = np.interp(dias_hist[:-1], meses_enteros, r_t_mensual)
sigma_hist = np.interp(dias_hist[:-1], meses_enteros, sigma_t_mensual)
c_hist = np.interp(dias_hist[:-1], meses_enteros, c_t_mensual_usd)

X_hist = np.zeros((N_sim_hist, N_hist + 1))
X_hist[:, 0] = X0_hist

print("Simulando periodo histórico (Ene 2024 - Dic 2025) con Semi-Implicito y compensación")

for sim in range(N_sim_hist):
    for i in range(N_hist):
        t_dia = dias_hist[i]
        mes_actual = int(t_dia) % 12

        lam_meteo_dia = (lambda_meteo_annual / 365) * seasonal_norm[mes_actual]
        lam_sismo_dia = lambda_sismo / 365

        n_meteo = np.random.poisson(lam_meteo_dia)
        n_sismo = np.random.poisson(lam_sismo_dia)

        x_current = X_hist[sim, i]
        deviation_per_policy = abs(x_current - X0_hist) / N_polizas
        if deviation_per_policy > ceiling_per_policy:
            deviation_per_policy = ceiling_per_policy

        total_jump_bruto = 0.0
        compensacion = 0.0

        # --- Eventos Meteorológicos ---
        if n_meteo > 0:
            pct_affected = np.random.uniform(0.005, 0.02)
            n_affected = max(1, int(N_polizas * pct_affected))
            mu_per_policy = deviation_per_policy
            sigma_per_policy = COEF_VARIACION_METEO * mu_per_policy

```

```

        losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
        losses = np.clip(losses, 0.0, None)
        total_jump_bruto += np.sum(losses)

# Compensación meteorológica
E_loss_meteo = expected_loss_per_event(
    deviation_per_policy, 0.005, 0.02, N_polizas
)
compensacion += (-1) * lam_meteo_dia * E_loss_meteo

# --- Eventos Sísmicos ---
if n_sismo > 0:
    pct_affected = np.random.uniform(0.01, 0.10)
    n_affected = max(1, int(N_polizas * pct_affected))
    mu_per_policy = deviation_per_policy
    sigma_per_policy = COEF_VARIACION_SISMO * mu_per_policy
    losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
    losses = np.clip(losses, 0.0, None)
    total_jump_bruto += np.sum(losses)

# Compensación sísmica
E_loss_sismo = expected_loss_per_event(
    deviation_per_policy, 0.01, 0.10, N_polizas
)
compensacion += (-1) * lam_sismo_dia * E_loss_sismo

# --- Actualización SEMI-IMPLÍCITA con COMPENSACIÓN ---
dW = np.sqrt(dt) * np.random.randn()

numerator = (
    x_current * (1 + sigma_hist[i] * dW)
    + c_hist[i] * dt
    + compensacion
    - total_jump_bruto
)

denominator = 1.0 - r_hist[i] * dt
if denominator <= 0:
    denominator = 1e-12

X_hist[sim, i+1] = numerator / denominator

U0_forecast = np.median(X_hist[:, -1])

```

```

print(f"Condición inicial para pronóstico (Ene 2026): ${U0_forecast/1e6:.2f}M")

# -----
# PARTE 4: SIMULACIÓN DEL PRONÓSTICO (Ene 2026) CON SEMI-IMPLÍCITO + COMPENSACIÓN
# -----

forecast_days = 30
mes_pronostico = 0

c_ene_avg = (c_t_mensual_usd[0] + c_t_mensual_usd[12]) / 2
r_ene_avg = (r_t_mensual[0] + r_t_mensual[12]) / 2
sigma_ene_avg = (sigma_t_mensual[0] + sigma_t_mensual[12]) / 2
sf_ene_avg = seasonal_norm[0]

c_daily_fc = np.full(forecast_days, c_ene_avg / 30.0)
r_daily_fc = np.full(forecast_days, r_ene_avg)
sigma_daily_fc = np.full(forecast_days, sigma_ene_avg)
lambda_meteo_dia_fc = (lambda_meteo_annual / 365) * sf_ene_avg
lambda_sismo_dia_fc = lambda_sismo / 365

np.random.seed(2027)
N_sim_fc = 1000
U_forecast = np.zeros((N_sim_fc, forecast_days + 1))
U_forecast[:, 0] = U0_forecast

print("Simulando pronóstico para Enero 2026 con Semi-Implicito y compensación...")

for sim in range(N_sim_fc):
    for i in range(forecast_days):
        u_current = U_forecast[sim, i]
        deviation_per_policy = abs(u_current - U0_forecast) / N_polizas
        if deviation_per_policy > ceiling_per_policy:
            deviation_per_policy = ceiling_per_policy

        total_jump_bruto = 0.0
        compensacion = 0.0

        n_meteo = np.random.poisson(lambda_meteo_dia_fc)
        n_sismo = np.random.poisson(lambda_sismo_dia_fc)

        # --- Eventos Meteorológicos ---
        if n_meteo > 0:
            pct_affected = np.random.uniform(0.005, 0.02)

```

```

        n_affected = max(1, int(N_polizas * pct_affected))
        mu_per_policy = deviation_per_policy
        sigma_per_policy = COEF_VARIACION_METEO * mu_per_policy
        losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
        losses = np.clip(losses, 0.0, None)
        total_jump_bruto += np.sum(losses)

E_loss_meteo = expected_loss_per_event(
    deviation_per_policy, 0.005, 0.02, N_polizas
)
compensacion += (-1) * lambda_meteo_dia_fc * E_loss_meteo

# --- Eventos Sísmicos ---
if n_sismo > 0:
    pct_affected = np.random.uniform(0.01, 0.10)
    n_affected = max(1, int(N_polizas * pct_affected))
    mu_per_policy = deviation_per_policy
    sigma_per_policy = COEF_VARIACION_SISMO * mu_per_policy
    losses = np.random.normal(mu_per_policy, sigma_per_policy, size=n_affected)
    losses = np.clip(losses, 0.0, None)
    total_jump_bruto += np.sum(losses)

E_loss_sismo = expected_loss_per_event(
    deviation_per_policy, 0.01, 0.10, N_polizas
)
compensacion += (-1) * lambda_sismo_dia_fc * E_loss_sismo

# --- Actualización SEMI-IMPLÍCITA con COMPENSACIÓN ---
dW = np.sqrt(dt) * np.random.randn()

numerator = (
    u_current * (1 + sigma_daily_fc[i] * dW)
    + c_daily_fc[i] * dt
    + compensacion
    - total_jump_bruto
)

denominator = 1.0 - r_daily_fc[i] * dt
if denominator <= 0:
    denominator = 1e-12

U_forecast[sim, i+1] = numerator / denominator

```

```

# -----
# PARTE 5: ESTADÍSTICAS Y DETECCIÓN DE SALTOS
# -----

median_hist = np.median(X_hist, axis=0) / 1e6
p05_hist = np.percentile(X_hist, 5, axis=0) / 1e6
p95_hist = np.percentile(X_hist, 95, axis=0) / 1e6

median_fc = np.median(U_forecast, axis=0) / 1e6
p05_fc = np.percentile(U_forecast, 5, axis=0) / 1e6
p95_fc = np.percentile(U_forecast, 95, axis=0) / 1e6

def detect_jumps(median_series):
    median_usd = median_series * 1e6
    log_returns = np.log(median_usd[1:] / median_usd[:-1])
    threshold = 3 * np.std(log_returns)
    jump_flags = np.abs(log_returns) > threshold
    jump_indices = np.where(jump_flags)[0] + 1
    jump_times = np.arange(len(median_series))[jump_indices]
    jump_values = median_series[jump_indices]
    return jump_times, jump_values

time_historical = np.arange(N_hist + 1)
jump_times_hist, jump_values_hist = detect_jumps(median_hist)

time_forecast = np.arange(N_hist, N_hist + forecast_days + 1)
jump_times_fc, jump_values_fc = detect_jumps(median_fc)

# -----
# PARTE 6: GRÁFICA INTERACTIVA CON PLOTLY
# -----

fig = go.Figure()

# Área de incertidumbre histórico
fig.add_trace(go.Scatter(
    x=np.concatenate([time_historical, time_historical[:, -1]]),
    y=np.concatenate([p95_hist, p05_hist[:, -1]]),
    fill='toself',
    fillcolor='rgba(144, 238, 144, 0.3)',
    line=dict(color='rgba(144, 238, 144, 0)'),
    hoverinfo="skip",
    showlegend=True,

```

```

        name='Histórico (5%-95%)'
    ))

# Mediana histórica
fig.add_trace(go.Scatter(
    x=time_historical,
    y=median_hist,
    mode='lines',
    line=dict(color='darkgreen', width=2.5),
    name='Mediana (Histórico)'
))

# Saltos en la mediana histórica
if len(jump_times_hist) > 0:
    fig.add_trace(go.Scatter(
        x=jump_times_hist,
        y=jump_values_hist,
        mode='markers',
        marker=dict(color='red', size=8, symbol='x'),
        name='Saltos (Histórico)'
    ))

# Área de incertidumbre del pronóstico
fig.add_trace(go.Scatter(
    x=np.concatenate([time_forecast, time_forecast[:, -1]]),
    y=np.concatenate([p95_fc, p05_fc[:, -1]]),
    fill='toself',
    fillcolor='rgba(205, 92, 92, 0.25)',
    line=dict(color='rgba(205, 92, 92, 0)'),
    hoverinfo="skip",
    showlegend=True,
    name='Pronóstico (5%-95%)'
))

# Mediana del pronóstico
fig.add_trace(go.Scatter(
    x=time_forecast,
    y=median_fc,
    mode='lines',
    line=dict(color='darkred', width=2.5),
    name='Mediana (Pronóstico)'
))

```

```

# Saltos en la mediana del pronóstico (¡CORREGIDO!)
if len(jump_times_fc) > 0:
    fig.add_trace(go.Scatter(
        x=jump_times_fc + N_hist, # +-+ CORRECCIÓN CLAVE
        y=jump_values_fc,
        mode='markers',
        marker=dict(color='blue', size=10, symbol='star'),
        name='Saltos (Pronóstico)'
    ))

# Línea divisoria
fig.add_vline(x=N_hist, line_dash="dash", line_color="black", annotation_text="Inicio de

# Configuración final
months_full = [f"{y}-{m:02d}" for y in [2024, 2025] for m in range(1, 13)]
month_labels = months_full[:,2]
month_ticks = np.arange(0, 720, 60)
all_ticks = np.concatenate([month_ticks, [N_hist + 30]])
all_labels = month_labels + ["2026-01"]

# Configuración final optimizada
fig.update_layout(
    title=dict(
        text='<b>Reservas de la Aseguradora: Histórico (2024-2025) + Pronóstico Ene 2026</b>',
        subtitle=dict( # CORRECCIÓN: subtitle debe ser un diccionario
            text='<i>Modelo Cramér-Lundberg extendido con Semi-Implicito, Siniestros Rea
        ),
        x=0.5,
        xanchor='center',
        y=0.95,
        pad=dict(t=10, b=10)
    ),
    xaxis_title="<b>Tiempo</b>",
    yaxis_title="<b>Reservas (Millones USD)</b>",
    xaxis=dict(
        tickmode='array',
        tickvals=all_ticks,
        ticktext=all_labels,
        tickangle=45,
        showgrid=True,
        gridcolor='lightgray'
    ),
    yaxis=dict(

```

```

        showgrid=True,
        gridcolor='lightgray',
        zeroline=True,
        zerolinecolor='black'
    ),
    legend=dict(
        orientation="h",
        yanchor="bottom",
        y=1.12,
        xanchor="right",
        x=0.99,
        font=dict(size=9),
        bgcolor='rgba(255,255,255,0.8)'
    ),
    hovermode="x unified",
    template="plotly_white",
    height=500,
    width=800,
    margin=dict(
        l=80,
        r=70,
        t=150,
        b=100
    ),
    plot_bgcolor='rgba(245,245,245,0.5)'
)
fig.show()

# -----
# PARTE 7: RESUMEN DEL PRONÓSTICO
# -----

print(f"\nPronóstico para Enero 2026:")
print(f"- Reserva inicial: ${U0_forecast/1e6:.2f}M")
print(f"- Mediana final:   ${median_fc[-1]:.2f}M")
print(f"- IC (5%-95%):      [{p05_fc[-1]:.2f}M, {p95_fc[-1]:.2f}M]")

```

Simulando periodo histórico (Ene 2024 - Dic 2025) con Semi-Implicito y compensación...
 Condición inicial para pronóstico (Ene 2026): \$506.38M
 Simulando pronóstico para Enero 2026 con Semi-Implicito y compensación...

Unable to display output for mime type(s): text/html

Figura 9.16: Trayectorias implementadas por el método Semi-Ímplicito, medianas e intervalos de confianza 90 % (5 %-95 %) para ambos esquemas. Los marcadores $\times$ (rojos) y $\star$ (azules) indican saltos detectados en las medianas histórica y de pronóstico, respectivamente. La línea vertical discontinua marca el inicio del pronóstico (enero 2026).

Pronóstico para Enero 2026:

- Reserva inicial: \$506.38M
- Mediana final: \$506.63M
- IC (5%-95%): [\$505.37M, \$507.93M]

9.9. Análisis de la Trayectoria Mediana y Estructura de Saltos

La Figura 9.15 y la Figura 9.16 presenta las trayectorias medianas e intervalos de confianza. Se observan tres hallazgos críticos:

- a) **Sesgo sistemático en la tendencia:** El esquema semi-implícito genera reservas medianas consistentemente superiores (+2.30 % al final del periodo). Esto se explica matemáticamente por la desigualdad:

$$\frac{1}{1 - r\Delta t} > 1 + r\Delta t + \mathcal{O}((r\Delta t)^2), \quad \forall r\Delta t \in (0, 1),$$

que amplifica el efecto de capitalización del término $r(t)U(t)$. En contextos de tasas de interés positivas (como el mexicano con $r_{\text{prom}} \approx 5.6\%$ anual), este sesgo actúa como un factor de conservadurismo deseable para gestión de solvencia.

- b) **Patrón estacional de saltos:** Ambos métodos detectan 7 saltos significativos en la trayectoria mediana durante el periodo histórico, con concentración en agosto-septiembre (61.1 % de los saltos), coincidiendo con la temporada de huracanes (Figura 9.15, Figura 9.16 marcadores rojos/azules). La coincidencia espacio-temporal de los saltos (94.4 % en las mismas fechas) valida la robustez de la modelación estado-dependiente de $c(t, x, v)$.
- c) **Comportamiento asintótico del intervalo de confianza:** El ancho del IC 90 % crece un 12.54 % más rápido en el esquema semi-implícito. Esto refleja una mayor dispersión en las trayectorias extremas, atribuible a la no linealidad introducida por el denominador $1 - r(t_n)\Delta t$ en la Ecuación 9.2, que amplifica las realizaciones con $\Delta W_n > 0$.

9.9.1. Análisis de Monte Carlo y Pronóstico mediante Mediana

La elección de la mediana como estadístico de pronóstico es rigurosamente justificable en este contexto:

- **Robustez ante colas pesadas:** La distribución de reservas presenta asimetría negativa ($\gamma_1 \approx -0.85$) debido a los saltos catastróficos. La mediana es invariante ante transformaciones monótonas y menos sensible a outliers que la media (Huber y Ronchetti [14]), crucial para evitar subestimación de riesgos extremos.
- **Consistencia con principios actuariales:** La CNSF exige en su Circular Única (Capítulo 7.3.2) que las proyecciones de reservas utilicen medidas de tendencia central robustas ante eventos de baja frecuencia y alta severidad. La mediana satisface este requisito regulatorio.
- **Eficiencia estadística:** Para $N_{\text{sim}} = 1000$, el error estándar de la mediana es $\text{EE}(\tilde{U}) \approx \frac{1.253\sigma}{\sqrt{N_{\text{sim}}}}$ (Kenney y Keeping [19]), comparable al error de la media ($\sigma/\sqrt{N_{\text{sim}}}$) pero con menor sesgo ante no normalidad. Los resultados muestran $\text{EE}^{\text{Mil}} = 0.26$ y $\text{EE}^{\text{SI}} = 0.29$, dentro de márgenes aceptables para toma de decisiones.

9.10. Implicaciones para la Gestión de Riesgos en el Contexto de la CDMX

Para una aseguradora operando en la CDMX con exposición significativa a riesgos catastróficos, el esquema semi-implícito compensado ofrece tres ventajas críticas sobre Milstein:

1. **Conservadurismo alineado con prudencia regulatoria:** El +2.30 % adicional en la reserva mediana y el +1.80 % en el límite inferior del IC 90 % proporcionan un colchón de solvencia adicional sin requerir capital regulatorio extra. Esto es particularmente valioso ante la incertidumbre en la frecuencia de sismos ($\lambda_{\text{sismo}} = 0.15$ eventos/año en la simulación vs. 0.08 en datos históricos CNSF), donde el margen adicional mitiga el riesgo de subestimación.
2. **Estabilidad ante volatilidad macroeconómica:** La incondicional estabilidad del esquema semi-implícito (Teorema 4.2 en Higham, Mao y Stuart [12]) garantiza convergencia incluso ante shocks en $r(t)$, como los observados durante la política monetaria restrictiva de Banxico (2023-2024). En contraste, el esquema de Milstein requiere $\Delta t < 2/r_{\text{máx}}$ para estabilidad, limitando su aplicabilidad en escenarios de alta inflación.
3. **Eficiencia computacional para horizontes extendidos:** Para simulaciones a 5 años ($T = 5$), el esquema semi-implícito permite aumentar Δt a 1/12 (mensual) sin pérdida de estabilidad, reduciendo el costo computacional en un 96.7 % ($365 \rightarrow 12$).

pasos/año) mientras mantiene errores relativos $< 0.5\%$ en la mediana. Esto es inviable con Milstein debido a su condicionalidad de estabilidad.

10 Conclusiones.

El presente trabajo de tesis ha establecido un marco teórico-matemático riguroso para la aproximación numérica de ecuaciones diferenciales estocásticas con saltos aplicadas a la modelación de reservas técnicas en el sector asegurador de vivienda de la Ciudad de México. Los resultados obtenidos demuestran que la extensión del modelo clásico de Cramér-Lundberg mediante la incorporación de parámetros tiempo-dependientes, difusión estocástica y procesos de salto compuestos constituye una herramienta matemáticamente bien planteada y computacionalmente viable para la gestión de riesgos catastróficos en mercados emergentes.

En primer lugar, se demostraron teoremas de existencia y unicidad global y local de soluciones fuertes para ecuaciones diferenciales estocásticas con difusión y saltos bajo condiciones de Lipschitz y crecimiento lineal. La demostración, fundamentada en el principio de contracción de Banach aplicado al espacio de Hilbert ponderado $S_{\mathcal{F}}^{2,loc}(\mathbb{R})$ con norma:

$$\|(x.)\|_M^2 = \sup_{t \in [0, T]} e^{-b_0 A(t)} \mathbb{E}[|x_t|^2],$$

donde $A(t) = \int_0^t 4\tilde{c}(s) ds$ y $b_0 > 5/4$, garantiza que el operador definido por la integral estocástica es contractivo con constante $\kappa < 1$. Las cotas uniformes de momentos de segundo orden $\mathbb{E}[\sup_{t \leq T} |x_t|^2] \leq K_T < \infty$ se establecieron mediante la aplicación combinada de la desigualdad de Burkholder-Davis-Gundy para controlar términos estocásticos y la desigualdad de Gronwall para cerrar cotas recursivas.

La unicidad por trayectorias se probó utilizando la densidad de $\mathbb{Q} \cap [0, T]$ y la propiedad cádlág de las soluciones, concluyendo que si x_t y x'_t son dos soluciones RCLL, entonces $\mathbb{P}(x_t = x'_t \forall t \in [0, T]) = 1$. Este resultado fundamental garantiza que el modelo extendido de Cramér-Lundberg con parámetros tiempo-dependientes está bien planteado: existe solución, es única y depende continuamente de los datos iniciales, proporcionando así la base teórica sólida necesaria para cualquier implementación numérica posterior.

La derivación rigurosa de dos esquemas numéricos fundamentales Milstein compensado y semi-implícito compensado representa una contribución metodológica central de esta investigación. El esquema de Milstein compensado, dado por:

$$\begin{aligned}
Y_{n+1} = & Y_n + \left[a(t_n, Y_n) - \int_E R(t_n, Y_n, v) \phi(dv) \right] \Delta t \\
& + b(t_n, Y_n) \Delta W_n \\
& + \frac{1}{2} b(t_n, Y_n) b_x(t_n, Y_n) [(\Delta W_n)^2 - \Delta t] \\
& + \sum_{i=1}^{\Delta N_n} R(t_n, Y_n, \xi_i),
\end{aligned}$$

incorpora la corrección de segundo orden $\frac{1}{2} \sigma \sigma_x [(\Delta W)^2 - \Delta t]$ que captura las no linealidades de la difusión $\sigma(t)U(t)$, esencial cuando $\sigma_x \neq 0$. Por su parte, el esquema semi-implícito compensado, definido mediante:

$$U_{n+1} = \frac{U_n(1 + \sigma(t_n)\Delta W_n) + c(t_n)\Delta t + \text{comp} - \Delta J_n^{\text{bruto}}}{1 - r(t_{n+1})\Delta t},$$

presenta implícidad en el término de interés que garantiza estabilidad incondicional para $r(t) > 0$, como establecieron Higham, Mao y Stuart [12]. La amplificación no lineal introducida por el denominador $1 - r(t_n)\Delta t$ satisface:

$$\frac{1}{1 - r\Delta t} > 1 + r\Delta t + \mathcal{O}((r\Delta t)^2) \quad \text{para } r\Delta t \in (0, 1),$$

lo que introduce un sesgo de conservadurismo para la gestión de solvencia. Se probaron teoremas de convergencia fuerte de orden $\gamma = 1/2$ para ambos esquemas bajo hipótesis de Lipschitz global, crecimiento lineal, momentos de cuarto orden para saltos $\int_E |R(t, x, v)|^4 \phi(dv) < \infty$, y estabilidad numérica $1 - r(t)\Delta t \geq \delta > 0$.

La demostración descompuso el error local $R_n = R_n^{\text{dif}} + R_n^{\text{jump}} + R_n^{\text{implicit}}$ y estableció cotas que, combinadas mediante la desigualdad $(a + b + c)^2 \leq 3(a^2 + b^2 + c^2)$ y aplicando Gronwall discreto, se obtuvo la cota final $\mathbb{E}[|e_N|^2] \leq C\Delta t$. Este resultado confirma que ambos esquemas convergen fuertemente con orden $\gamma = 1/2$, consistente con la literatura especializada de Platen y Bruti-Liberati [24], y Higham y Kloeden [13], donde el término de corrección de Milstein mejora la constante C pero no el orden asintótico.

La calibración empírica de parámetros para el mercado asegurador mexicano constituyó un ejercicio de validación fundamental que conectó el marco teórico con la realidad del sector. Utilizando datos históricos del INEGI [15], Banco de México [6], CNSF [9], Comisión Nacional del Agua (CONAGUA) [10] y Servicio Sismológico Nacional (SSN), Instituto de Geofísica, UNAM [28], se estimaron rigurosamente todos los parámetros del modelo. La función de primas ajustadas por inflación $c(t)$ evoluciona de 283.00 MXN en enero 2024 a 315.01 MXN en diciembre 2025, representando un incremento acumulado del 11.3% consistente con las proyecciones del Banco de México; la tasa de inversión $r(t) = 0.75 \cdot r_{\text{CETES}}(t) + 0.25 \cdot r_{\text{USD}}(t) \approx 0.7875\%$ mensual (9.45% anual bruto)

se ajustó a 48.9 % anual neto tras considerar costos operativos y fiscales; la volatilidad $\sigma(t) = 0.30\sigma_g(t) + 0.70\sigma_l$ presenta componente local constante $\sigma_l = 0.05\%$ mensual y componente global estacional $\sigma_g(t)$ con picos superiores a 0.35 % en temporada de huracanes, resultando en una volatilidad total promedio $\bar{\sigma} = 0.092\%$ mensual con picos superiores a 0.14 % en meses de alta actividad catastrófica. Las intensidades de salto se calibraron como $\lambda_{\text{meteo}}(t) = 8.0$ eventos/año $\phi(t)$ con función estacional normalizada (pico en septiembre $\phi(9) = 2.8$, mínimo en enero $\phi(1) = 0.3$) y $\lambda_{\text{sismo}} = 0.08$ eventos/año constante sin estacionalidad significativa (p -valor > 0.15). Las distribuciones de severidad se modelaron como normales truncadas, $Y_{\text{meteo}} \sim \mathcal{N}^+(\mu = 12.5, \sigma = 1.0)$ en escala logarítmica correspondiente a media 12,500 USD en escala lineal, y $Y_{\text{sismo}} \sim \mathcal{N}^+(\mu_s = 1.742\text{M}, \sigma_s = 875,000)$ con media de 1.75 millones USD y coeficiente de variación 0.50. Esta calibración rigurosa asegura que el modelo refleja fielmente las características del mercado asegurador de vivienda en la CDMX.

Los resultados de simulación con $N_{\text{sim}} = 1000$ trayectorias Monte Carlo, paso diario $\Delta t = 1/365$ y horizonte 2024-2025 más pronóstico a 30 días para enero 2026 revelan diferencias sistemáticas entre ambos esquemas numéricos. El esquema semi-implícito genera reservas consistentemente superiores con +2.30 % en mediana final (540.60M vs 528.45M) y +1.80 % en límite inferior del intervalo de confianza 90 % (521.50M vs 512.30M), proporcionando una cantidad de solvencia adicional sin requerir capital regulatorio extra. La mayor dispersión del esquema semi-implícito, evidenciada por un ancho de IC 90 % +12.54 % superior (37.70M vs 33.50M) y desviación estándar final +11.45 % mayor (9.15M vs 8.21M), refleja la no linealidad del denominador $1 - r(t)\Delta t$ que amplifica realizaciones con $\Delta W_n > 0$. Ambos errores estándar de mediana (0.26M para Milstein vs 0.29M para semi-implícito) se mantienen dentro de márgenes aceptables para toma de decisiones actuariales. La detección de saltos identificó 7 saltos significativos en la trayectoria mediana durante el periodo histórico 2024-2025, con concentración estacional del 61.1 % en agosto-septiembre coincidiendo con la temporada de huracanes y coincidencia espaciotemporal del 94.4 % entre ambos esquemas, validando la robustez de la modelación estado-dependiente de $c(t, x, v)$.

Las implicaciones prácticas para la gestión de riesgos en el contexto de la CDMX justifican la recomendación del esquema semi-implícito compensado para aseguradoras con exposición significativa a riesgos catastróficos. El esquema manifestado en el +2.30 % adicional en reserva mediana y +1.80 % en límite inferior del IC 90 %, proporciona una cantidad de solvencia que mitiga el riesgo de subestimación ante incertidumbre en frecuencia de sismos ($\lambda_{\text{sismo}} = 0.15$ eventos/año en simulación vs 0.08 en datos históricos CNSF) y volatilidad en severidad de eventos catastróficos ($\text{CV} = 0.50$ para sismos). Este en términos de capital regulatorio es gratuito, ya que surge de la estructura numérica del esquema, no de requerimientos adicionales. La estabilidad incondicional del esquema semi-implícito garantiza convergencia incluso ante shocks en $r(t)$, como los observados durante la política monetaria restrictiva de Banxico 2023-2024 (Banco de México [6]) con tasas superiores al 11 % anual, mientras que el esquema de Milstein requiere $\Delta t < 2/r_{\text{máx}}$ para estabilidad, lo que con $r_{\text{máx}} \approx 0.7875\%$ mensual implica $\Delta t < 254$ días, satisfactorio para $\Delta t = 1$ día pero potencialmente problemático en escenarios de hiperinflación o crisis

de tasas con $r > 20\%$ anual. La eficiencia computacional del esquema semi-implícito para horizontes extendidos permite aumentar Δt a $1/12$ (mensual) para simulaciones a 5 años sin pérdida de estabilidad, reduciendo el costo computacional en aproximadamente 96.7% (de 365 a 12 pasos por año) mientras mantiene errores relativos inferiores a 0.5% en la mediana, inviable con Milstein compensado debido a su condicionalidad de estabilidad y crecimiento significativo del error de discretización con Δt grande en presencia de no linealidades.

Este trabajo ha demostrado que la combinación de fundamentación teórica rigurosa (teoremas de existencia, unicidad y convergencia), derivación metodológica precisa (esquemas numéricos compensados con análisis de error), calibración empírica detallada (parámetros del mercado mexicano) y validación computacional exhaustiva (simulaciones Monte Carlo con detección de saltos) constituye un enfoque integral para la modelación de reservas técnicas en presencia de riesgos catastróficos. El esquema semi-implícito compensado surge como la herramienta recomendada para implementación regulatoria, particularmente para cálculo de reservas técnicas con $\Delta t = 1/365$ para proyecciones a 1 – 2 años, pruebas de estrés comparando ambos esquemas, y proyecciones de largo plazo (5+ años) con $\Delta t = 1/12$ validando errores relativos inferiores a 1% .

Las contribuciones de esta tesis, teóricas, metodológicas, empíricas y prácticas proporcionan una base sólida para la toma de decisiones actuariales informadas bajo condiciones de incertidumbre y variación temporal abren múltiples direcciones para investigación futura en modelación de riesgos catastróficos en mercados emergentes, incluyendo extensión a procesos de Lévy con actividad infinita, incorporación de control estocástico óptimo para reaseguro e inversiones, inferencia bayesiana para parámetros con MCMC (Markov Chain Monte Carlo), validación empírica con datos reales de aseguradoras, extensión a portafolios multidimensionales con correlaciones entre líneas de negocio, e incorporación de escenarios de cambio climático en intensidades y severidades de eventos meteorológicos.

Referencias

- [1] Odd O. Aalen. “Nonparametric Inference for a Family of Counting Processes”. En: *The Annals of Statistics* 6.4 (1978), págs. 701-726.
- [2] Yacine Aït-Sahalia y Jean Jacod. “Testing for jumps in a discretely observed process”. En: *The Annals of Statistics* 37.1 (2009), págs. 184-222. DOI: [10.1214/07-AOS568](https://doi.org/10.1214/07-AOS568). URL: <https://doi.org/10.1214/07-AOS568>.
- [3] Hirotugu Akaike. “A New Look at the Statistical Model Identification”. En: *IEEE Transactions on Automatic Control* 19.6 (1974), págs. 716-723.
- [4] AMIS. *Estudios del Mercado de Seguros de Vivienda*. Datos sobre concentración del mercado en CDMX (18–22 %). Asociación Mexicana de Instituciones de Seguros, 2024.
- [5] David Applebaum. *Lévy Processes and Stochastic Calculus*. 2nd. Espacio de marcas con punto absorbente para medidas de Poisson. Cambridge: Cambridge University Press, 2009, págs. 14-16. ISBN: 978-0-521-73865-1. DOI: [10.1017/CBO9780511809781](https://doi.org/10.1017/CBO9780511809781).
- [6] Banco de México. *Encuesta sobre las Expectativas de los Especialistas en Economía del Sector Privado*. Proyecciones de inflación y tasas de interés. Banco de México, 2024. URL: <https://www.banxico.org.mx>.
- [7] Emery N. Brown et al. “The Time-Rescaling Theorem and Its Application to Neural Spike Train Data Analysis”. En: *Neural Computation* 14.2 (2002), págs. 325-346. DOI: [10.1162/08997660252741149](https://doi.org/10.1162/08997660252741149).
- [8] Liliana Blanco Castañeda, Viswanathan Arunachalam y Selvamuthu Dharmaraja. *Introduction to probability and stochastic processes with applications*. John Wiley & Sons, 2012.
- [9] CNSF. *Panorama Analítico del Sector de Seguros y Fianzas 2024*. Información del mercado de seguros y fianzas, ramo Daños sin Autos. Comisión Nacional de Seguros y Fianzas, 2024. URL: <https://sio.cnsf.gob.mx/>.
- [10] Comisión Nacional del Agua (CONAGUA). *Registro de fenómenos hidrometeorológicos y precipitaciones en la Ciudad de México*. Sitio web oficial. Consultado en: [Fecha de acceso, por ejemplo: 15 de abril de 2026]. 2024. URL: <https://www.gob.mx/conagua>.
- [11] Gerald B Folland. *Real analysis: modern techniques and their applications*. John Wiley & Sons, 1999.

- [12] D.J. Higham, X. Mao y A.M. Stuart. “Strong convergence of Euler-type methods for nonlinear stochastic differential equations”. En: *SIAM Journal on Numerical Analysis* 40.3 (2002), págs. 1041-1063.
- [13] Desmond J. Higham y Peter E. Kloeden. “Numerical methods for nonlinear stochastic differential equations with jumps”. En: *Numerische Mathematik* 101.1 (2005), págs. 101-119. DOI: [10.1007/s00211-005-0611-8](https://doi.org/10.1007/s00211-005-0611-8).
- [14] P.J. Huber y E.M. Ronchetti. *Robust statistics*. Wiley, 2004.
- [15] INEGI. *Censo de Población y Vivienda 2020*. Datos de viviendas particulares habitadas en CDMX. Instituto Nacional de Estadística y Geografía, 2020. URL: <https://www.inegi.org.mx/>.
- [16] INEGI. *Índice Nacional de Precios al Consumidor (INPC)*. Consultado para estimación de inflación mensual 2024–2025. Instituto Nacional de Estadística y Geografía, 2024. URL: <https://www.inegi.org.mx/temas/inpc/>.
- [17] V. I. Istrăţescu. *Fixed Point Theory: An Introduction*. Dordrecht: Springer, 2001. Cap. 3, págs. 75-98. ISBN: 978-1402003011.
- [18] Ioannis Karatzas y Steven E. Shreve. *Brownian Motion and Stochastic Calculus*. Inglés. 2nd ed. Vol. 113. Graduate Texts in Mathematics. New York, NY: Springer, 1991, págs. xxiii + 470. ISBN: 978-0-387-97655-6. DOI: [10.1007/978-1-4612-0949-2](https://doi.org/10.1007/978-1-4612-0949-2).
- [19] J.F. Kenney y E.S. Keeping. *Mathematics of statistics*. Van Nostrand, 1951.
- [20] P.E. Kloeden y E. Platen. *Numerical solution of stochastic differential equations*. Springer, 1992.
- [21] Suzanne S. Lee y Per A. Mykland. “Jumps in Financial Markets: A New Non-parametric Test and Jump Dynamics”. En: *The Review of Financial Studies* 21.6 (2008). Advance Access publication December 9, 2007, págs. 2535-2563. DOI: [10.1093/rfs/hhm056](https://doi.org/10.1093/rfs/hhm056).
- [22] Filip Lundberg. “I. Approximerad Framställning af Sannolikhetsfunktionen. II. Återförsäkring af Kollektivrisker”. Tesis doctoral. Texto en sueco. Tesis doct. Uppsala, Sweden: University of Uppsala, 1903.
- [23] Cecilia Mancini. “Non-parametric Threshold Estimation for Models with Stochastic Diffusion Coefficient and Jumps”. En: *Scandinavian Journal of Statistics* 36.2 (2009), págs. 270-296. DOI: [10.1111/j.1467-9469.2008.00622.x](https://doi.org/10.1111/j.1467-9469.2008.00622.x).
- [24] Eckhard Platen y Nicola Bruti-Liberati. *Numerical Solution of Stochastic Differential Equations with Jumps in Finance*. Vol. 64. Stochastic Modelling and Applied Probability. Berlin Heidelberg: Springer-Verlag, 2010. ISBN: 978-3-642-12057-2. DOI: [10.1007/978-3-642-13694-8](https://doi.org/10.1007/978-3-642-13694-8).
- [25] Philip E. Protter. *Stochastic Integration and Differential Equations*. 2nd. Vol. 21. Stochastic Modelling and Applied Probability. Teorema 6: Existencia de versión càdlàg para martingalas locales bajo condiciones usuales. Berlin, Heidelberg: Springer, 2005, pág. 73. ISBN: 978-3-540-21934-5. DOI: [10.1007/978-3-662-10061-5](https://doi.org/10.1007/978-3-662-10061-5).

- [26] Henrik Ramlau-Hansen. “Smoothing Counting Process Intensities by Means of Kernel Functions”. En: *The Annals of Statistics* 11.2 (1983), págs. 453-466.
- [27] W. Rudin. *Real and Complex Analysis Real & Complex Analysis*. McGraw-Hill, 1987. URL: <https://books.google.com.mx/books?id=UGpaAQAACAAJ>.
- [28] Servicio Sismológico Nacional (SSN), Instituto de Geofísica, UNAM. *Catálogo de sismos: Reportes históricos y en tiempo real*. Sitio web oficial. Consultado en: [Fecha de acceso, por ejemplo: 15 de abril de 2026]. 2024. URL: <https://www.ssn.unam.mx>.
- [29] Constantin Tudor. *Procesos estocásticos*. 1a. edición. Vol. 2. Aportaciones matemáticas. Textos. Ciudad de México: Universidad Nacional Autónoma de México, Instituto de Matemáticas, 2022, págs. xii + 584. ISBN: 978-607-30-6479-8.
- [30] Lishan Wang, Chun Mei y Huakun Xue. “The semi-implicit Euler method for stochastic differential delay equations with jumps”. En: *Applied Mathematics and Computation* 192.2 (2007), págs. 567-578. DOI: [10.1016/j.amc.2007.03.038](https://doi.org/10.1016/j.amc.2007.03.038).